planteamiento del proyecto

Angel Santiago Barrantes Montoya

2026-09-26

Proyecto: Modelación estadística para inversiones de corto plazo

1. Planteamiento del problema

Una serie de precios bursátiles no es una muestra de observaciones independientes e idénticamente distribuidas. Es la realización de un proceso estocástico cuyo nivel no es estacionario: la media y la varianza del precio dependen del momento en que se observen, de modo que estadísticos como el promedio o la desviación estándar del precio carecen de interpretación estable. Esta es la primera dificultad práctica que enfrenta cualquier análisis financiero aplicado, y la que obliga a trabajar no sobre el precio sino sobre una transformación suya.

La transformación habitual es el rendimiento logarítmico, definido como el logaritmo del cociente entre dos cierres consecutivos. Su uso no es arbitrario: estabiliza la varianza, convierte los cambios porcentuales en una escala aditiva en el tiempo y elimina buena parte de la tendencia que hace no estacionario al precio. Sin embargo, resolver el problema del nivel no resuelve el problema de la forma. Los rendimientos financieros presentan de manera sistemática colas más pesadas que las de una distribución normal, agrupamiento de volatilidad —periodos tranquilos seguidos de periodos agitados— y valores extremos que no son errores de medición sino parte legítima del fenómeno. En consecuencia, los estadísticos construidos sobre el supuesto de normalidad, empezando por la media aritmética y el coeficiente de correlación de Pearson, se vuelven frágiles justamente en los tramos que más importan para una decisión de inversión.

A esta dificultad distribucional se suma una de estructura de dependencia. En la práctica financiera se asume que la asociación entre dos activos queda resumida por un coeficiente de correlación lineal, y que un valor cercano a cero autoriza a tratarlos como independientes. Ambas afirmaciones son aproximaciones. La correlación lineal solo captura la componente lineal de la relación; la correlación de rangos amplía el alcance a relaciones monótonas, pero sigue siendo ciega a dependencias que se manifiestan en la magnitud de los movimientos y no en su dirección. Determinar hasta qué punto estas medidas describen adecuadamente la asociación entre activos reales es, en sí mismo, un problema estadístico.

El presente trabajo aborda estas cuestiones en su etapa exploratoria, sobre una muestra construida deliberadamente heterogénea de veintiún instrumentos distribuidos en ocho estratos: acciones (Tesla, Google, Microsoft y Anglo American, esta última como aproximación al mercado del diamante), índices bursátiles (S&P 500, STOXX Europe 600 y Nasdaq-100), materias primas negociadas mediante futuros (petróleo WTI, gas natural, oro, plata y cobre), renta fija (bonos del Tesoro de Estados Unidos a más de veinte años), divisas (índice del dólar y euro), criptoactivos (bitcoin y ethereum), volatilidad implícita (índice VIX) y productos inversos (fondos que replican el movimiento diario contrario del S&P 500, del Nasdaq-100 y del oro). La heterogeneidad es intencional: si los patrones distribucionales y de dependencia que se buscan son propios de los mercados financieros y no de un sector concreto, deben aparecer en clases de activos con mecanismos de formación de precios, liquidez y exposición al ciclo económico distintos entre sí.

Los productos inversos cumplen un papel particular dentro de la muestra. Por construcción, su rendimiento diario es un múltiplo negativo del rendimiento de otro activo que también forma parte del estudio, de modo que su correlación con ese activo debe ser cercana a −1. Funcionan así como casos de control: permiten comprobar que las medidas de asociación empleadas recuperan una dependencia conocida de antemano y, al mismo tiempo, muestran qué ocurre en una cartera cuando se combinan activos con correlación fuertemente negativa.

La obtención de los datos planteó además un problema operativo con consecuencias estadísticas directas. Los veintiún activos no comparten calendario de negociación: los criptoactivos cotizan todos los días del año, los contratos de futuros operan en jornadas en que las bolsas de acciones permanecen cerradas y el índice europeo sigue su propio calendario de festivos. Tampoco comparten la hora de cierre: el STOXX Europe 600 cierra varias horas antes que la bolsa de Nueva York y los criptoactivos cierran a medianoche en tiempo universal. Alinear las series por posición en lugar de por fecha produciría un desfase creciente entre ellas y, con él, coeficientes de asociación carentes de sentido. Este detalle, que rara vez se menciona en los tratamientos introductorios, condiciona toda la sección de correlaciones del informe.

2. Pregunta de investigación

¿Qué estructura distribucional y de dependencia presentan los rendimientos diarios de un conjunto heterogéneo de activos financieros, y en qué medida las medidas de asociación basadas en rangos y en distancias describen esa dependencia con mayor fidelidad que los estadísticos clásicos apoyados en supuestos de normalidad y linealidad?

De esta pregunta se desprenden cuatro interrogantes operativos que orientan el análisis:

- ¿Presentan las distintas clases de activos, dentro de una misma ventana temporal, comportamientos distribucionales comparables en cuanto a dispersión, asimetría y presencia de valores atípicos?
- ¿Coinciden las conclusiones sobre la asociación entre activos cuando se emplea un coeficiente sensible únicamente a relaciones monótonas frente a uno capaz de detectar cualquier forma de dependencia?
- ¿Es estable en el tiempo la relación de cada activo con el índice de referencia, o los coeficientes agregados del periodo ocultan regímenes de comportamiento distintos?
- ¿Qué aportan a una cartera los activos con correlación fuertemente negativa, y a qué costo en términos de rendimiento?

3. Objetivo general

Caracterizar el comportamiento distribucional y la estructura de dependencia de los rendimientos logarítmicos diarios de una muestra heterogénea de veintiún activos financieros, mediante análisis exploratorio de datos y medidas de asociación robustas a la presencia de valores extremos, tomando el S&P 500 como referencia de mercado para evaluar el desempeño relativo de cada instrumento y el efecto de combinar activos con correlación negativa.

4. Objetivos específicos

- Diseñar y ejecutar un procedimiento propio de extracción de información bursátil que garantice trazabilidad y reproducibilidad, y delimitar una ventana muestral común que haga comparables entre sí a los veintiún activos seleccionados.

- Transformar las series de precios en rendimientos logarítmicos y diagnosticar la calidad de cada base en cuanto a tipos de variable, completitud y cardinalidad, identificando las limitaciones que cada activo impone al análisis posterior.
- Cuantificar la presencia de valores atípicos en precios, volumen y rendimientos mediante el criterio de rango intercuartílico, y estimar su efecto sobre las medidas de tendencia central con el fin de justificar el uso de estadísticos robustos.
- Describir la forma de las distribuciones de las variables originales y de los rendimientos a través de histogramas, contrastando el comportamiento de las distintas clases de activos.
- Medir la asociación entre los veintiún activos mediante el coeficiente de correlación de Spearman y la correlación de distancias, comparar ambos resultados para distinguir la dependencia monótona de la dependencia general, e identificar los pares con correlación fuertemente negativa.
- Evaluar el desempeño de cada activo frente al S&P 500 mediante regresión lineal sobre los rendimientos diarios, y examinar la estabilidad temporal de esa relación a través de correlaciones calculadas sobre ventanas móviles.
- Evaluar el resultado de combinar en una misma cartera activos con correlación fuertemente negativa, y contrastarlo con el de combinar activos con correlación cercana a cero, para distinguir entre cubrir y diversificar.

5. Justificación

El trabajo se articula sobre los contenidos de tres asignaturas, y conviene explicitar de qué manera interviene cada una.

Muestreo. La selección de los veintiún activos no obedece a un procedimiento aleatorio sino a un diseño intencional estratificado por clase de activo, con ocho estratos: acciones, índices bursátiles, materias primas, renta fija, divisas, criptoactivos, volatilidad implícita y productos inversos. Esta decisión tiene una consecuencia que debe declararse: los resultados describen la muestra observada y no admiten inferencia probabilística hacia el universo de instrumentos cotizados, puesto que no existe un marco muestral con probabilidades de selección conocidas. A cambio, el diseño garantiza la presencia de contrastes que un muestreo aleatorio simple difícilmente habría producido con veintiún unidades. Dentro de ese diseño, los productos inversos se incorporaron de forma deliberada como unidades de control, porque su relación con otros activos de la muestra se conoce de antemano. La delimitación de una ventana temporal común cumple una función análoga a la de un control experimental: al obligar a que todos los activos se observen sobre el mismo periodo, se evita que las diferencias entre ellos se confundan con diferencias entre regímenes de mercado.

Series de tiempo. El objeto de estudio es una sucesión ordenada de observaciones, no un conjunto intercambiable de ellas, y el orden es informativo. El paso del precio al rendimiento logarítmico es la primera operación propia de la materia: transforma una serie integrada en una aproximadamente estacionaria en media, estabiliza la varianza y permite que los rendimientos de periodos sucesivos se sumen en lugar de multiplicarse, propiedad que se aprovecha directamente al construir las trayectorias acumuladas del informe. El análisis mediante ventanas móviles pertenece igualmente a este ámbito: al recalcular un coeficiente sobre subperiodos consecutivos se abandona el supuesto de parámetros constantes y se abre la puerta a los modelos de dependencia temporal y volatilidad variable que constituyen la continuación natural de este trabajo. La alineación de las series por fecha, y el cálculo de los rendimientos después de alinear los precios, responde a la misma lógica: garantizar que cada observación de un activo corresponda al mismo intervalo de tiempo que la de los demás.

Estadística no paramétrica. El diagnóstico de valores atípicos realizado sobre cada base proporciona la justificación empírica del enfoque. Cuando una proporción apreciable de las observaciones cae fuera del rango intercuartílico, y cuando la exclusión de esos puntos desplaza la media de manera sustantiva, los procedimientos que dependen de supuestos distribucionales pierden fiabilidad. Las medidas basadas en rangos, como el coeficiente de Spearman, resuelven parte del problema: al sustituir los valores por su posición ordinal se vuelven invariantes ante transformaciones monótonas y acotan la influencia de los extremos. Pero conservan una limitación importante, y es que un valor nulo no implica independencia. La correlación de distancias supera esa restricción, ya que se anula si y solo si las variables son independientes y detecta por tanto relaciones no lineales que los coeficientes anteriores no registran. Emplear ambas medidas en paralelo no es redundante: su discrepancia es informativa, siempre que se tenga en cuenta que el estimador muestral de la correlación de distancias tiene un sesgo positivo, cuya magnitud se cuantifica en la sección de correlaciones.

La pertinencia práctica del enfoque es directa. Las decisiones de diversificación y las medidas de riesgo de una cartera descansan sobre estimaciones de correlación. Si esas estimaciones se obtienen con un coeficiente que no capta la forma real de la dependencia, o si se asume constante una relación que cambia a lo largo del tiempo, el riesgo efectivamente asumido difiere del riesgo calculado. La inclusión de activos con correlación fuertemente negativa permite además examinar una distinción que suele confundirse en la práctica: diversificar reduce el riesgo sin renunciar al rendimiento, mientras que cubrir reduce el riesgo a costa de anular también el rendimiento. Verificar estos supuestos sobre datos reales, antes de construir cualquier modelo predictivo, es el propósito de esta etapa del proyecto.

6. Origen y construcción de los datos

La información procede de Yahoo Finance y fue obtenida mediante un extractor propio desarrollado en Python (`Scrapper multiactivo excel.py`), que consulta el histórico diario completo de cada instrumento, calcula el rendimiento y el rango porcentual de cada jornada, y consolida el resultado en un único archivo de Excel con una hoja por activo. Un segundo procedimiento (`exportar_csv.py`) recorta las series a la ventana común de análisis y las exporta en formato CSV, que es el insumo directo de este informe. Los tickers consultados fueron los siguientes:

Activo	Ticker	Clase	Mercado
Tesla	TSLA	Acción	NASDAQ
Google (Alphabet)	GOOGL	Acción	NASDAQ
Microsoft	MSFT	Acción	NASDAQ
Diamante (proxy)	NGLOY	Acción	OTC
S&P 500	^GSPC	Índice	Estados Unidos
STOXX Europe 600	^STOXX	Índice	Europa
Nasdaq-100	QQQ	Índice (fondo cotizado)	NASDAQ
Petróleo WTI	CL=F	Futuro	NYMEX
Gas natural	NG=F	Futuro	NYMEX
Oro	GC=F	Futuro	COMEX
Plata	SI=F	Futuro	COMEX

Activo	Ticker	Clase	Mercado
Cobre	HG=F	Futuro	COMEX
Bonos del Tesoro a más de 20 años	TLT	Renta fija (fondo cotizado)	NASDAQ
Índice del dólar	DX-Y.NYB	Divisa	ICE
Euro	FXE	Divisa (fondo cotizado)	NYSE Arca
Bitcoin	BTC-USD	Criptoactivo	Negociación continua
Ethereum	ETH-USD	Criptoactivo	Negociación continua
VIX	^VIX	Volatilidad implícita	CBOE
Short S&P 500	SH	Inverso −1x	NYSE Arca
Short Nasdaq-100	PSQ	Inverso −1x	NYSE Arca
UltraShort oro	GLL	Inverso −2x	NYSE Arca

https://finance.yahoo.com/ (https://finance.yahoo.com/)

Sobre la construcción de esta base deben declararse las siguientes decisiones y sus implicaciones.

Ventana temporal. El extractor descarga el histórico completo disponible, que abarca desde 1927 en el caso del S&P 500 hasta 2017 en el de ethereum. Comparar series con veinticuatro mil y con tres mil observaciones carece de sentido estadístico, por lo que todas se recortaron a una ventana común de cinco años, del 4 de septiembre de 2021 al 4 de septiembre de 2026. La fecha final queda fija en el procedimiento de exportación, de modo que volver a ejecutar el extractor no altera el periodo analizado. La ventana deja aproximadamente 1.255 observaciones diarias por activo, salvo en los criptoactivos, que suman 1.827 porque cotizan también los fines de semana.

Alineación por fecha y cálculo de rendimientos. Como los calendarios de negociación difieren entre mercados, la consolidación de las series se hace cruzando por fecha y no por posición, y se conservan solo las jornadas en que los veintiún activos tienen precio. Los rendimientos del análisis de dependencia se calculan después de esa alineación, sobre los precios de las jornadas comunes. De esta forma el rendimiento de cada activo cubre exactamente el mismo intervalo que el de los demás: el movimiento de un fin de semana del bitcoin, o el de un día en que solo cotizaron los futuros, queda incorporado en el rendimiento de la siguiente jornada común en lugar de perderse.

Horas de cierre. Aun con las fechas alineadas, los activos no cierran a la misma hora. El STOXX Europe 600 cierra varias horas antes que la bolsa de Nueva York y los criptoactivos cierran a medianoche en tiempo universal. Parte de lo que ocurre en la tarde estadounidense se refleja al día siguiente en el índice europeo, lo que atenúa su correlación contemporánea con los activos de Estados Unidos. La sección de correlaciones cuantifica este efecto.

Divisas. Para el euro se descartó el tipo de cambio EUR/USD que publica Yahoo Finance, porque su serie diaria está fechada con un día de retraso respecto de los mercados estadounidenses: su correlación de Spearman con el índice del dólar resultaba prácticamente nula en la misma fecha (−0,07) y de −0,87 al desplazarla un día. En su lugar se utiliza FXE, un fondo cotizado en Nueva York que replica el euro frente al dólar y cierra a la misma hora que las acciones. Ni el índice del dólar ni el VIX registran volumen de negociación en la fuente, por lo que su columna de volumen vale cero en todas las fechas.

Precio empleado. El rendimiento se calcula sobre el precio de cierre y no sobre el cierre ajustado. Los dividendos y los intereses distribuidos quedan fuera, de modo que las rentabilidades acumuladas corresponden a rentabilidad por precio y no a rentabilidad total. La diferencia es despreciable en los futuros, en las divisas y en los criptoactivos, pero subestima el rendimiento de los activos que reparten dividendos, como Microsoft y Anglo American, y sobre todo el del fondo de bonos del Tesoro, que distribuye cada mes los intereses de su cartera. El cierre ajustado tiene además la desventaja de que la fuente lo recalcula cada vez que se paga un nuevo dividendo.

Futuros continuos. Los precios del petróleo, el gas natural, el oro, la plata y el cobre corresponden a series continuas que encadenan contratos sucesivos. En el cambio de un contrato al siguiente pueden aparecer saltos que no son movimientos del mercado. La fuente puede además reconstruir la serie completa: entre la primera descarga de este proyecto, el 6 de septiembre de 2026, y la actual, del 21 de septiembre, Yahoo Finance modificó la serie del oro. Sus cierres cambiaron en una mediana de 0,37 % y hasta un máximo de 1,96 %, y su volumen mediano pasó de 344 a cerca de 181.000 contratos, lo que sugiere que la serie pasó a construirse con el contrato más negociado. El informe utiliza la versión vigente.

Productos inversos y VIX. SH y PSQ buscan el rendimiento diario opuesto del S&P 500 y del Nasdaq-100, y GLL el doble del rendimiento diario opuesto del oro. Como el objetivo se reajusta cada día, en horizontes largos su rendimiento acumulado no es el opuesto del rendimiento del activo de referencia, y se aleja de él tanto más cuanto mayor es la volatilidad del periodo. El VIX, por su parte, es un índice de volatilidad implícita que no se puede comprar directamente, de modo que su rendimiento es la variación de un indicador y no el resultado de una inversión.

Aproximación del diamante. El diamante no cotiza como contrato de futuros en ningún mercado organizado. Su precio se establece mediante catálogos de referencia elaborados por De Beers y por el índice Rapaport, y no mediante un mecanismo continuo de oferta y demanda, por lo que no existe una serie diaria de precios comparable a la de los demás activos. Se emplea en su lugar la acción de Anglo American (NGLOY), empresa propietaria de De Beers. Debe interpretarse, en consecuencia, como una acción del sector minero sujeta al ciclo bursátil y no como el precio del diamante, y los resultados de este instrumento se leen con esa salvedad a lo largo de todo el informe.

7. EDA inicial

Librerías

```
library(tidyverse)
library(pander)
library(ggplot2)
library(dlookr)
library(energy)
library(ggrepel)
```

analisis de datos

Para cada uno de los veintiún activos se calcula la rentabilidad del periodo como el logaritmo del cociente entre el cierre actual y el cierre anterior:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

Sobre esta variable, y sobre las variables originales de precio y volumen, se ejecuta el diagnóstico de la base (`diagnose`), el diagnóstico de valores atípicos (`diagnose_outlier`) y los histogramas correspondientes.

Tesla (TSLA)

```
tesla <- read.csv("datos_csv/TSLA.csv")
pander::pander(head(tesla,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	246.7	253.4	246.4	251	251	60119400
2021-09-08	253.9	254.8	246.9	251.3	251.3	56379000
2021-09-09	251.1	254	250.5	251.6	251.6	42233100
2021-09-10	253.2	254.2	244.8	245.4	245.4	45552600
2021-09-13	246.7	248.3	236.3	247.7	247.7	68857500
2021-09-14	247.5	251.5	245.5	248.2	248.2	55574700
2021-09-15	248.3	252.3	246.1	251.9	251.9	46073100
2021-09-16	250.9	253	249.2	252.3	252.3	41770200
2021-09-17	252.4	253.7	250	253.2	253.2	84612600
2021-09-20	244.9	247.3	239.5	243.4	243.4	74273100

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
tesla <- tesla |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
tesla <- tesla |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(tesla))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count	unique_rate
Date	character	0	0	1255	1
Open	numeric	0	0	1215	0.9681
High	numeric	0	0	1223	0.9745
Low	numeric	0	0	1230	0.9801
Close	numeric	0	0	1233	0.9825
Adj.Close	numeric	0	0	1233	0.9825
Volume	integer	0	0	1254	0.9992
rentabilidad	numeric	1	0.07968	1255	1
rent_porcent	numeric	1	0.07968	1248	0.9944

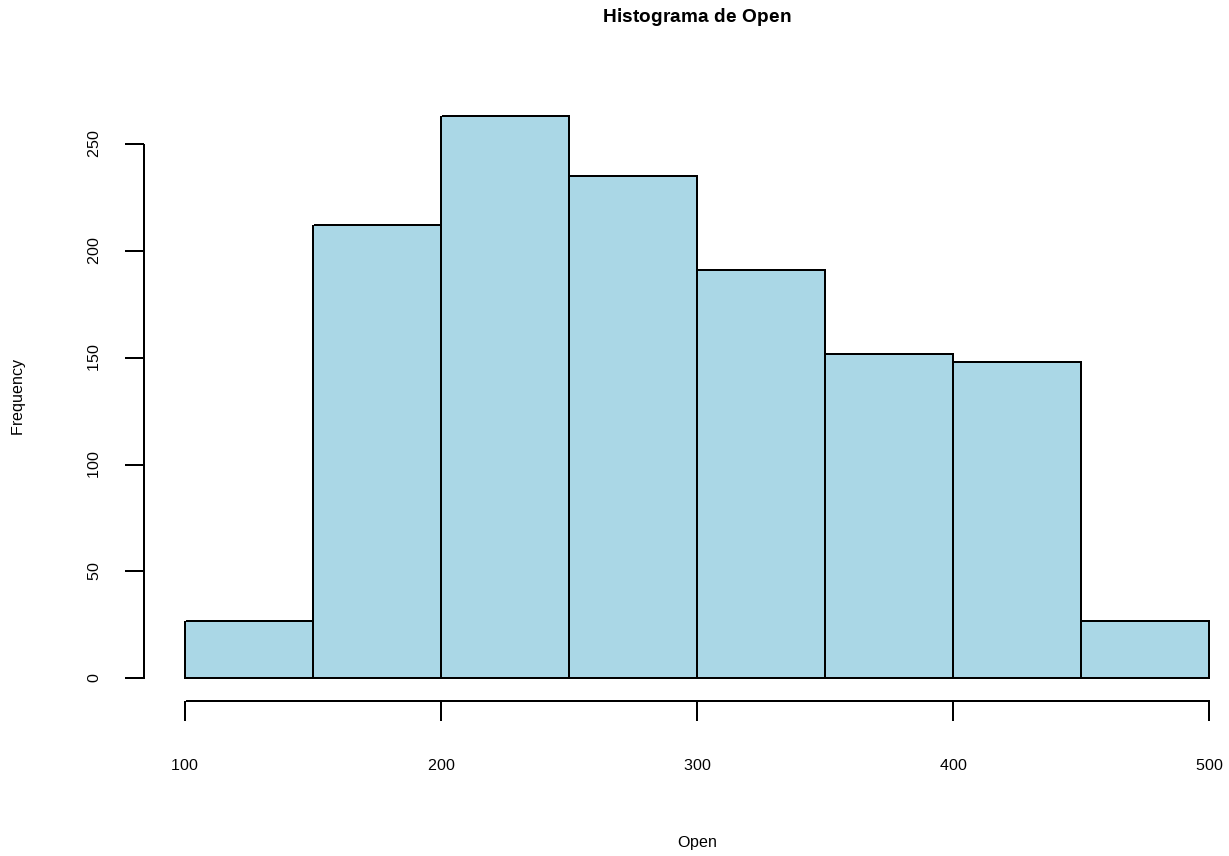
```
pander(diagnose_outlier(tesla))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	0	0	NA	287.1
High	0	0	NA	293.3
Low	0	0	NA	280.7
Close	0	0	NA	287
Adj.Close	0	0	NA	287
Volume	38	3.028	216160618	95365649

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean	without_mean
rentabilidad	45	3.586	-0.0225	0.0002745	287.1
rent_porcent	45	3.586	-2.25	0.02744	293.3
					280.7
					287
					287
					91593908
					0.001122
					0.1122

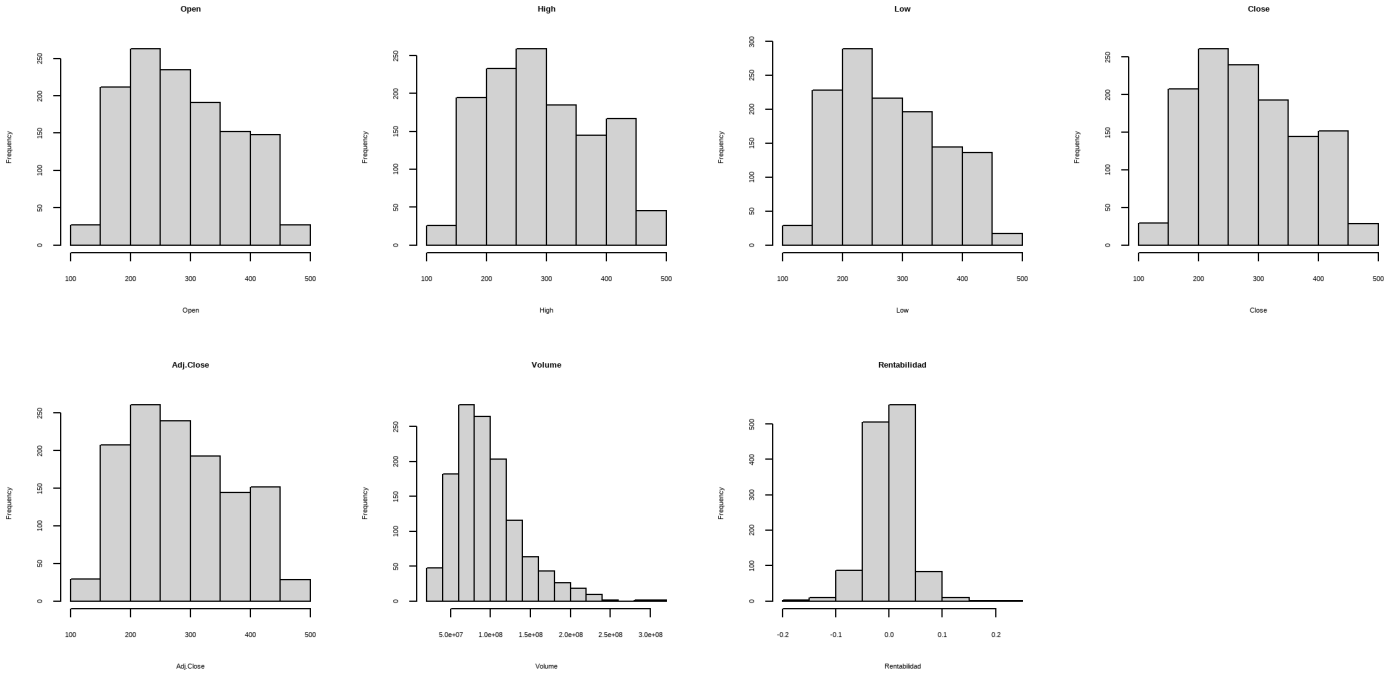
```
hist(tesla$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(tesla$Open, main = "Open", xlab = "Open")
hist(tesla$High, main = "High", xlab = "High")
hist(tesla$Low, main = "Low", xlab = "Low")
hist(tesla$Close, main = "Close", xlab = "Close")
hist(tesla$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(tesla$Volume, main = "Volume", xlab = "Volume")
hist(tesla$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Google - Alphabet (GOOGL)

```
google <- read.csv("datos_csv/GOOGL.csv")
pander::pander(head(google,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	143.8	144.6	143.6	144.3	142.9	20124000
2021-09-08	144.1	144.4	143	143.7	142.3	18344000
2021-09-09	143.8	144.3	143.2	143.5	142.2	15314000
2021-09-10	144.2	144.7	140.7	140.9	139.5	36840000
2021-09-13	141.9	142.9	141.2	142.3	141	22094000
2021-09-14	143	143.4	141.8	142.5	141.2	19674000
2021-09-15	142.8	144.5	141.3	144.4	143.1	27408000
2021-09-16	144	144.3	142.4	143.6	142.3	26190000
2021-09-17	143	143.4	140.5	140.8	139.5	53384000
2021-09-20	138.2	139	136.3	138.7	137.4	46518000

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
google <- google |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
google <- google |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(google))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1255
Open	numeric	0	0	1212
High	numeric	0	0	1209
Low	numeric	0	0	1218
Close	numeric	0	0	1227
Adj.Close	numeric	0	0	1237
Volume	integer	0	0	1253
rentabilidad	numeric	1	0.07968	1254
rent_porcent	numeric	1	0.07968	1245

unique_rate
1
0.9657
0.9633
0.9705
0.9777
0.9857
0.9984
0.9992
0.992

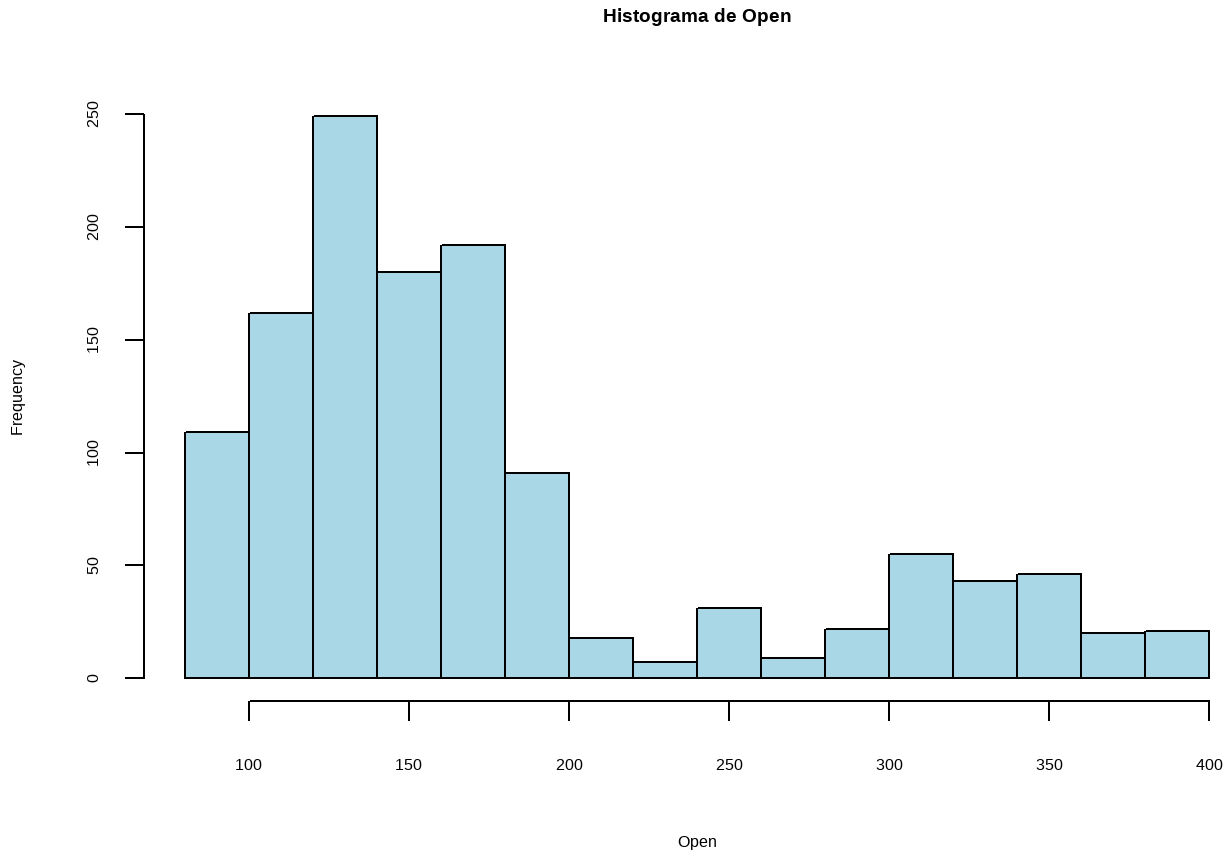
```
pander(diagnose_outlier(google))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	196	15.62	336.8	176.9
High	198	15.78	340.6	179
Low	196	15.62	332.6	174.8
Close	194	15.46	337.6	177
Adj.Close	196	15.62	336.7	176
Volume	69	5.498	72861812	32417203
rentabilidad	49	3.904	0.002557	0.0006799
rent_porcent	49	3.904	0.2557	0.06799

without_mean
147.3
148.8
145.6
147.6
146.2
30064186
0.0006036
0.06036

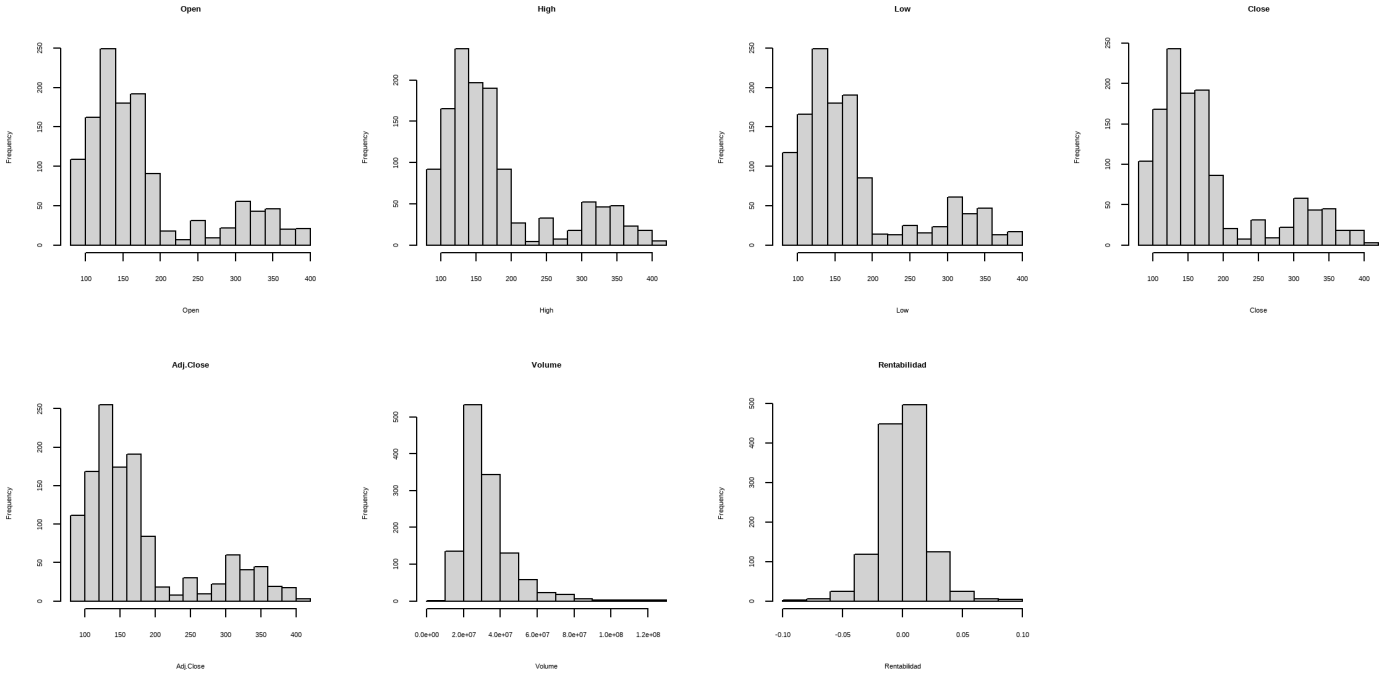
```
hist(google$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(google$Open, main = "Open", xlab = "Open")
hist(google$High, main = "High", xlab = "High")
hist(google$Low, main = "Low", xlab = "Low")
hist(google$Close, main = "Close", xlab = "Close")
hist(google$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(google$Volume, main = "Volume", xlab = "Volume")
hist(google$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Microsoft (MSFT)

```
microsoft <- read.csv("datos_csv/MSFT.csv")
pander::pander(head(microsoft,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	301	301.1	298.2	300.2	288.1	17180400
2021-09-08	299.8	300.6	297.5	300.2	288.1	15046800
2021-09-09	300.8	302.1	297	297.2	285.3	19927000
2021-09-10	298.4	299.9	295.4	295.7	283.8	19633400
2021-09-13	297.5	298.5	294.1	297	285	23652900
2021-09-14	299.6	301.4	298.1	299.8	287.7	21853400
2021-09-15	303.3	305.3	301.8	304.8	292.5	28356300
2021-09-16	303.8	305.3	300.8	305.2	292.9	19550800
2021-09-17	304.2	304.5	299.5	299.9	287.8	41372500
2021-09-20	296.3	298.7	289.5	294.3	282.4	38278700

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
microsoft <- microsoft |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
microsoft <- microsoft |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(microsoft))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1255
Open	numeric	0	0	1220
High	numeric	0	0	1215
Low	numeric	0	0	1214
Close	numeric	0	0	1228
Adj.Close	numeric	0	0	1247
Volume	integer	0	0	1253
rentabilidad	numeric	1	0.07968	1255
rent_porcent	numeric	1	0.07968	1235

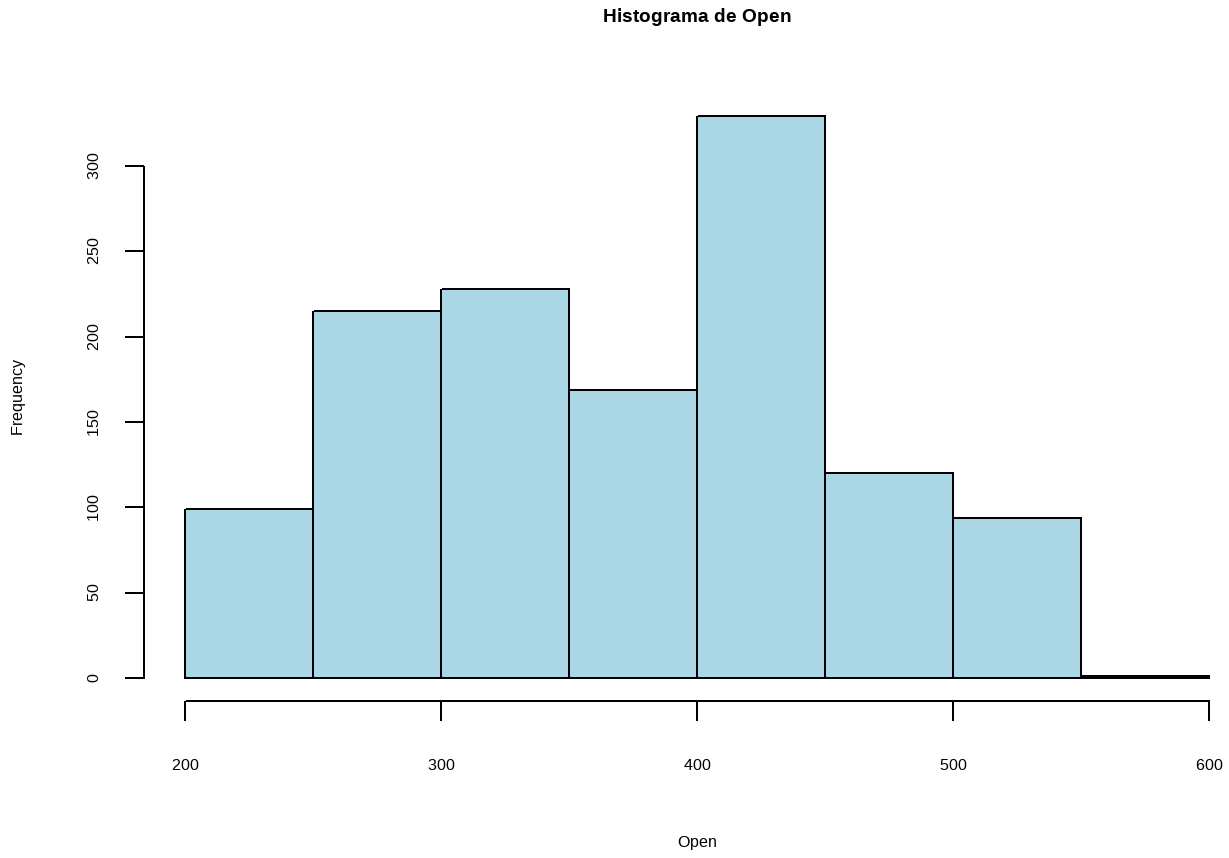
unique_rate
1
0.9721
0.9681
0.9673
0.9785
0.9936
0.9984
1
0.9841

```
pander(diagnose_outlier(microsoft))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean	without_mean
Open	0	0	NA	371.1	371.1
High	0	0	NA	374.7	374.7
Low	0	0	NA	367.4	367.4
Close	0	0	NA	371.2	371.2
Adj.Close	0	0	NA	364.4	364.4
Volume	56	4.462	64841489	26892713	25120293
rentabilidad	59	4.701	-0.003202	0.0004064	0.0005846
rent_porcent	59	4.701	-0.3202	0.04064	0.05846

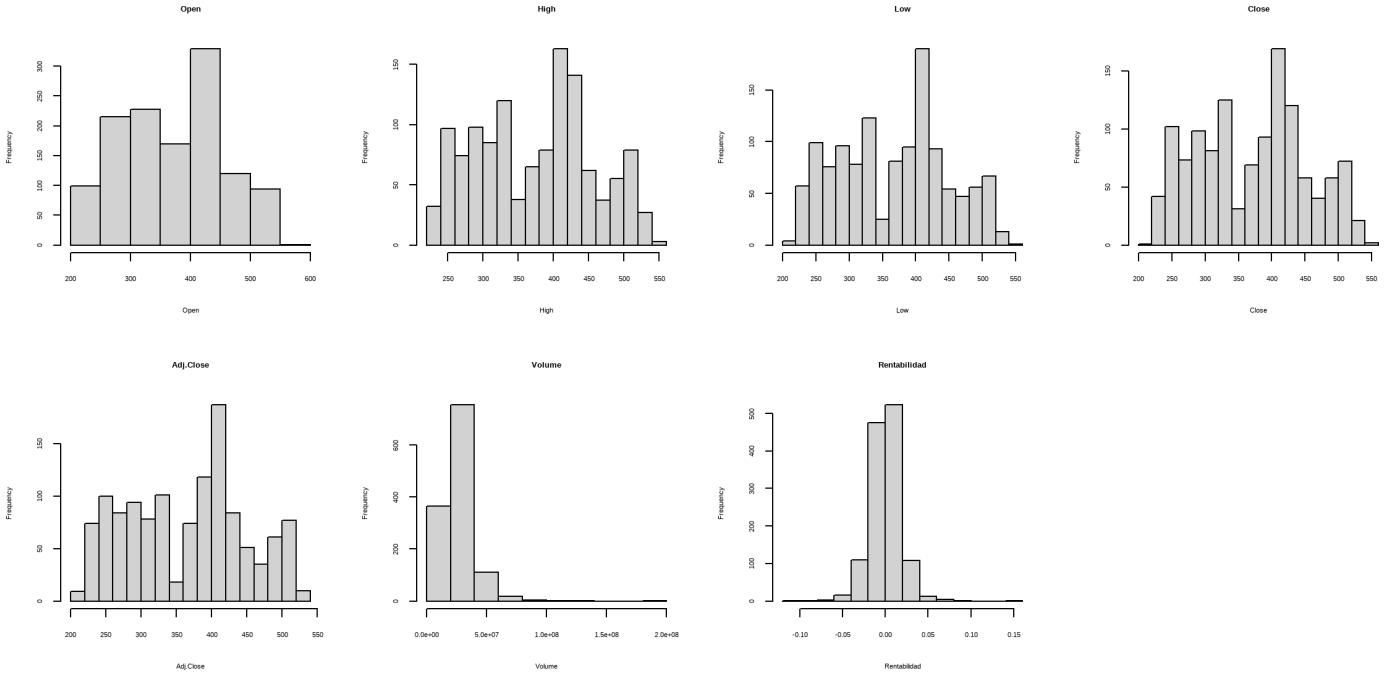
```
hist(microsoft$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(microsoft$Open, main = "Open", xlab = "Open")
hist(microsoft$High, main = "High", xlab = "High")
hist(microsoft$Low, main = "Low", xlab = "Low")
hist(microsoft$Close, main = "Close", xlab = "Close")
hist(microsoft$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(microsoft$Volume, main = "Volume", xlab = "Volume")
hist(microsoft$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Petróleo WTI (CL=F)

```
petroleo <- read.csv("datos_csv/PETROLEO.csv")
pander::pander(head(petroleo,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	69.11	69.48	67.64	68.35	68.35	481704
2021-09-08	68.37	69.75	68.31	69.3	69.3	389325
2021-09-09	69.36	69.89	67.56	68.14	68.14	556451
2021-09-10	67.97	69.96	67.68	69.72	69.72	411079
2021-09-13	69.74	70.97	69.51	70.45	70.45	390939
2021-09-14	70.64	71.22	69.98	70.46	70.46	414231
2021-09-15	70.76	73.14	70.65	72.61	72.61	418665
2021-09-16	72.65	72.99	71.53	72.61	72.61	298412
2021-09-17	72.62	72.72	71.21	71.97	71.97	119933
2021-09-20	71.92	72.08	69.86	70.29	70.29	75837

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
petroleo <- petroleo |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
petroleo <- petroleo |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(petroleo))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1257
Open	numeric	0	0	1090
High	numeric	0	0	1078
Low	numeric	0	0	1090
Close	numeric	0	0	1083
Adj.Close	numeric	0	0	1083
Volume	integer	0	0	1247
rentabilidad	numeric	1	0.07955	1251
rent_porcent	numeric	1	0.07955	1241

unique_rate
1
0.8671
0.8576
0.8671
0.8616
0.8616
0.992
0.9952
0.9873

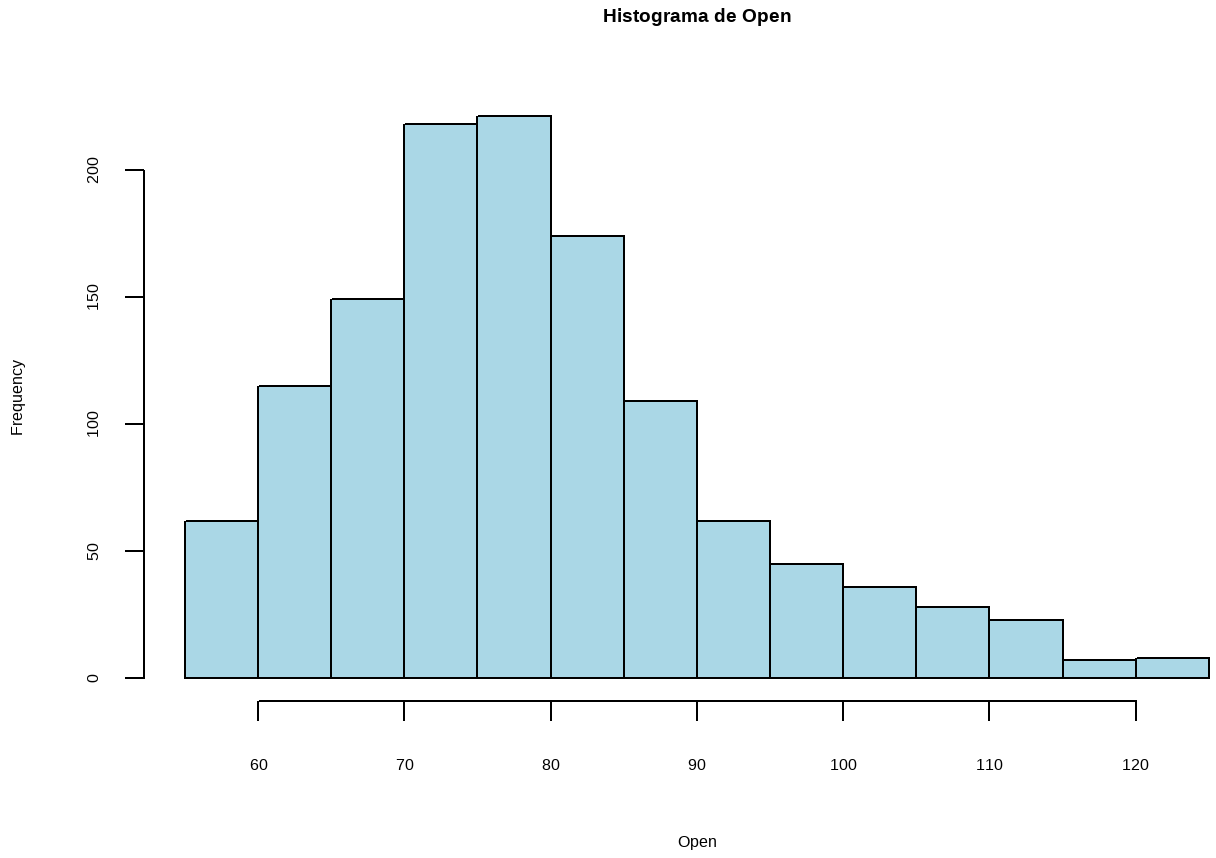
```
pander(diagnose_outlier(petroleo))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	47	3.739	114	78.61
High	56	4.455	115.9	80.07
Low	46	3.66	110.8	77.03
Close	45	3.58	114	78.54
Adj.Close	45	3.58	114	78.54
Volume	79	6.285	458149	313542
rentabilidad	46	3.66	-0.02161	0.0002321
rent_porcent	46	3.66	-2.161	0.02321

without_mean
77.23
78.4
75.75
77.23
77.23
303844
0.001062
0.1062

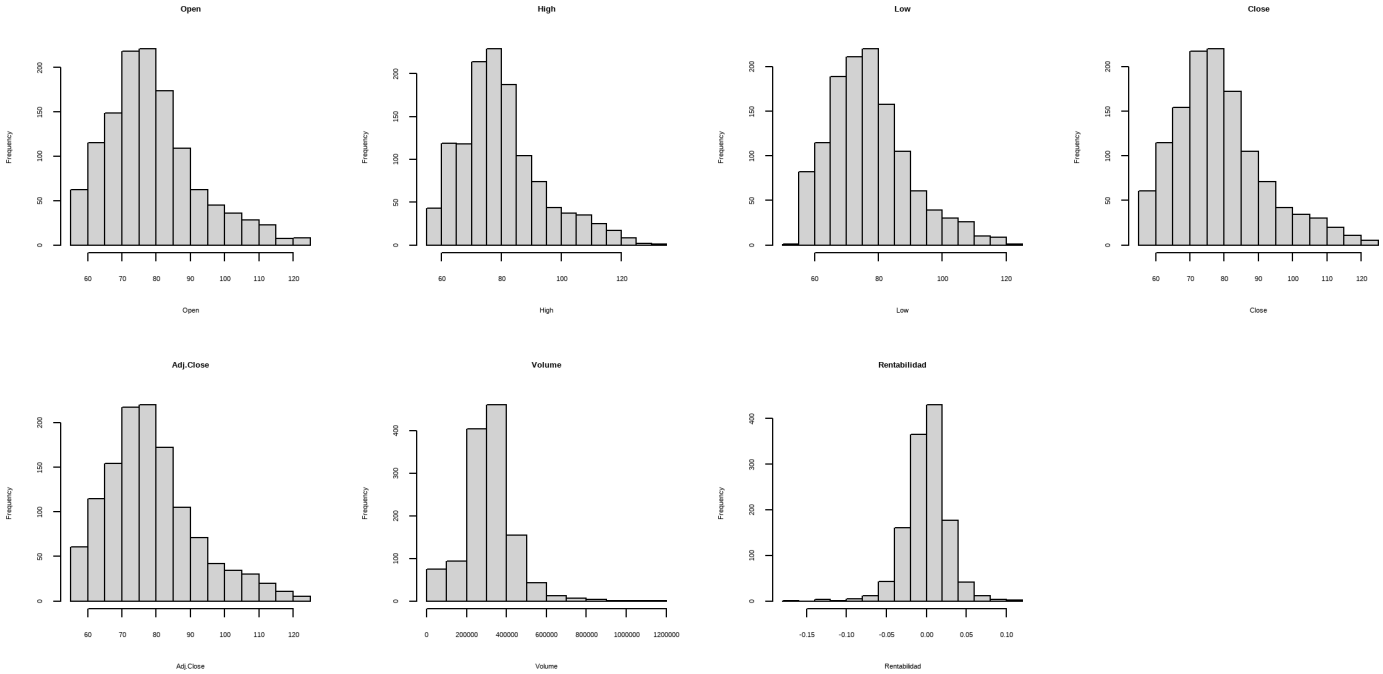
```
hist(petroleo$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(petroleo$Open, main = "Open", xlab = "Open")
hist(petroleo$High, main = "High", xlab = "High")
hist(petroleo$Low, main = "Low", xlab = "Low")
hist(petroleo$Close, main = "Close", xlab = "Close")
hist(petroleo$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(petroleo$Volume, main = "Volume", xlab = "Volume")
hist(petroleo$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Gas natural (NG=F)

```
gas <- read.csv("datos_csv/GASNATURAL.csv")
pander::pander(head(gas,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	4.71	4.774	4.557	4.568	4.568	163663
2021-09-08	4.598	5.01	4.585	4.914	4.914	244742
2021-09-09	4.917	5.047	4.82	5.031	5.031	234848
2021-09-10	5.002	5.058	4.913	4.938	4.938	151036
2021-09-13	4.945	5.289	4.879	5.231	5.231	201770
2021-09-14	5.199	5.369	5.171	5.26	5.26	200943
2021-09-15	5.28	5.65	5.266	5.46	5.46	279117
2021-09-16	5.41	5.6	5.228	5.335	5.335	221139
2021-09-17	5.27	5.394	5.044	5.105	5.105	164579
2021-09-20	5.015	5.172	4.905	4.985	4.985	156870

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
gas <- gas |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
gas <- gas |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(gas))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1258
Open	numeric	0	0	1088
High	numeric	0	0	1078
Low	numeric	0	0	1070
Close	numeric	0	0	1083
Adj.Close	numeric	0	0	1083
Volume	integer	0	0	1246
rentabilidad	numeric	1	0.07949	1256
rent_porcent	numeric	1	0.07949	1250

unique_rate
1
0.8649
0.8569
0.8506
0.8609
0.8609
0.9905
0.9984
0.9936

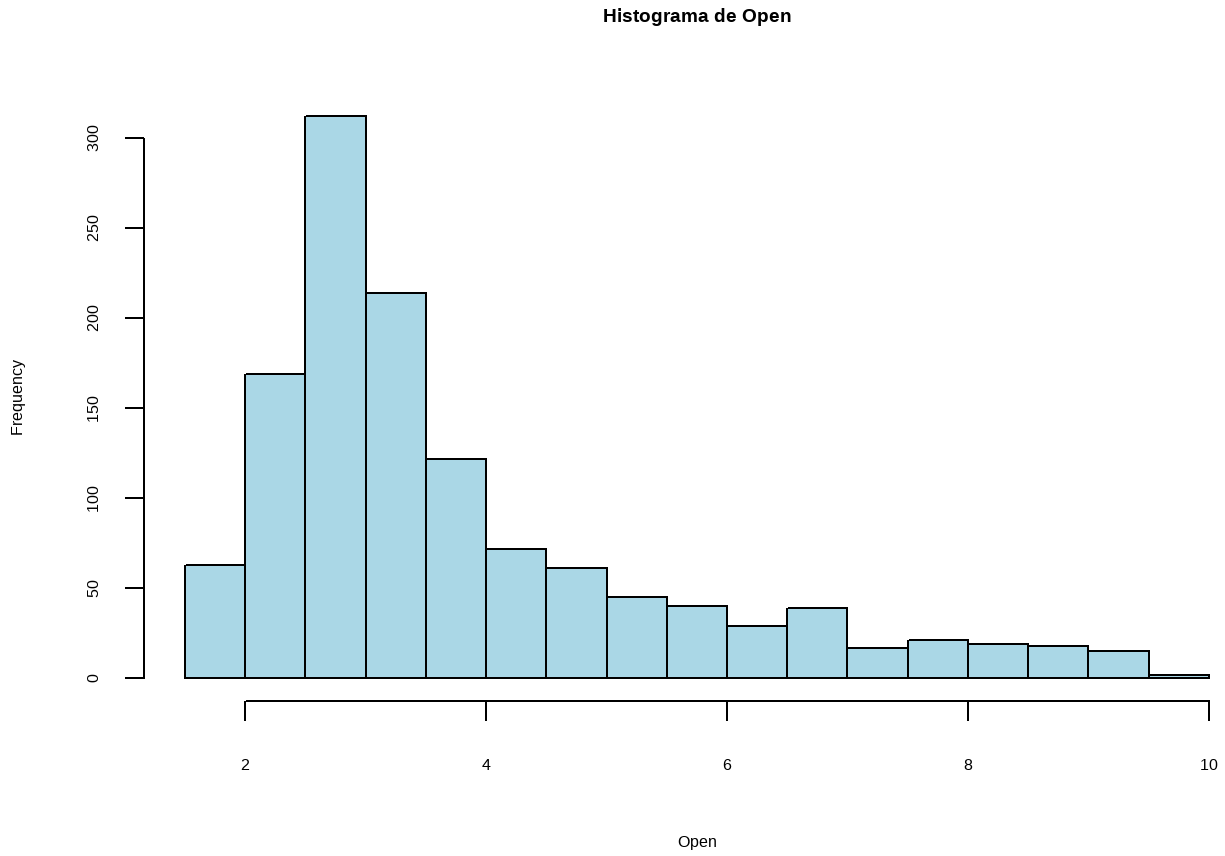
```
pander(diagnose_outlier(gas))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	89	7.075	8.292	3.79
High	90	7.154	8.59	3.918
Low	89	7.075	7.976	3.663
Close	87	6.916	8.314	3.785
Adj.Close	87	6.916	8.314	3.785
Volume	30	2.385	262184	146075
rentabilidad	39	3.1	-0.02861	-0.0003412
rent_porcent	39	3.1	-2.861	-0.03411

without_mean
3.448
3.558
3.335
3.449
3.449
143239
0.0005641
0.05641

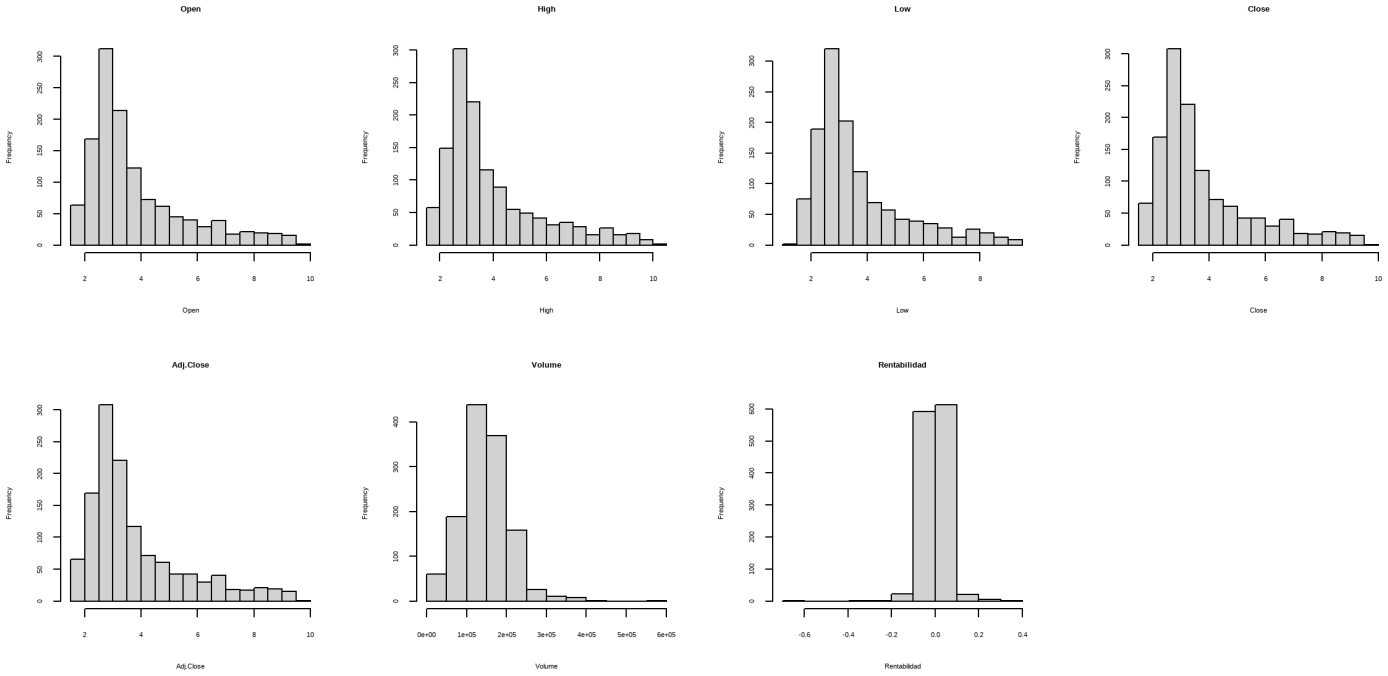
```
hist(gas$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(gas$Open, main = "Open", xlab = "Open")
hist(gas$High, main = "High", xlab = "High")
hist(gas$Low, main = "Low", xlab = "Low")
hist(gas$Close, main = "Close", xlab = "Close")
hist(gas$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(gas$Volume, main = "Volume", xlab = "Volume")
hist(gas$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Oro (GC=F)

```
oro <- read.csv("datos_csv/ORO.csv")
pander::pander(head(oro,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	1834	1834	1794	1798	1798	252475
2021-09-08	1796	1804	1783	1794	1794	161258
2021-09-09	1791	1803	1785	1800	1800	154126
2021-09-10	1796	1806	1788	1792	1792	136246
2021-09-13	1790	1800	1784	1794	1794	114310
2021-09-14	1795	1811	1781	1807	1807	197954
2021-09-15	1807	1808	1792	1795	1795	139297
2021-09-16	1796	1797	1746	1757	1757	255267
2021-09-17	1755	1768	1747	1751	1751	183254
2021-09-20	1754	1768	1742	1764	1764	152451

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
oro <- oro |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
oro <- oro |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(oro))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1258
Open	numeric	0	0	1189
High	numeric	0	0	1207
Low	numeric	0	0	1196
Close	numeric	0	0	1196
Adj.Close	numeric	0	0	1196
Volume	integer	0	0	1245
rentabilidad	numeric	1	0.07949	1253
rent_porcent	numeric	1	0.07949	1231

unique_rate
1
0.9452
0.9595
0.9507
0.9507
0.9507
0.9897
0.996
0.9785

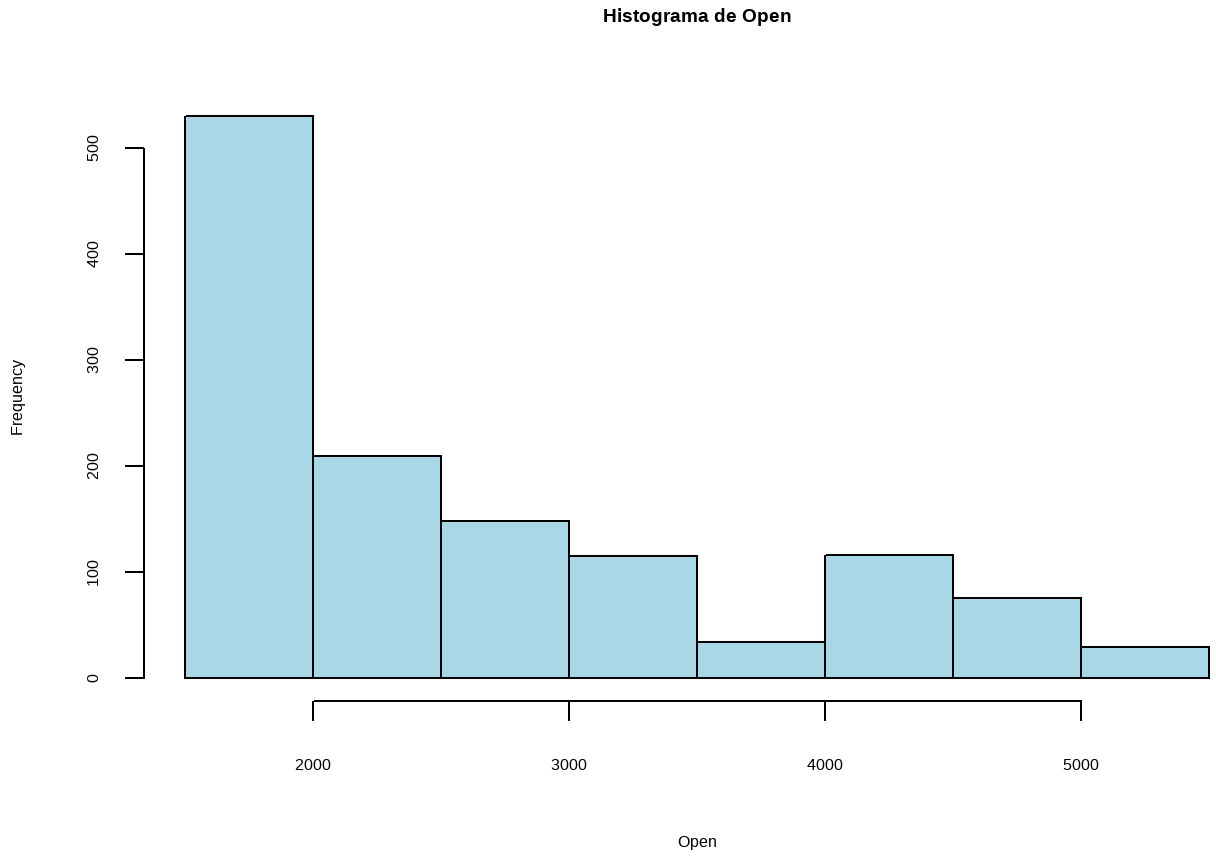
```
pander(diagnose_outlier(oro))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	0	0	NA	2662
High	1	0.07949	5586	2687
Low	0	0	NA	2637
Close	0	0	NA	2663
Adj.Close	0	0	NA	2663
Volume	58	4.61	265313	190655
rentabilidad	77	6.121	-0.005168	0.0007255
rent_porcent	77	6.121	-0.5168	0.07255

without_mean
2662
2685
2637
2663
2663
187046
0.00111
0.111

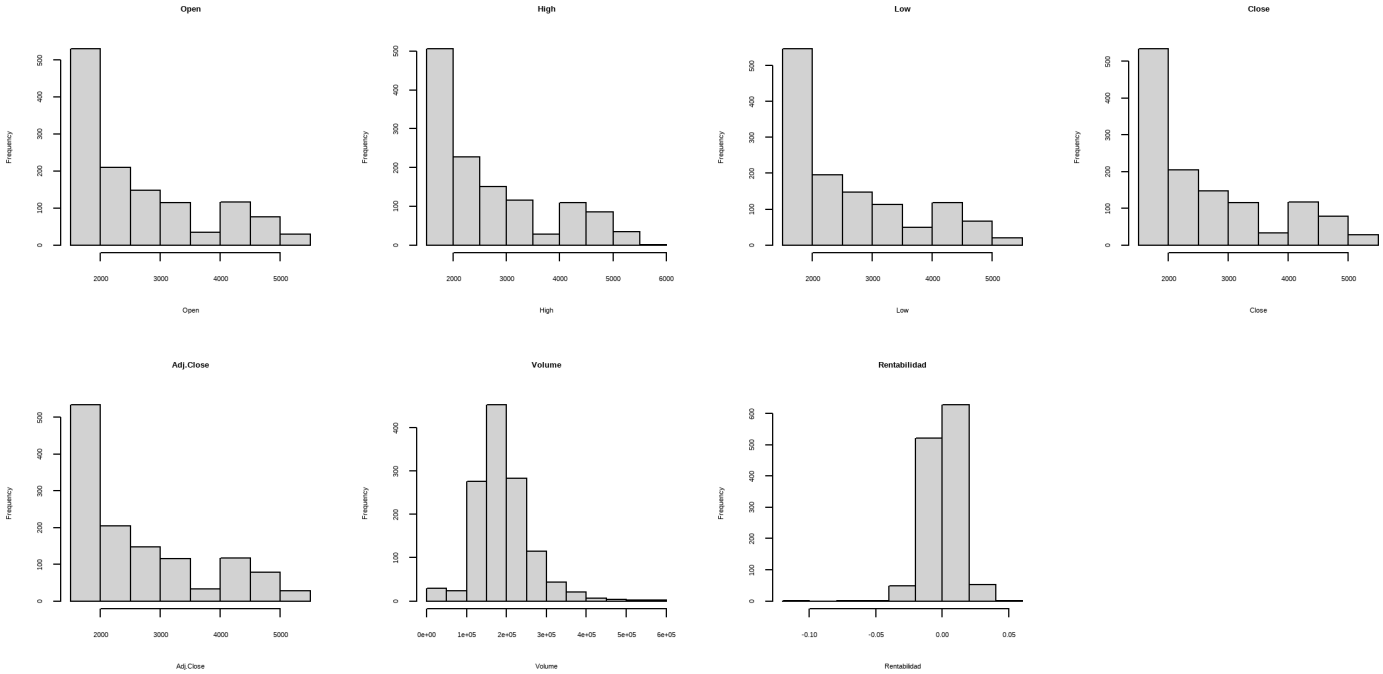
```
hist(oro$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(oro$Open, main = "Open", xlab = "Open")
hist(oro$High, main = "High", xlab = "High")
hist(oro$Low, main = "Low", xlab = "Low")
hist(oro$Close, main = "Close", xlab = "Close")
hist(oro$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(oro$Volume, main = "Volume", xlab = "Volume")
hist(oro$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Diamante - proxy Anglo American (NGLOY)

```
diamante <- read.csv("datos_csv/DIAMANTE.csv")
pander::pander(head(diamante,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	21.22	21.3	20.86	20.88	17.7	101802
2021-09-08	20.77	20.92	20.51	20.56	17.43	141375
2021-09-09	20.48	20.63	20.42	20.52	17.4	139530
2021-09-10	20.93	21.09	20.72	20.73	17.57	87860
2021-09-13	20.99	21.07	20.78	20.9	17.72	116053
2021-09-14	20.88	20.88	20.23	20.33	17.23	140760
2021-09-15	20.09	20.21	20.04	20.17	17.1	415514
2021-09-16	19.1	19.2	18.97	19.17	16.25	210166
2021-09-17	18.14	18.14	17.43	17.62	14.93	211089
2021-09-20	16.4	16.81	16.34	16.8	14.24	717537

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
diamante <- diamante |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
diamante <- diamante |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(diamante))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1255
Open	numeric	0	0	955
High	numeric	0	0	984
Low	numeric	0	0	976
Close	numeric	0	0	945
Adj.Close	numeric	0	0	1114
Volume	integer	0	0	1155
rentabilidad	numeric	1	0.07968	1243
rent_porcent	numeric	1	0.07968	1237

unique_rate
1
0.761
0.7841
0.7777
0.753
0.8876
0.9203
0.9904
0.9857

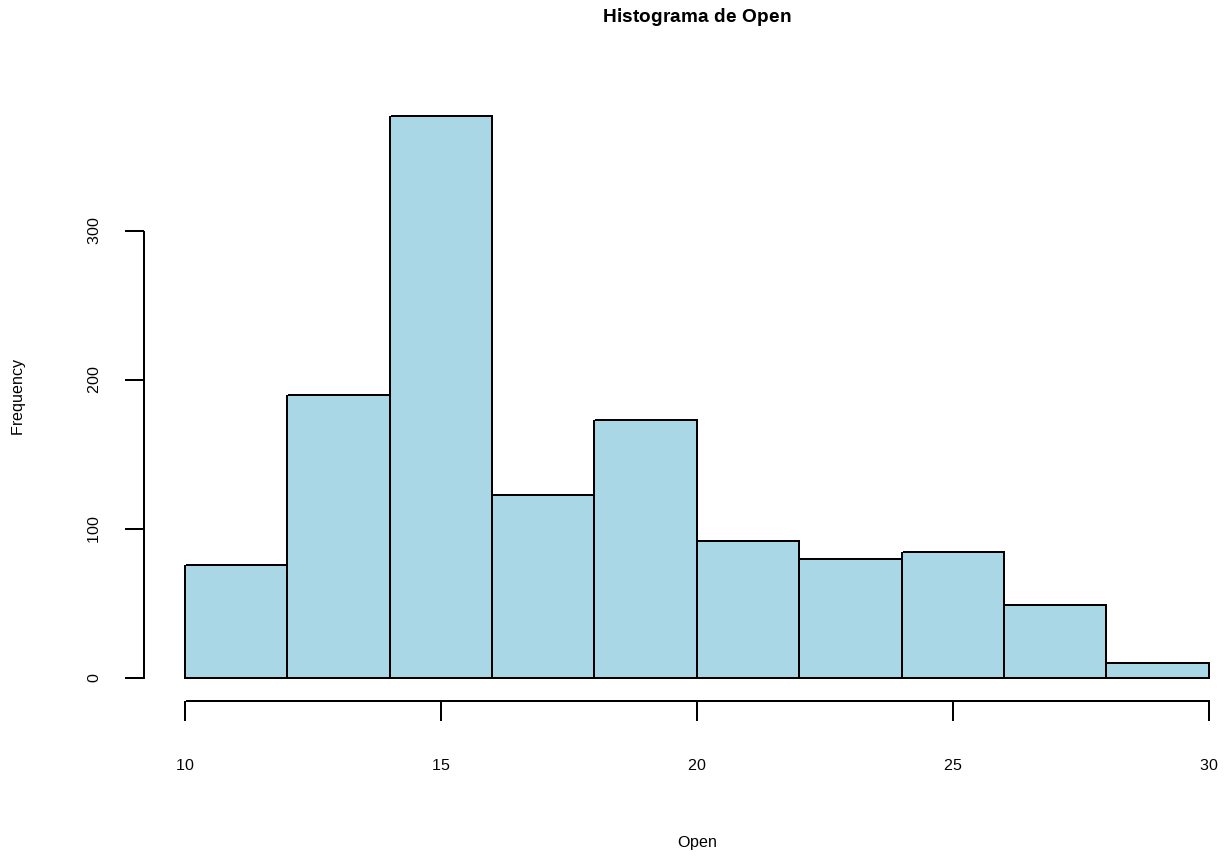
```
pander(diagnose_outlier(diamante))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	4	0.3187	28.99	17.42
High	2	0.1594	29.25	17.61
Low	2	0.1594	28.69	17.23
Close	4	0.3187	28.89	17.43
Adj.Close	38	3.028	27.51	16.44
Volume	86	6.853	1603129	379106
rentabilidad	41	3.267	0.01452	0.0002443
rent_porcent	41	3.267	1.452	0.02443

without_mean
17.38
17.59
17.21
17.39
16.09
289058
-0.0002382
-0.02382

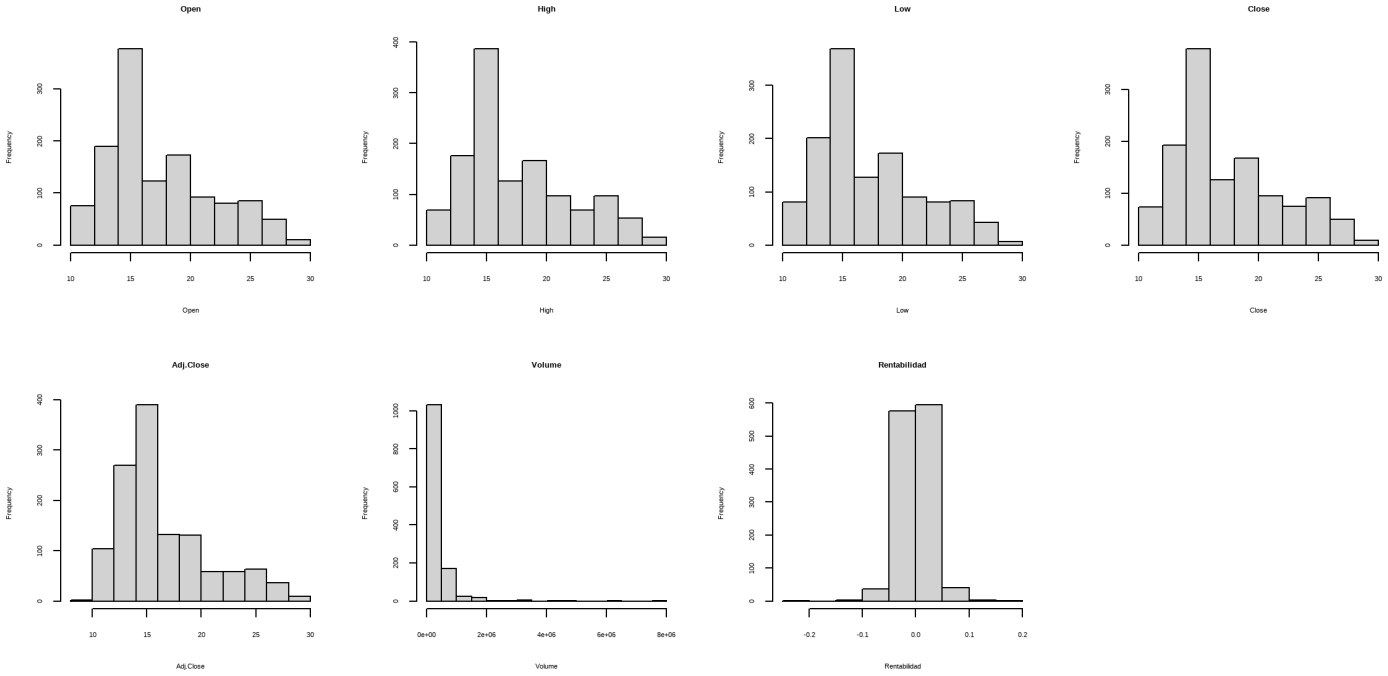
```
hist(diamante$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(diamante$Open, main = "Open", xlab = "Open")
hist(diamante$High, main = "High", xlab = "High")
hist(diamante$Low, main = "Low", xlab = "Low")
hist(diamante$Close, main = "Close", xlab = "Close")
hist(diamante$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(diamante$Volume, main = "Volume", xlab = "Volume")
hist(diamante$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



S&P 500 (^GSPC)

```
sp500 <- read.csv("datos_csv/SP500.csv")
pander::pander(head(sp500,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	4535	4535	4513	4520	4520	3.823e+09
2021-09-08	4518	4522	4494	4514	4514	3.751e+09
2021-09-09	4513	4530	4492	4493	4493	3.735e+09
2021-09-10	4507	4520	4458	4459	4459	3.623e+09
2021-09-13	4475	4493	4446	4469	4469	3.914e+09
2021-09-14	4479	4486	4435	4443	4443	3.67e+09
2021-09-15	4447	4487	4438	4481	4481	4.032e+09
2021-09-16	4477	4486	4444	4474	4474	3.985e+09
2021-09-17	4470	4472	4428	4433	4433	7.29e+09
2021-09-20	4403	4403	4306	4358	4358	4.898e+09

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
sp500 <- sp500 |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
sp500 <- sp500 |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(sp500))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1255
Open	numeric	0	0	1254
High	numeric	0	0	1251
Low	numeric	0	0	1250
Close	numeric	0	0	1254
Adj.Close	numeric	0	0	1254
Volume	numeric	0	0	1255
rentabilidad	numeric	1	0.07968	1255
rent_porcent	numeric	1	0.07968	1235

unique_rate
1
0.9992
0.9968
0.996
0.9992
0.9992
1
1
0.9841

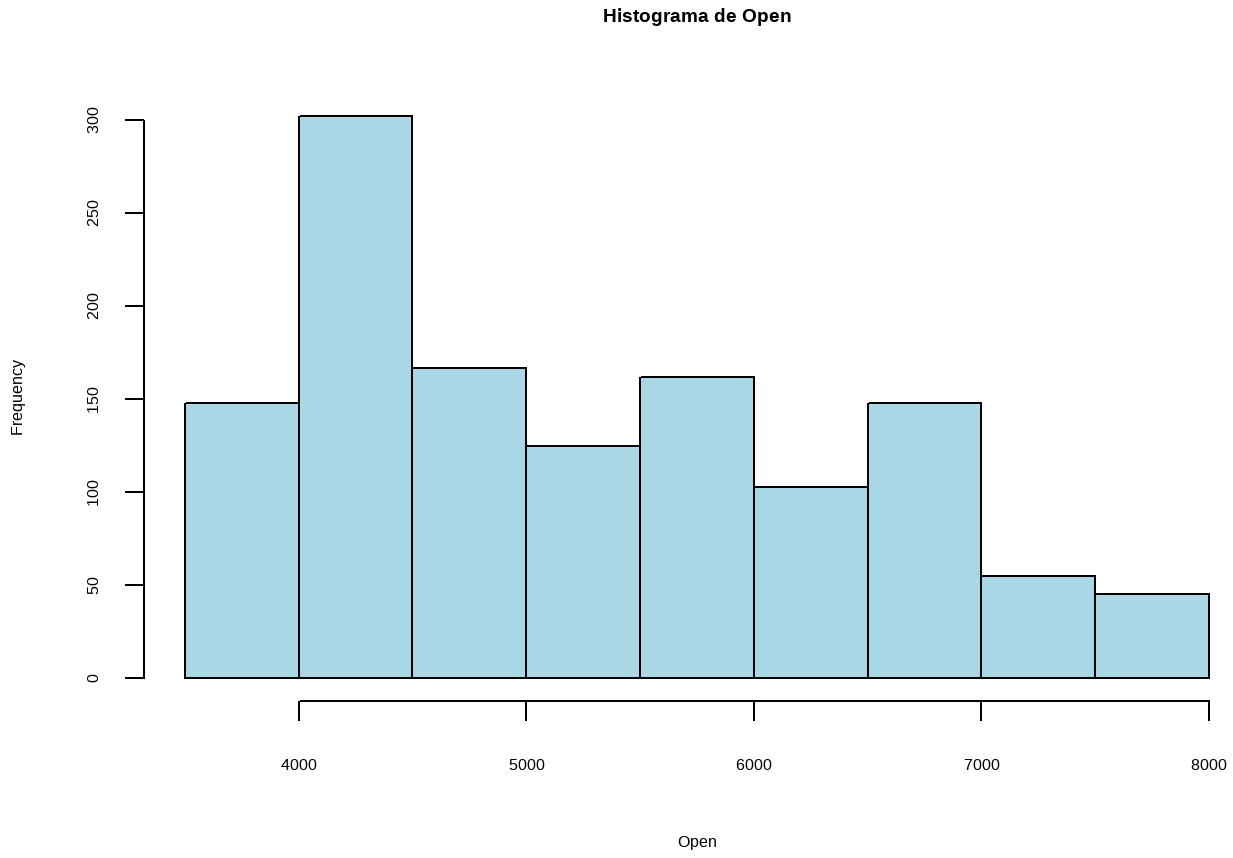
```
pander(diagnose_outlier(sp500))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	0	0	NA	5274
High	0	0	NA	5303
Low	0	0	NA	5243
Close	0	0	NA	5275
Adj.Close	0	0	NA	5275
Volume	36	2.869	7.225e+09	4.535e+09
rentabilidad	56	4.462	-0.004747	0.0004267
rent_porcent	56	4.462	-0.4747	0.04267

without_mean
5274
5303
5243
5275
5275
4.456e+09
0.0006686
0.06686

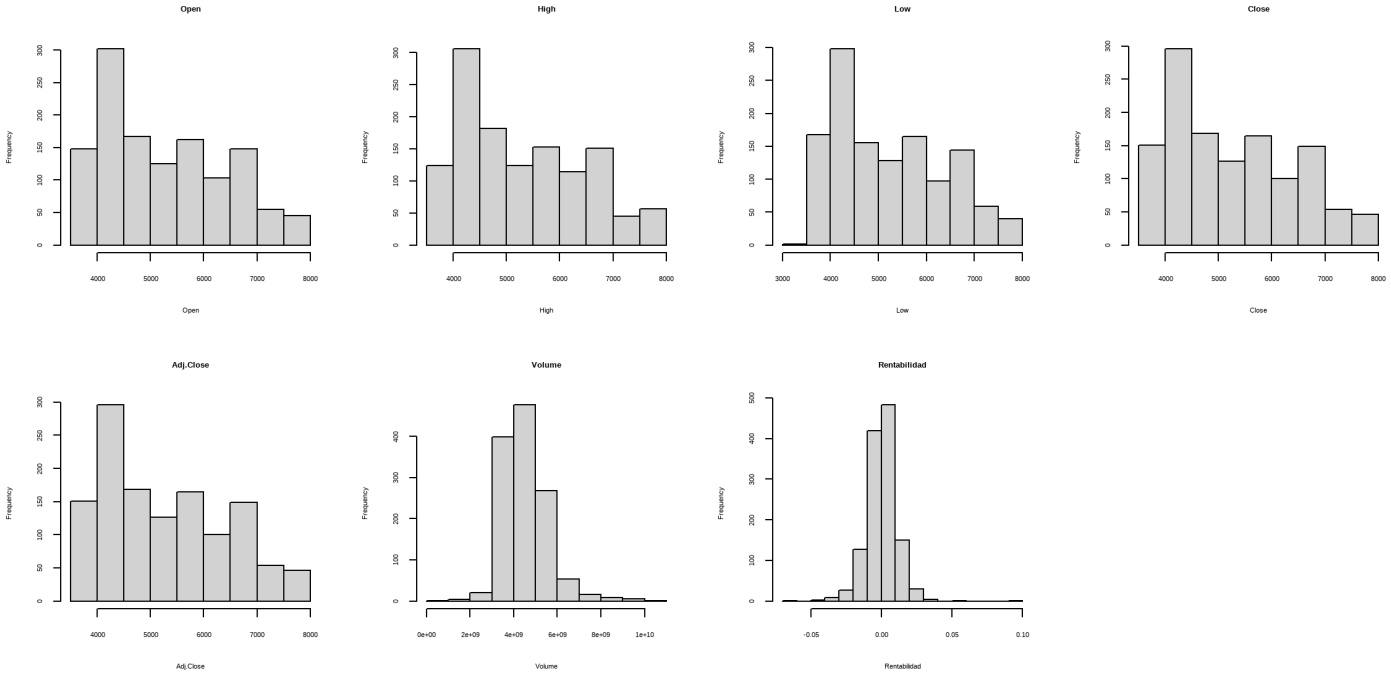
```
hist(sp500$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(sp500$Open, main = "Open", xlab = "Open")
hist(sp500$High, main = "High", xlab = "High")
hist(sp500$Low, main = "Low", xlab = "Low")
hist(sp500$Close, main = "Close", xlab = "Close")
hist(sp500$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(sp500$Volume, main = "Volume", xlab = "Volume")
hist(sp500$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



STOXX Europe 600 (^STOXX)

```
stoxx <- read.csv("datos_csv/STOXX600.csv")
pander::pander(head(stoxx,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-06	471.7	475.6	471.7	475.2	475.2	89335200
2021-09-07	475.1	475.1	472.6	472.9	472.9	122852800
2021-09-08	472.7	472.7	466.4	467.9	467.9	163146700
2021-09-09	468.1	469.3	463.8	467.6	467.6	1.62e+08
2021-09-10	467.7	469.1	465.8	466.3	466.3	145355900
2021-09-13	466.5	470	466.5	467.7	467.7	143754800
2021-09-14	467.6	469	465.7	467.6	467.6	159937700
2021-09-15	467.7	468.1	463.9	463.9	463.9	189650400
2021-09-16	463.9	468	463.9	466	466	172691500
2021-09-17	465.9	469.8	461.3	461.8	461.8	423202300

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
stoxx <- stoxx |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
stoxx <- stoxx |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(stoxx))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1257
Open	numeric	0	0	1203
High	numeric	0	0	1202
Low	numeric	0	0	1214
Close	numeric	0	0	1225
Adj.Close	numeric	0	0	1225
Volume	integer	0	0	1257
rentabilidad	numeric	1	0.07955	1257
rent_porcent	numeric	1	0.07955	1224

unique_rate
1
0.957
0.9562
0.9658
0.9745
0.9745
1
1
0.9737

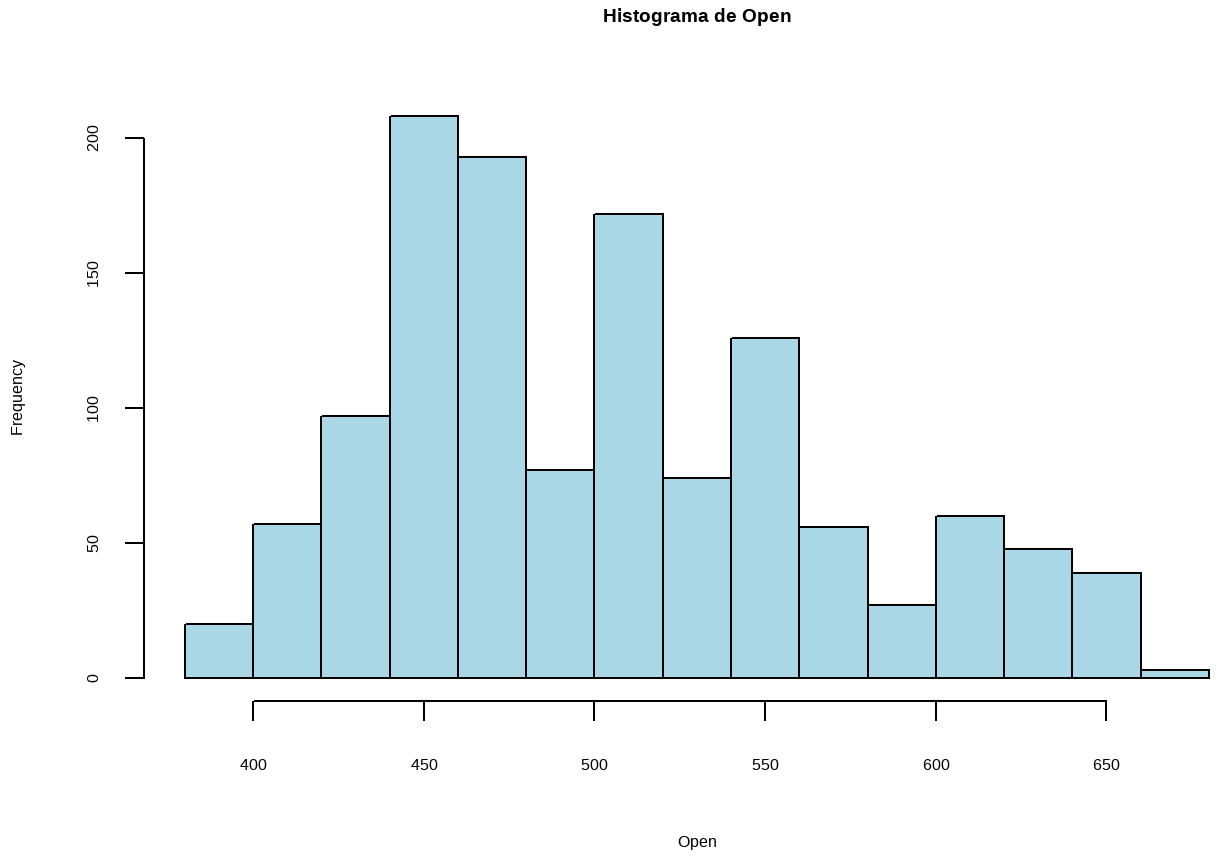
```
pander(diagnose_outlier(stoxx))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	0	0	NA	504.1
High	0	0	NA	506.6
Low	0	0	NA	501.6
Close	0	0	NA	504.3
Adj.Close	0	0	NA	504.3
Volume	83	6.603	339533719	201401015
rentabilidad	47	3.739	-0.007953	0.0002493
rent_porcent	47	3.739	-0.7953	0.02493

without_mean
504.1
506.6
501.6
504.3
504.3
191635245
0.0005681
0.05681

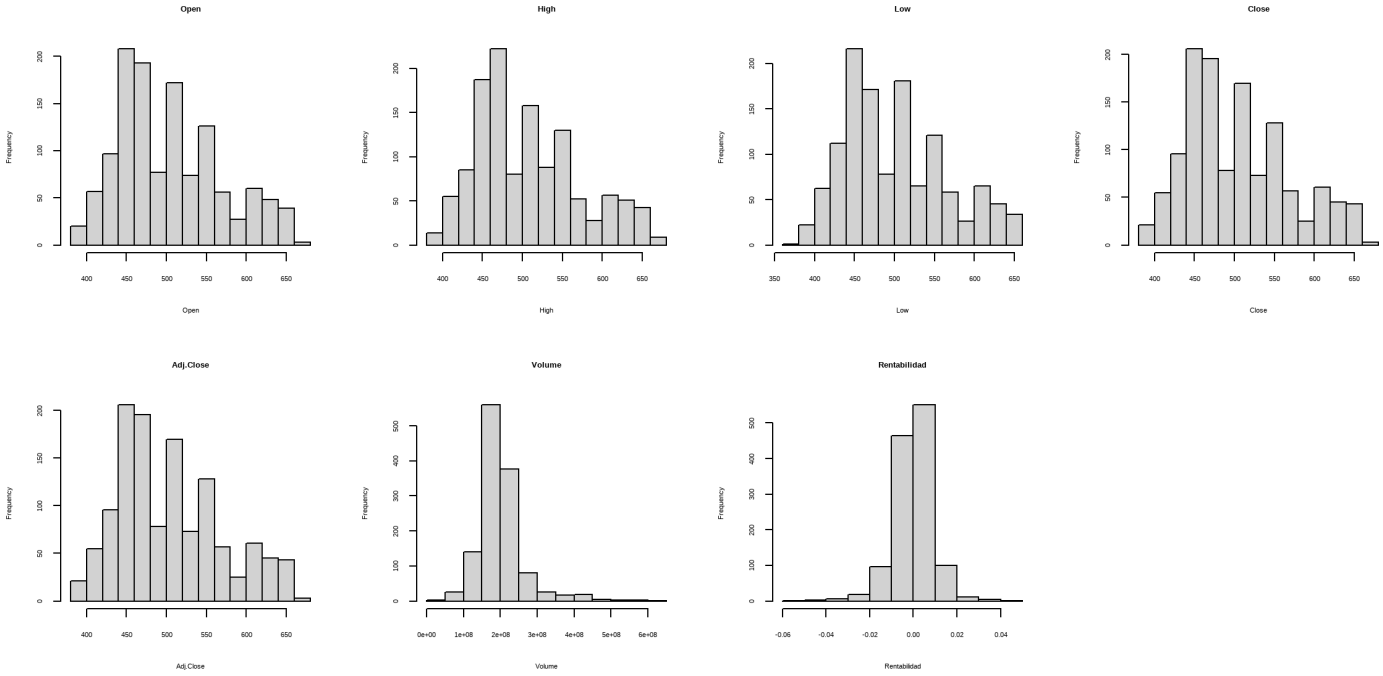
```
hist(stoxx$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(stoxx$Open, main = "Open", xlab = "Open")
hist(stoxx$High, main = "High", xlab = "High")
hist(stoxx$Low, main = "Low", xlab = "Low")
hist(stoxx$Close, main = "Close", xlab = "Close")
hist(stoxx$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(stoxx$Volume, main = "Volume", xlab = "Volume")
hist(stoxx$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Nasdaq-100 (QQQ)

```
qqq <- read.csv("datos_csv/QQQ.csv")
pander::pander(head(qqq,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	381.7	382.8	380.5	382.1	370.8	23970200
2021-09-08	381.9	381.9	378.5	380.8	369.5	32949200
2021-09-09	381	382.1	379.2	379.5	368.3	29399000
2021-09-10	381.2	382	376.2	376.6	365.5	40249400
2021-09-13	379	379.4	374.2	376.3	365.2	48741800
2021-09-14	377.9	378.6	374.3	375.3	364.2	41826600
2021-09-15	375.7	378.4	373.4	378	366.9	34097900
2021-09-16	376.7	378.9	374.7	378.3	367.1	35193100
2021-09-17	377.8	377.9	372.8	373.8	362.8	60912300
2021-09-20	367.5	369.2	360.9	365.7	355.3	76203200

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
qqq <- qqq |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
qqq <- qqq |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(qqq))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1255
Open	numeric	0	0	1233
High	numeric	0	0	1231
Low	numeric	0	0	1239
Close	numeric	0	0	1227
Adj.Close	numeric	0	0	1246
Volume	integer	0	0	1254
rentabilidad	numeric	1	0.07968	1255
rent_porcent	numeric	1	0.07968	1236

unique_rate
1
0.9825
0.9809
0.9873
0.9777
0.9928
0.9992
1
0.9849

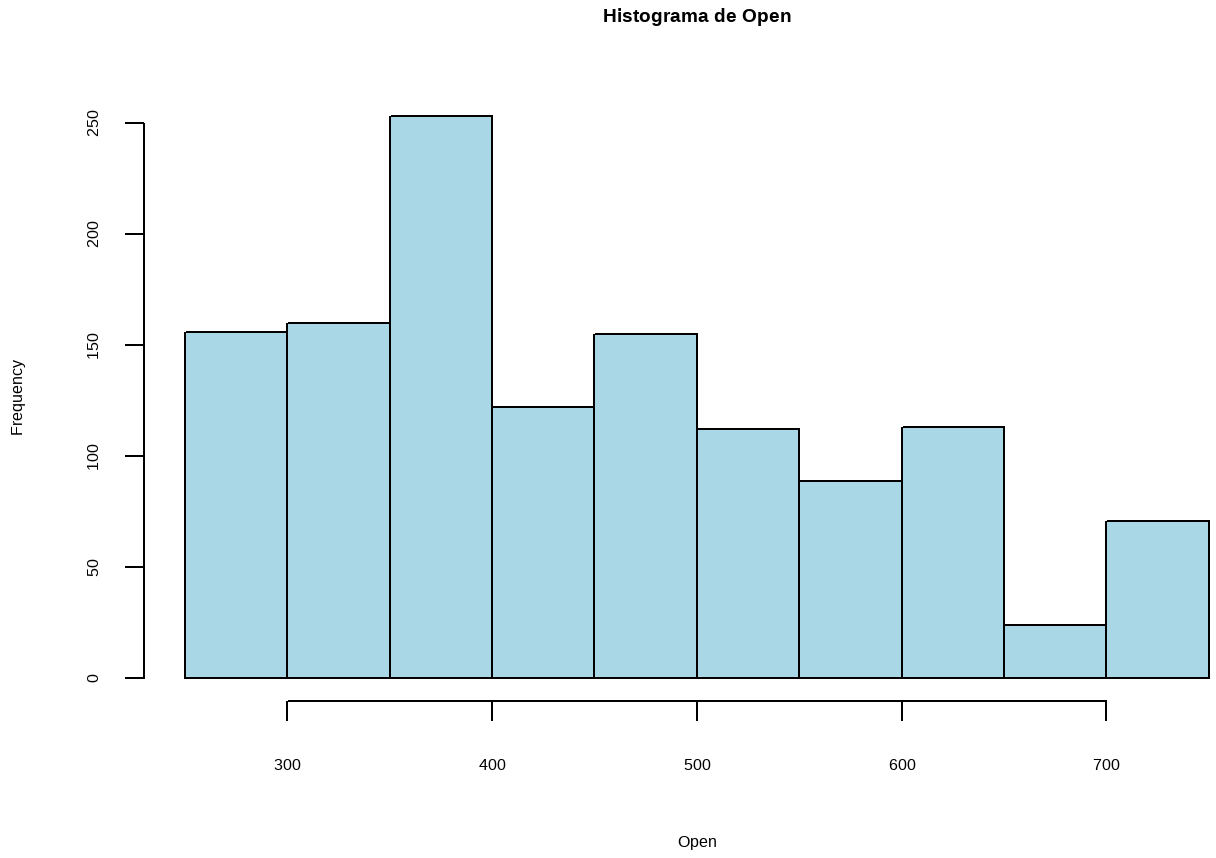
```
pander(diagnose_outlier(qqq))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	0	0	NA	448.8
High	0	0	NA	452.1
Low	0	0	NA	445.2
Close	0	0	NA	448.9
Adj.Close	0	0	NA	443.7
Volume	41	3.267	116528185	51105507
rentabilidad	49	3.904	-0.008781	0.0005041
rent_porcent	49	3.904	-0.8781	0.05041

without_mean
448.8
452.1
445.2
448.9
443.7
48896010
0.0008816
0.08816

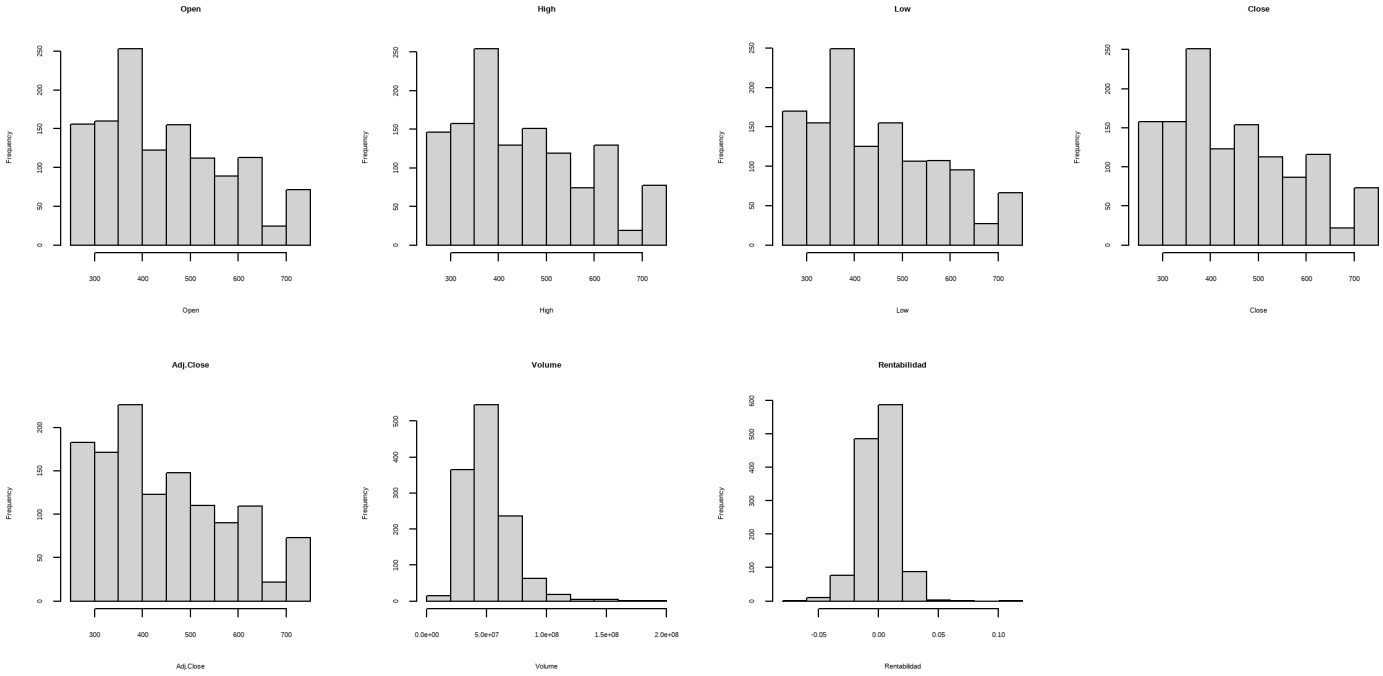
```
hist(qqq$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(qqq$Open, main = "Open", xlab = "Open")
hist(qqq$High, main = "High", xlab = "High")
hist(qqq$Low, main = "Low", xlab = "Low")
hist(qqq$Close, main = "Close", xlab = "Close")
hist(qqq$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(qqq$Volume, main = "Volume", xlab = "Volume")
hist(qqq$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Plata (SI=F)

```
plata <- read.csv("datos_csv/PLATA.csv")
pander::pander(head(plata,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	24.81	24.81	24.18	24.33	24.33	32
2021-09-08	24.35	24.4	23.94	24.01	24.01	105
2021-09-09	23.95	24.24	23.84	24.13	24.13	104
2021-09-10	24.14	24.14	23.85	23.85	23.85	13
2021-09-13	23.69	23.75	23.33	23.75	23.75	184
2021-09-14	23.66	23.85	23.64	23.84	23.84	82
2021-09-15	23.8	23.8	23.76	23.76	23.76	25
2021-09-16	23.51	23.51	22.61	22.75	22.75	75
2021-09-17	22.89	22.91	22.3	22.3	22.3	74
2021-09-20	22.38	22.38	22.14	22.16	22.16	132

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
plata <- plata |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
plata <- plata |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(plata))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1257
Open	numeric	0	0	1126
High	numeric	0	0	1149
Low	numeric	0	0	1145
Close	numeric	0	0	1217
Adj.Close	numeric	0	0	1217
Volume	integer	0	0	476
rentabilidad	numeric	1	0.07955	1257
rent_porcent	numeric	1	0.07955	1243

unique_rate
1
0.8958
0.9141
0.9109
0.9682
0.9682
0.3787
1
0.9889

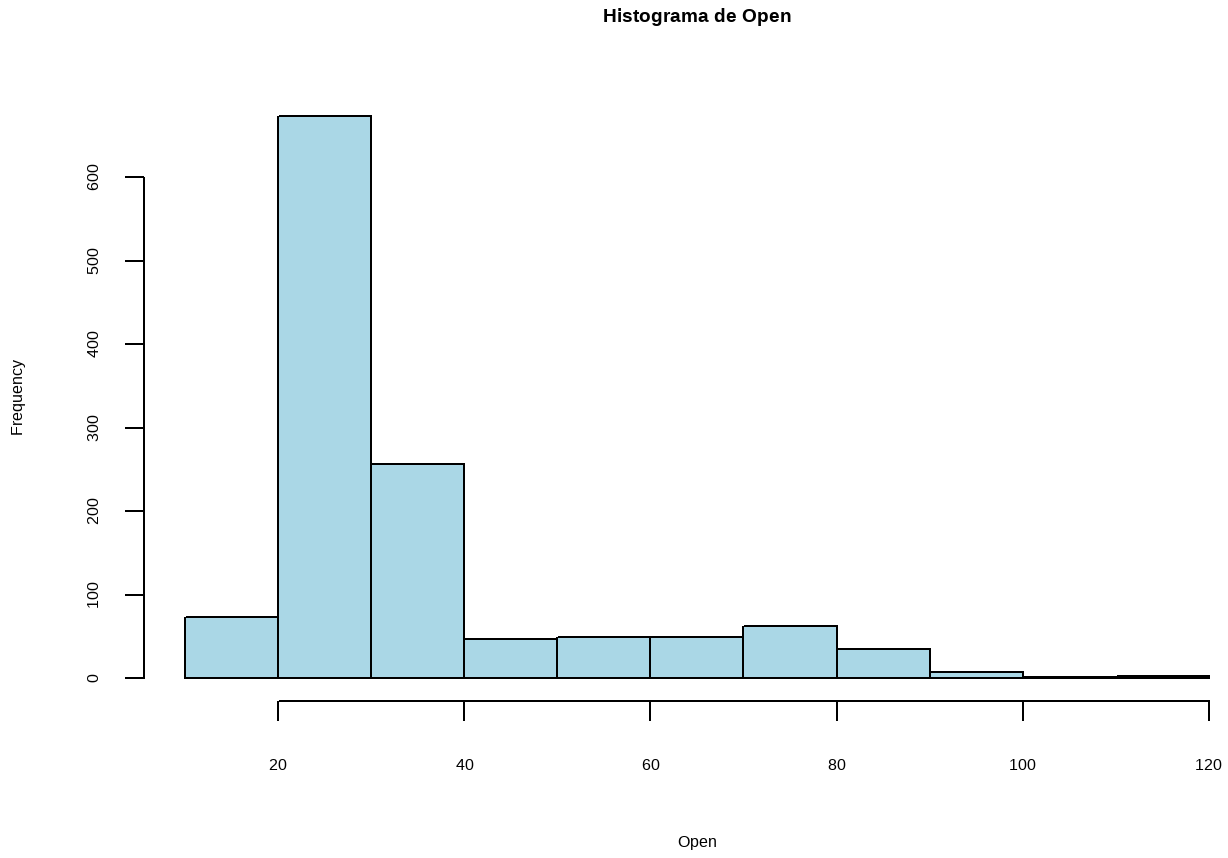
```
pander(diagnose_outlier(plata))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	192	15.27	72.94	34.25
High	193	15.35	74.2	34.62
Low	192	15.27	71.41	33.84
Close	193	15.35	72.67	34.21
Adj.Close	193	15.35	72.67	34.21
Volume	152	12.09	9793	1273
rentabilidad	71	5.648	-0.002239	0.000795
rent_porcent	71	5.648	-0.2239	0.0795

without_mean
27.27
27.44
27.07
27.24
27.24
100.5
0.0009768
0.09768

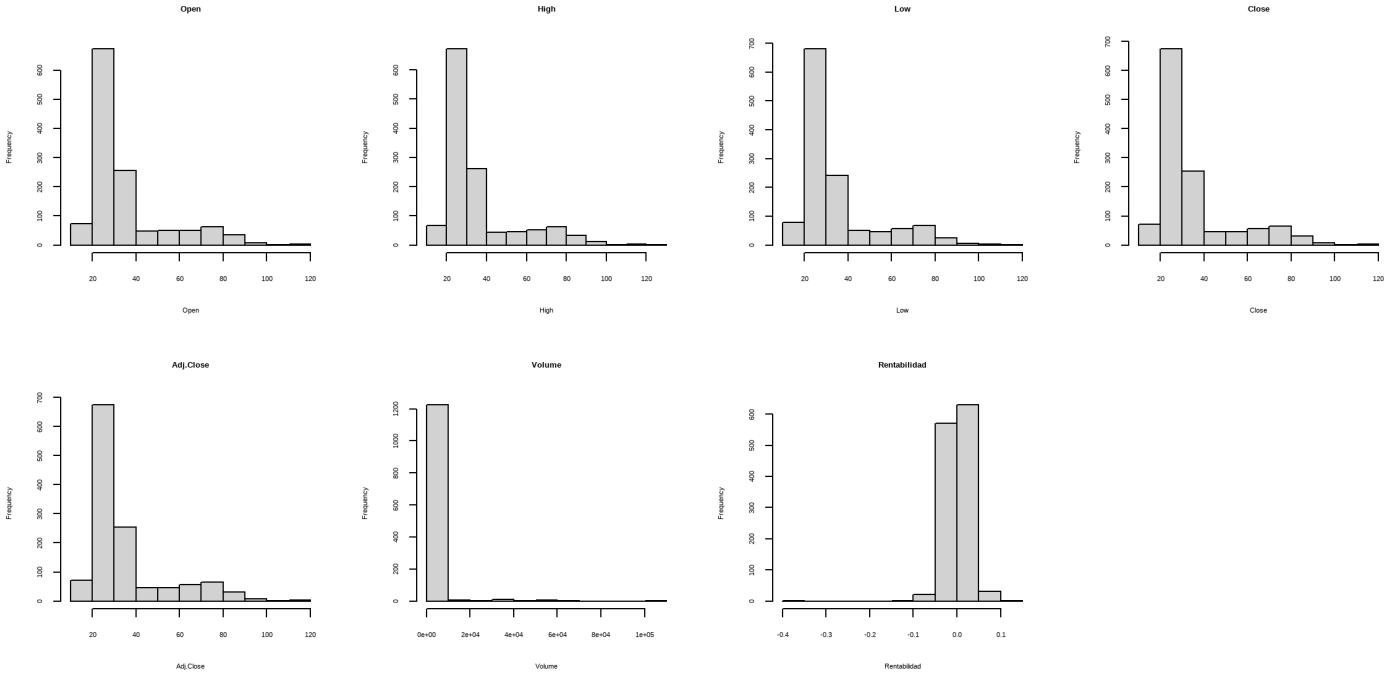
```
hist(plata$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(plata$Open, main = "Open", xlab = "Open")
hist(plata$High, main = "High", xlab = "High")
hist(plata$Low, main = "Low", xlab = "Low")
hist(plata$Close, main = "Close", xlab = "Close")
hist(plata$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(plata$Volume, main = "Volume", xlab = "Volume")
hist(plata$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Cobre (HG=F)

```
cobre <- read.csv("datos_csv/COBRE.csv")
pander::pander(head(cobre,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	4.338	4.338	4.253	4.278	4.278	746
2021-09-08	4.268	4.291	4.208	4.232	4.232	929
2021-09-09	4.228	4.302	4.224	4.284	4.284	645
2021-09-10	4.275	4.462	4.275	4.448	4.448	904
2021-09-13	4.415	4.467	4.335	4.364	4.364	630
2021-09-14	4.357	4.363	4.284	4.318	4.318	505
2021-09-15	4.31	4.416	4.292	4.404	4.404	624
2021-09-16	4.4	4.402	4.26	4.279	4.279	589
2021-09-17	4.282	4.34	4.233	4.246	4.246	808
2021-09-20	4.23	4.23	4.1	4.117	4.117	759

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
cobre <- cobre |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
cobre <- cobre |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(cobre))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1258
Open	numeric	0	0	1069
High	numeric	0	0	1089
Low	numeric	0	0	1053
Close	numeric	0	0	1089
Adj.Close	numeric	0	0	1089
Volume	integer	0	0	817
rentabilidad	numeric	1	0.07949	1253
rent_porcent	numeric	1	0.07949	1238

unique_rate
1
0.8498
0.8657
0.837
0.8657
0.8657
0.6494
0.996
0.9841

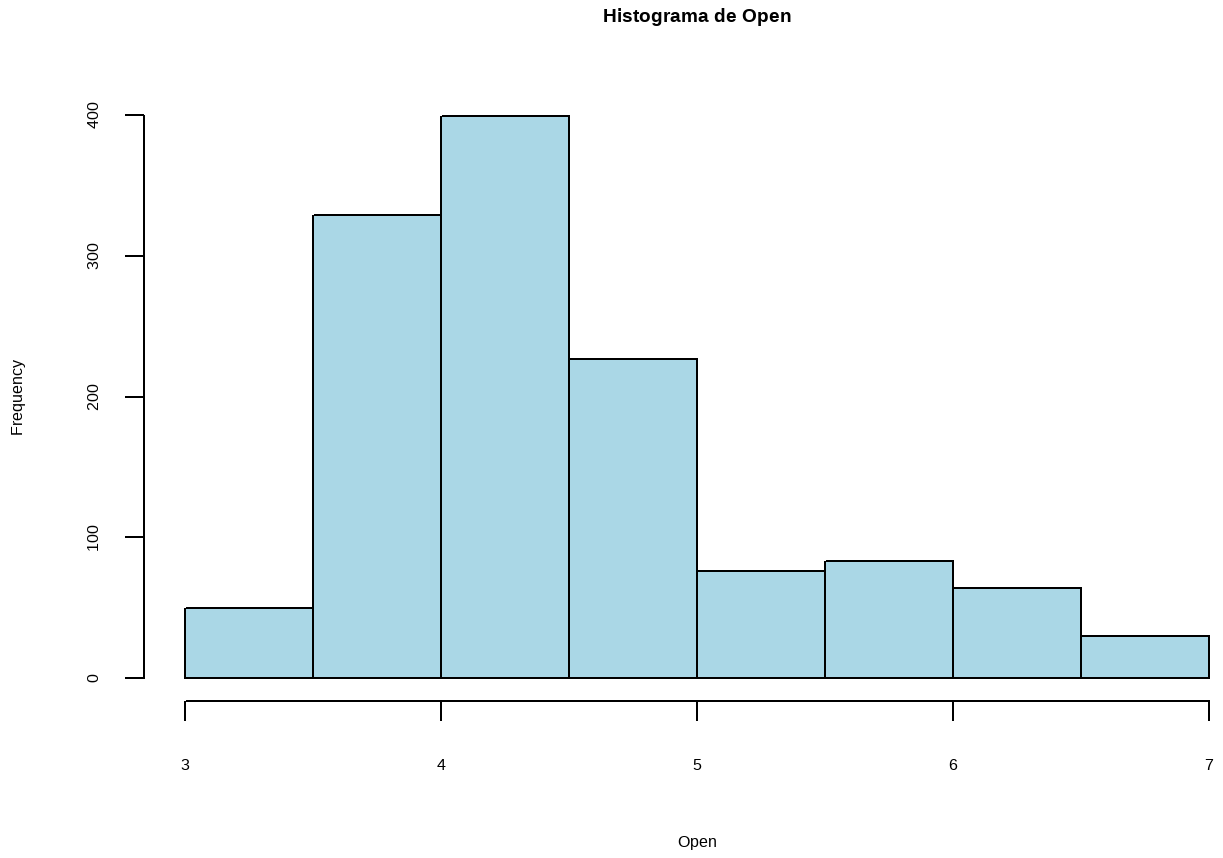
```
pander(diagnose_outlier(cobre))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	71	5.644	6.443	4.487
High	74	5.882	6.472	4.52
Low	84	6.677	6.356	4.453
Close	72	5.723	6.439	4.489
Adj.Close	72	5.723	6.439	4.489
Volume	94	7.472	11121	1455
rentabilidad	36	2.862	-0.01161	0.0003447
rent_porcent	36	2.862	-1.161	0.03447

without_mean
4.37
4.398
4.317
4.37
4.37
674.4
0.0006971
0.06971

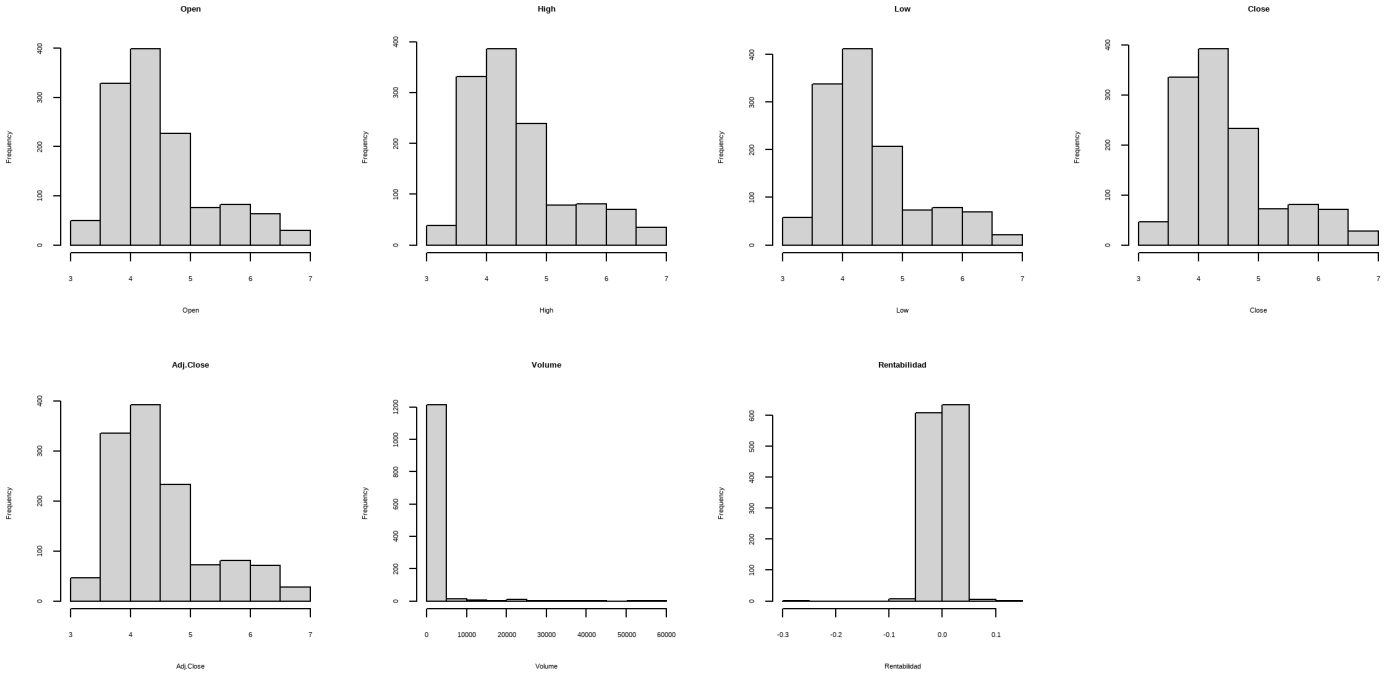
```
hist(cobre$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(cobre$Open, main = "Open", xlab = "Open")
hist(cobre$High, main = "High", xlab = "High")
hist(cobre$Low, main = "Low", xlab = "Low")
hist(cobre$Close, main = "Close", xlab = "Close")
hist(cobre$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(cobre$Volume, main = "Volume", xlab = "Volume")
hist(cobre$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Bonos del Tesoro a más de 20 años (TLT)

```
tlt <- read.csv("datos_csv/TLT.csv")
pander::pander(head(tlt,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	147.3	147.5	146.7	146.9	123.2	15547800
2021-09-08	147.7	148.2	147.4	147.9	124	14533700
2021-09-09	148.2	149.9	147.9	149.7	125.5	20324600
2021-09-10	148.9	149.2	148.2	148.4	124.4	14894600
2021-09-13	149	149.5	148.9	149.3	125.2	15036100
2021-09-14	149.7	151.6	149.6	151.1	126.7	19918400
2021-09-15	151.2	151.2	149.9	150.6	126.2	11940300
2021-09-16	149.7	150.4	149.5	149.9	125.7	13328900
2021-09-17	149.2	149.4	148.7	149.2	125.1	13782900
2021-09-20	150.6	151.4	150.2	151	126.6	14660400

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
tlt <- tlt |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
tlt <- tlt |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(tlt))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1255
Open	numeric	0	0	1037
High	numeric	0	0	1030
Low	numeric	0	0	1045
Close	numeric	0	0	1035
Adj.Close	numeric	0	0	1228
Volume	integer	0	0	1254
rentabilidad	numeric	1	0.07968	1253
rent_porcent	numeric	1	0.07968	1230

unique_rate
1
0.8263
0.8207
0.8327
0.8247
0.9785
0.9992
0.9984
0.9801

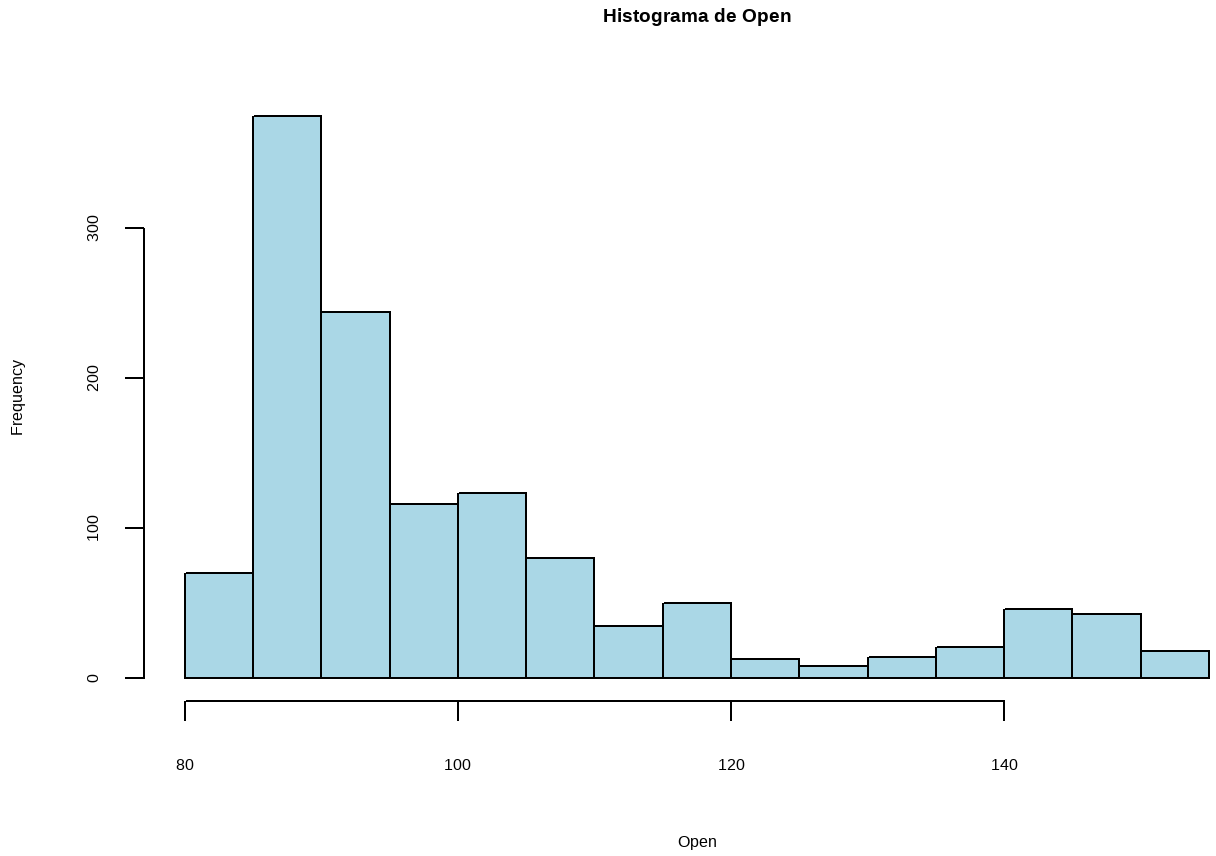
```
pander(diagnose_outlier(tlt))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	138	11	144.1	100.7
High	136	10.84	145	101.2
Low	137	10.92	143.4	100.2
Close	134	10.68	144.4	100.7
Adj.Close	153	12.19	119.9	90.38
Volume	36	2.869	82746375	31119353
rentabilidad	24	1.912	-0.00216	-0.0004631
rent_porcent	24	1.912	-0.216	-0.04631

without_mean
95.36
95.9
94.94
95.5
86.28
29594683
-0.00043
-0.043

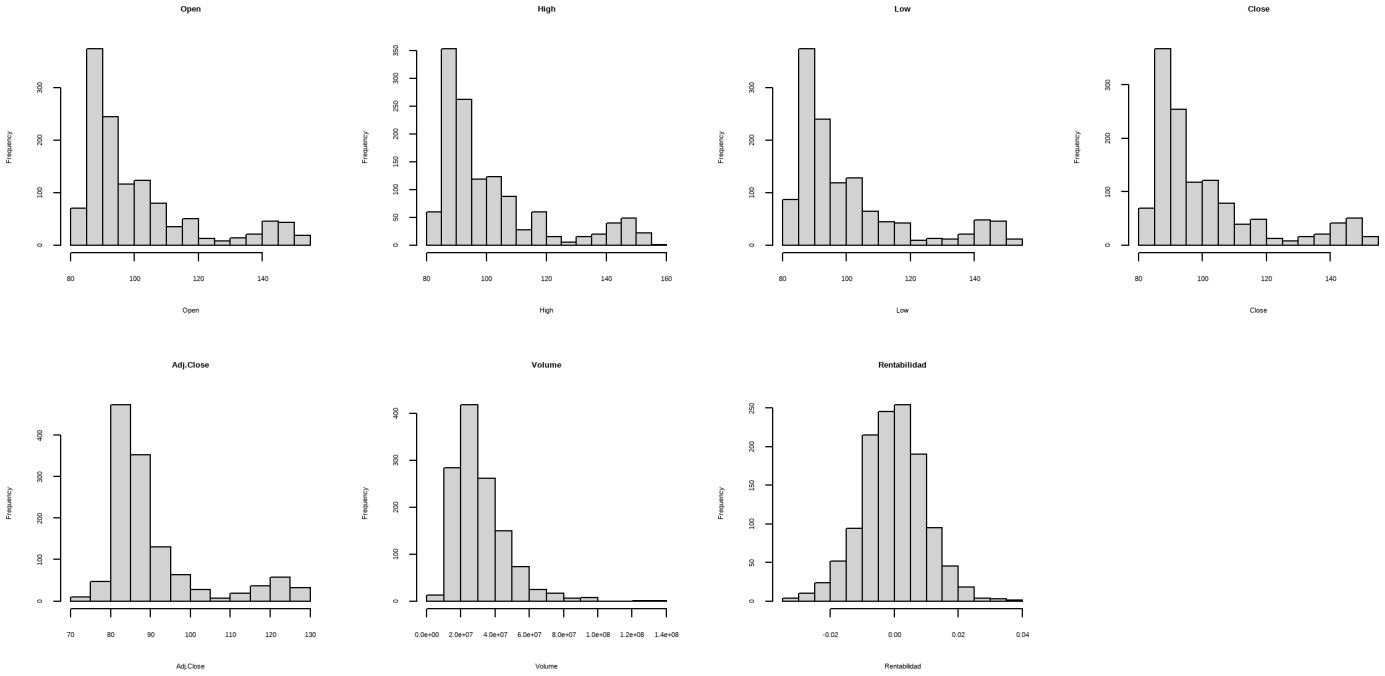
```
hist(tlt$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(tlt$Open, main = "Open", xlab = "Open")
hist(tlt$High, main = "High", xlab = "High")
hist(tlt$Low, main = "Low", xlab = "Low")
hist(tlt$Close, main = "Close", xlab = "Close")
hist(tlt$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(tlt$Volume, main = "Volume", xlab = "Volume")
hist(tlt$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Índice del dólar (DX-Y.NYB)

```
dolar <- read.csv("datos_csv/DOLAR.csv")
pander::pander(head(dolar,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	92.2	92.57	92.1	92.52	92.52	0
2021-09-08	92.54	92.86	92.47	92.65	92.65	0
2021-09-09	92.71	92.76	92.38	92.48	92.48	0
2021-09-10	92.53	92.65	92.33	92.58	92.58	0
2021-09-13	92.61	92.89	92.57	92.62	92.62	0
2021-09-14	92.62	92.68	92.32	92.65	92.65	0
2021-09-15	92.68	92.68	92.42	92.49	92.49	0
2021-09-16	92.46	92.96	92.46	92.86	92.86	0
2021-09-17	92.88	93.25	92.77	93.2	93.2	0
2021-09-20	93.25	93.45	93.19	93.24	93.24	0

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
dolar <- dolar |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
dolar <- dolar |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(dolar))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1257
Open	numeric	0	0	818
High	numeric	0	0	833
Low	numeric	0	0	805
Close	numeric	0	0	826
Adj.Close	numeric	0	0	826
Volume	integer	0	0	1
rentabilidad	numeric	1	0.07955	1239
rent_porcent	numeric	1	0.07955	1167

unique_rate
1
0.6508
0.6627
0.6404
0.6571
0.6571
0.0007955
0.9857
0.9284

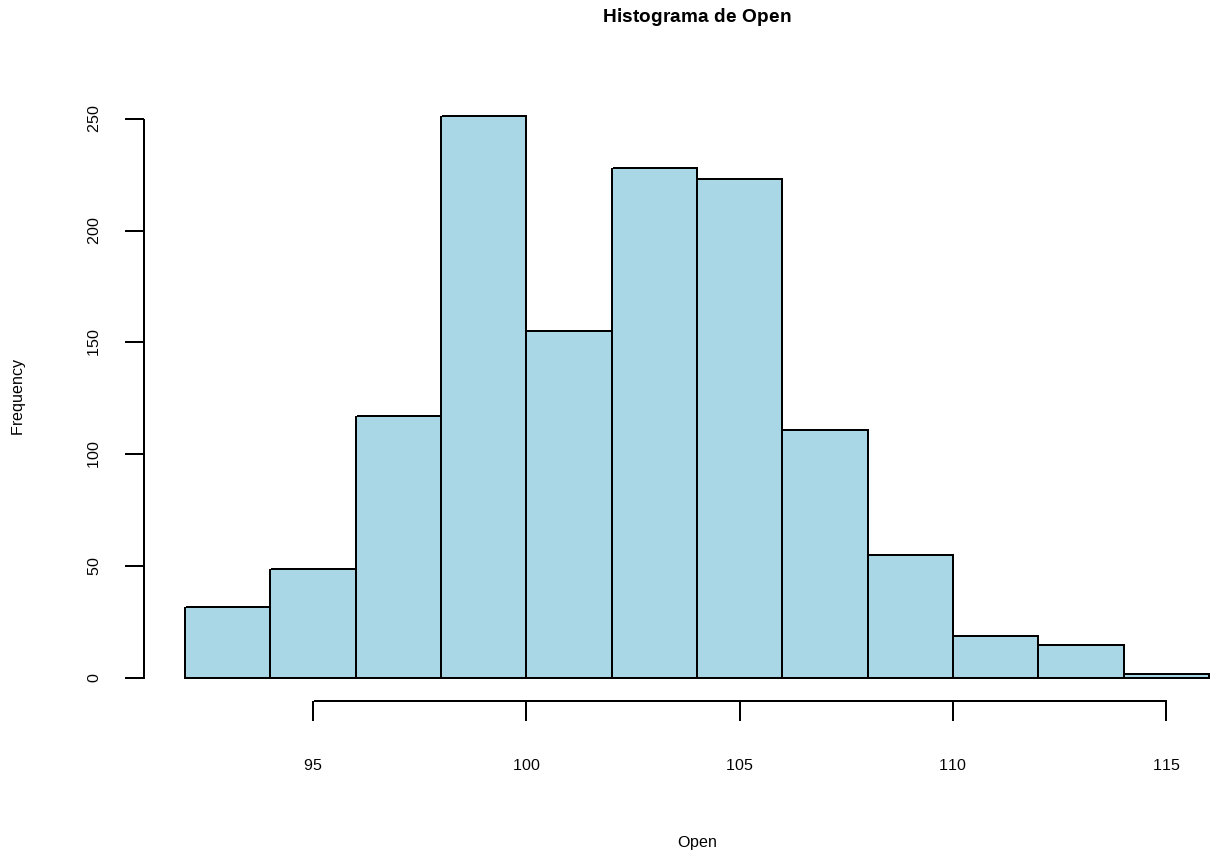
```
pander(diagnose_outlier(dolar))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	5	0.3978	113.6	102
High	6	0.4773	114.2	102.4
Low	3	0.2387	113.1	101.7
Close	4	0.3182	113.7	102
Adj.Close	4	0.3182	113.7	102
Volume	0	0	NA	0
rentabilidad	38	3.023	-0.005698	5.518e-05
rent_porcent	38	3.023	-0.5698	0.005519

without_mean
102
102.3
101.7
102
102
0
0.0002347
0.02347

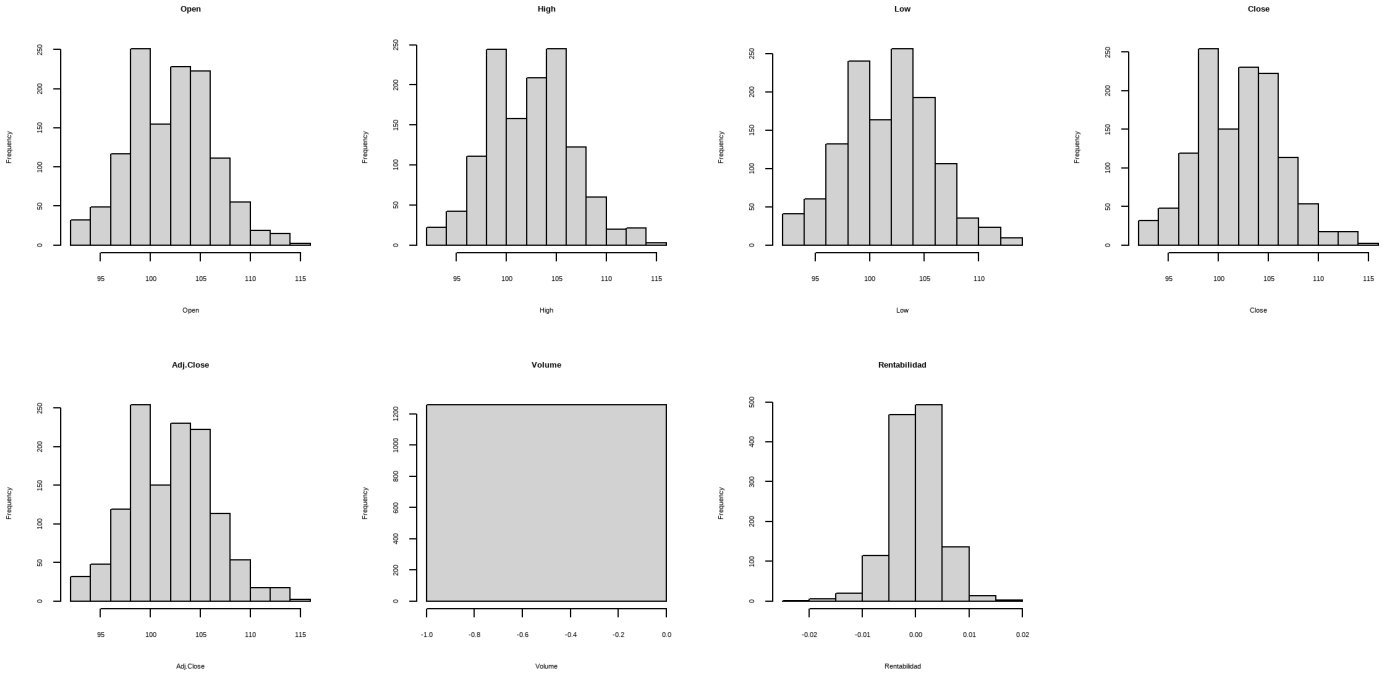
```
hist(dolar$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(dolar$Open, main = "Open", xlab = "Open")
hist(dolar$High, main = "High", xlab = "High")
hist(dolar$Low, main = "Low", xlab = "Low")
hist(dolar$Close, main = "Close", xlab = "Close")
hist(dolar$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(dolar$Volume, main = "Volume", xlab = "Volume")
hist(dolar$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Euro (FXE)

```
euro <- read.csv("datos_csv/EURO.csv")
pander::pander(head(euro,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	110.5	110.6	110.4	110.4	104.7	32900
2021-09-08	110.2	110.3	110.1	110.2	104.5	84200
2021-09-09	110.3	110.4	110.1	110.3	104.6	71400
2021-09-10	110.3	110.4	110.1	110.1	104.4	64000
2021-09-13	110	110.2	110	110.1	104.4	39200
2021-09-14	110.4	110.4	110	110.1	104.4	35900
2021-09-15	110.2	110.2	110.1	110.2	104.5	22900
2021-09-16	109.6	109.8	109.6	109.7	104.1	52400
2021-09-17	109.6	109.7	109.3	109.4	103.7	256900
2021-09-20	109.2	109.4	109.2	109.4	103.7	163100

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
euro <- euro |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
euro <- euro |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(euro))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1255
Open	numeric	0	0	852
High	numeric	0	0	823
Low	numeric	0	0	855
Close	numeric	0	0	836
Adj.Close	numeric	0	0	1181
Volume	integer	0	0	915
rentabilidad	numeric	1	0.07968	1239
rent_porcent	numeric	1	0.07968	1171

unique_rate
1
0.6789
0.6558
0.6813
0.6661
0.941
0.7291
0.9873
0.9331

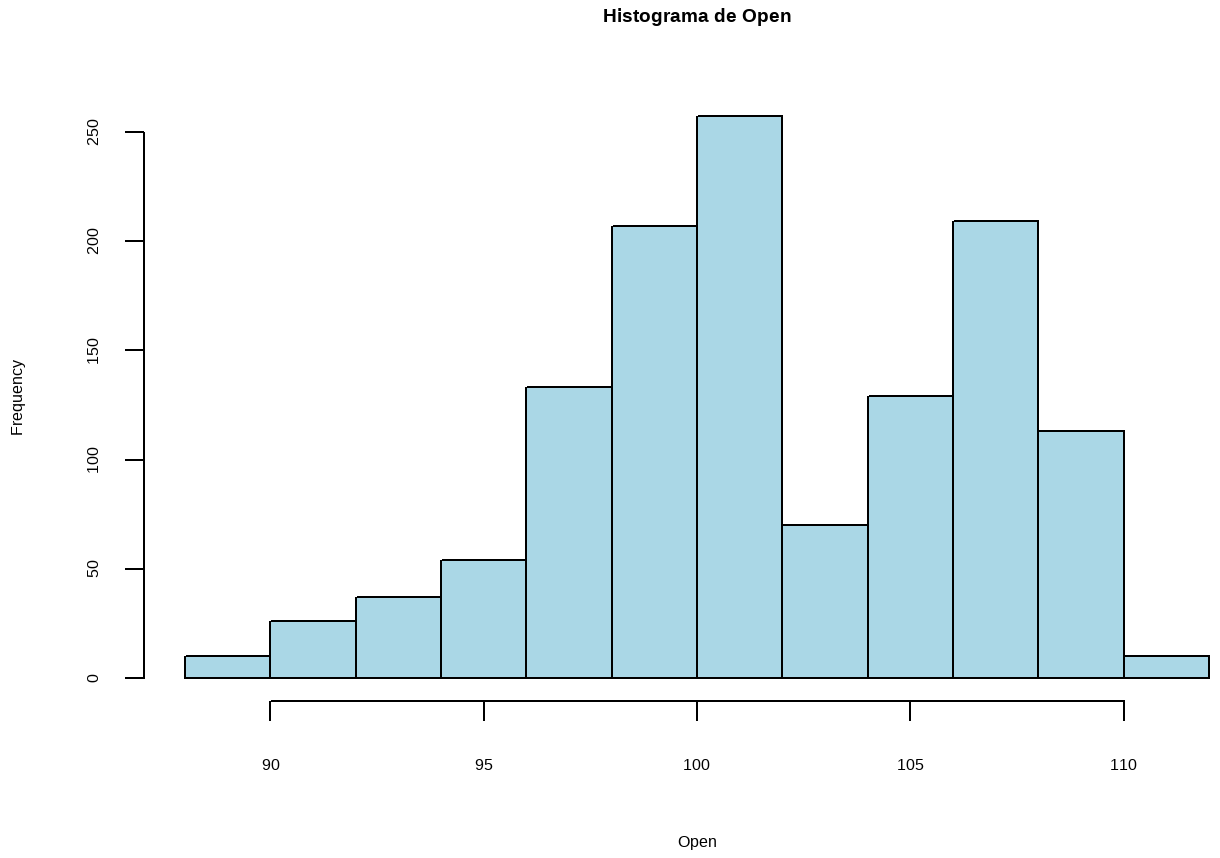
```
pander(diagnose_outlier(euro))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	0	0	NA	101.8
High	0	0	NA	102
Low	0	0	NA	101.6
Close	0	0	NA	101.8
Adj.Close	0	0	NA	98.75
Volume	100	7.968	438004	109551
rentabilidad	37	2.948	0.003008	-2.412e-05
rent_porcent	37	2.948	0.3008	-0.002411

without_mean
101.8
102
101.6
101.8
98.75
81113
-0.0001163
-0.01163

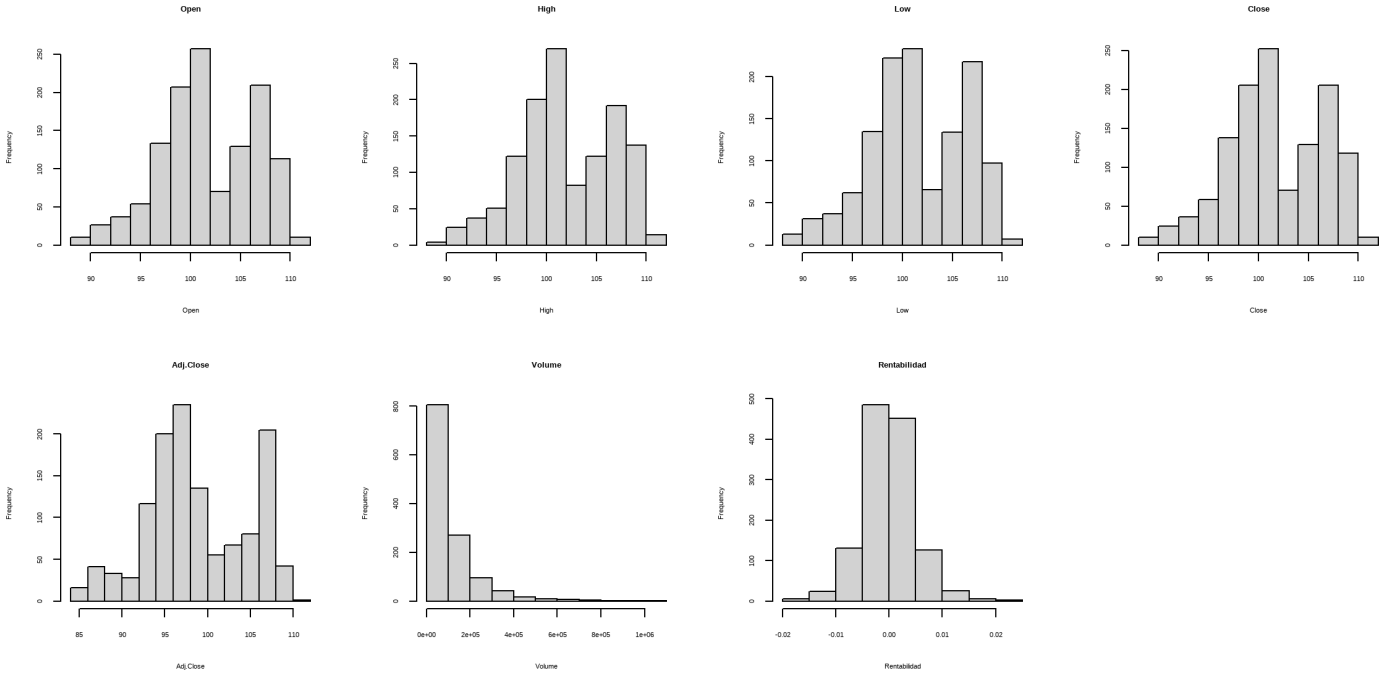
```
hist(euro$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(euro$Open, main = "Open", xlab = "Open")
hist(euro$High, main = "High", xlab = "High")
hist(euro$Low, main = "Low", xlab = "Low")
hist(euro$Close, main = "Close", xlab = "Close")
hist(euro$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(euro$Volume, main = "Volume", xlab = "Volume")
hist(euro$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Bitcoin (BTC-USD)

```
btc <- read.csv("datos_csv/BTC.csv")
pander::pander(head(btc,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-04	50009	50546	49549	49945	49945	3.747e+10
2021-09-05	49938	51869	49539	51753	51753	3.032e+10
2021-09-06	51769	52701	51054	52634	52634	3.888e+10
2021-09-07	52660	52854	43285	46811	46811	6.521e+10
2021-09-08	46828	47334	44561	46091	46091	4.901e+10
2021-09-09	45775	47262	45670	46391	46391	3.867e+10
2021-09-10	46397	47032	44344	44884	44884	3.915e+10
2021-09-11	44870	45969	44818	45201	45201	3.45e+10
2021-09-12	45207	46365	44790	46063	46063	2.788e+10
2021-09-13	46057	46599	43591	44963	44963	4.097e+10

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
btc <- btc |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
btc <- btc |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(btc))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1827
Open	numeric	0	0	1827
High	numeric	0	0	1827
Low	numeric	0	0	1826
Close	numeric	0	0	1827
Adj.Close	numeric	0	0	1827
Volume	numeric	0	0	1827
rentabilidad	numeric	1	0.05473	1827
rent_porcent	numeric	1	0.05473	1803

unique_rate
1
1
1
0.9995
1
1
1
1
0.9869

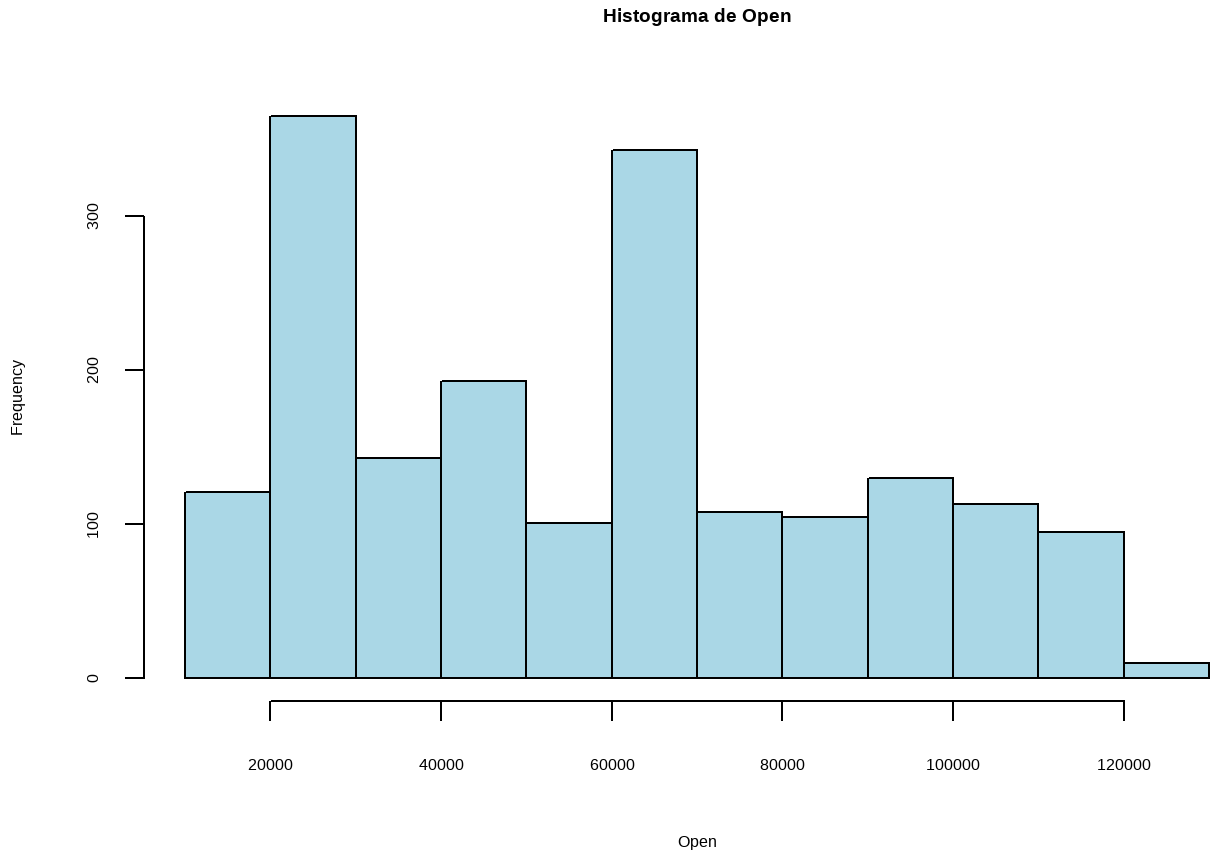
```
pander(diagnose_outlier(btc))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	0	0	NA	58165
High	0	0	NA	59193
Low	0	0	NA	57081
Close	0	0	NA	58179
Adj.Close	0	0	NA	58179
Volume	81	4.433	9.714e+10	3.48e+10
rentabilidad	122	6.678	-0.005067	0.0002558
rent_porcent	122	6.678	-0.5067	0.02557

without_mean
58165
59193
57081
58179
58179
3.19e+10
0.0006368
0.06368

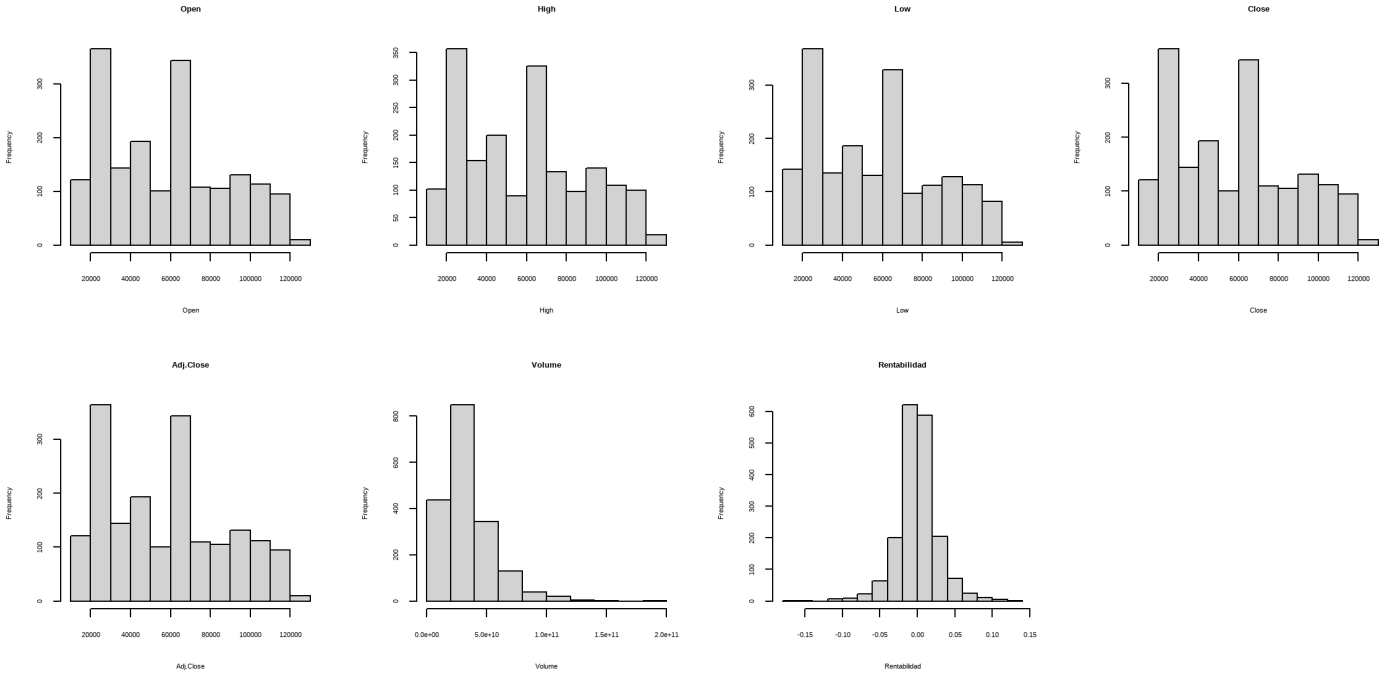
```
hist(btc$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(btc$Open, main = "Open", xlab = "Open")
hist(btc$High, main = "High", xlab = "High")
hist(btc$Low, main = "Low", xlab = "Low")
hist(btc$Close, main = "Close", xlab = "Close")
hist(btc$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(btc$Volume, main = "Volume", xlab = "Volume")
hist(btc$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Ethereum (ETH-USD)

```
eth <- read.csv("datos_csv/ETH.csv")
pander::pander(head(eth,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-04	3938	3969	3838	3888	3888	2.081e+10
2021-09-05	3886	3979	3838	3952	3952	1.837e+10
2021-09-06	3952	3968	3869	3928	3928	1.867e+10
2021-09-07	3927	3945	3062	3426	3426	3.913e+10
2021-09-08	3428	3559	3225	3497	3497	3.174e+10
2021-09-09	3453	3563	3401	3427	3427	2.412e+10
2021-09-10	3426	3513	3157	3212	3212	2.236e+10
2021-09-11	3209	3347	3209	3270	3270	1.863e+10
2021-09-12	3270	3462	3235	3410	3410	1.681e+10
2021-09-13	3407	3427	3122	3286	3286	2.272e+10

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
eth <- eth |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
eth <- eth |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(eth))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1827
Open	numeric	0	0	1827
High	numeric	0	0	1826
Low	numeric	0	0	1826
Close	numeric	0	0	1826
Adj.Close	numeric	0	0	1826
Volume	numeric	0	0	1827
rentabilidad	numeric	1	0.05473	1827
rent_porcent	numeric	1	0.05473	1813

unique_rate
1
1
0.9995
0.9995
0.9995
0.9995
1
1
0.9923

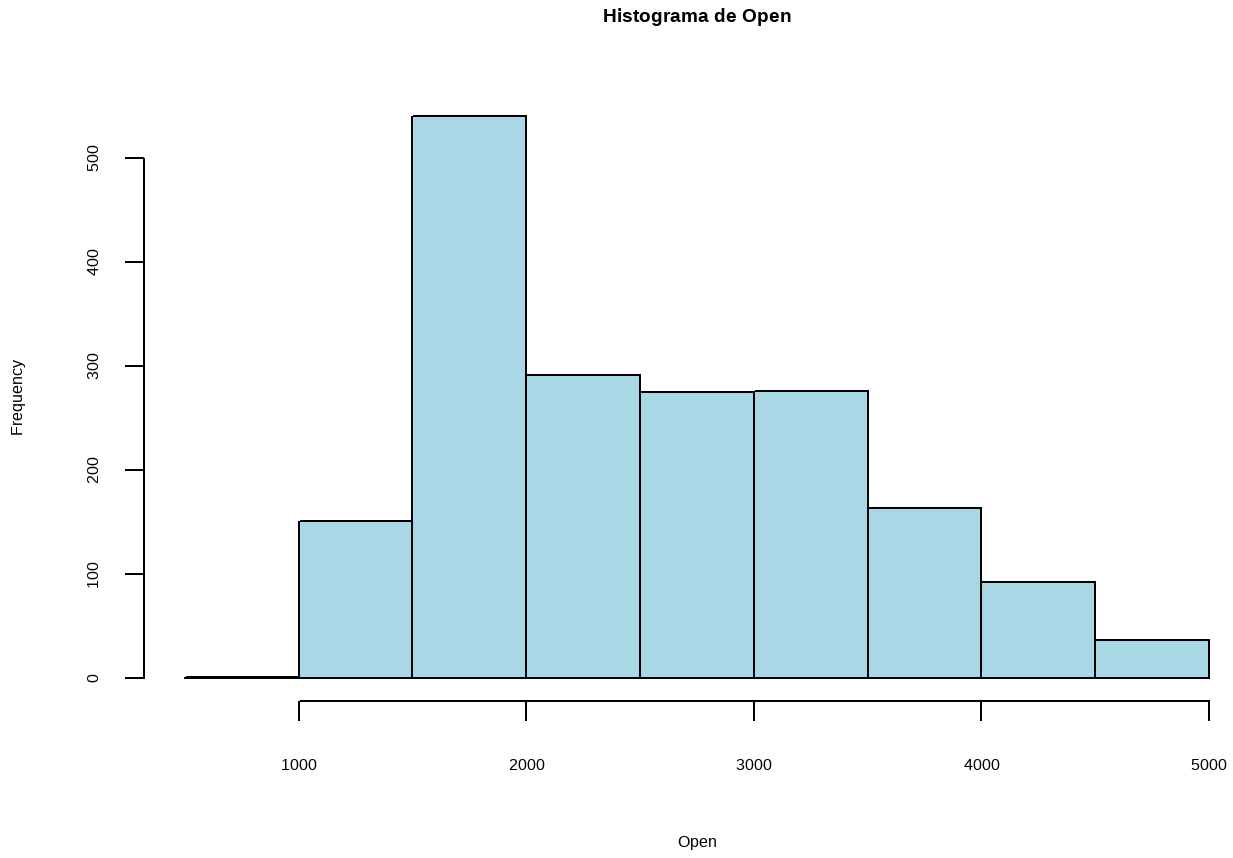
```
pander(diagnose_outlier(eth))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	0	0	NA	2527
High	0	0	NA	2588
Low	0	0	NA	2460
Close	0	0	NA	2526
Adj.Close	0	0	NA	2526
Volume	101	5.528	5.181e+10	1.772e+10
rentabilidad	109	5.966	-0.007384	-0.0002515
rent_porcent	109	5.966	-0.7384	-0.02515

without_mean
2527
2588
2460
2526
2526
1.573e+10
0.0002013
0.02013

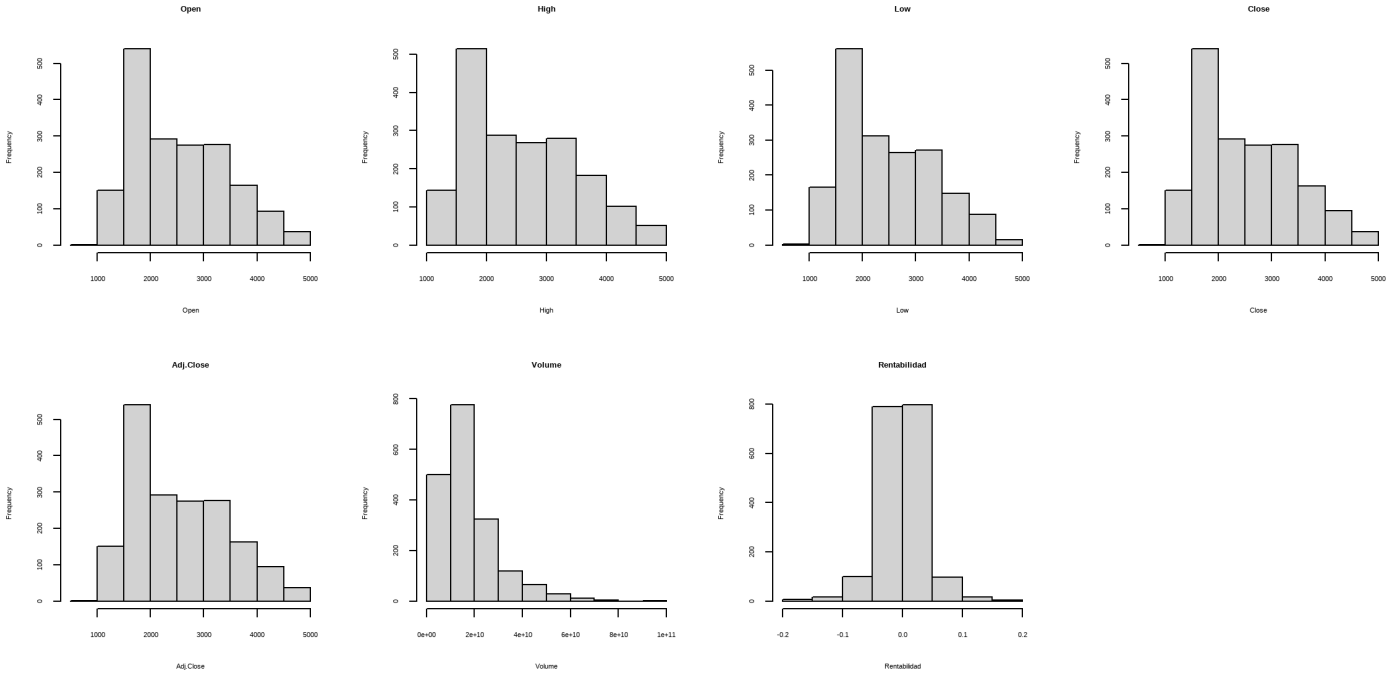
```
hist(eth$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(eth$Open, main = "Open", xlab = "Open")
hist(eth$High, main = "High", xlab = "High")
hist(eth$Low, main = "Low", xlab = "Low")
hist(eth$Close, main = "Close", xlab = "Close")
hist(eth$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(eth$Volume, main = "Volume", xlab = "Volume")
hist(eth$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



VIX (^VIX)

```
vix <- read.csv("datos_csv/VIX.csv")
pander::pander(head(vix,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	16.94	18.39	16.89	18.14	18.14	0
2021-09-08	18.97	19.64	17.78	17.96	17.96	0
2021-09-09	19.44	19.54	17.17	18.8	18.8	0
2021-09-10	17.94	21.13	16.99	20.95	20.95	0
2021-09-13	19.64	21.18	18.76	19.37	19.37	0
2021-09-14	19.58	20.47	18.39	19.46	19.46	0
2021-09-15	19.3	20.27	18.01	18.18	18.18	0
2021-09-16	18.41	19.76	17.65	18.69	18.69	0
2021-09-17	18.37	21.51	18.35	20.81	20.81	0
2021-09-20	24.25	28.79	23.9	25.71	25.71	0

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
vix <- vix |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
vix <- vix |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(vix))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1256
Open	numeric	0	0	855
High	numeric	0	0	911
Low	numeric	0	0	846
Close	numeric	0	0	866
Adj.Close	numeric	0	0	866
Volume	integer	0	0	1
rentabilidad	numeric	1	0.07962	1251
rent_porcent	numeric	1	0.07962	1245

unique_rate
1
0.6807
0.7253
0.6736
0.6895
0.6895
0.0007962
0.996
0.9912

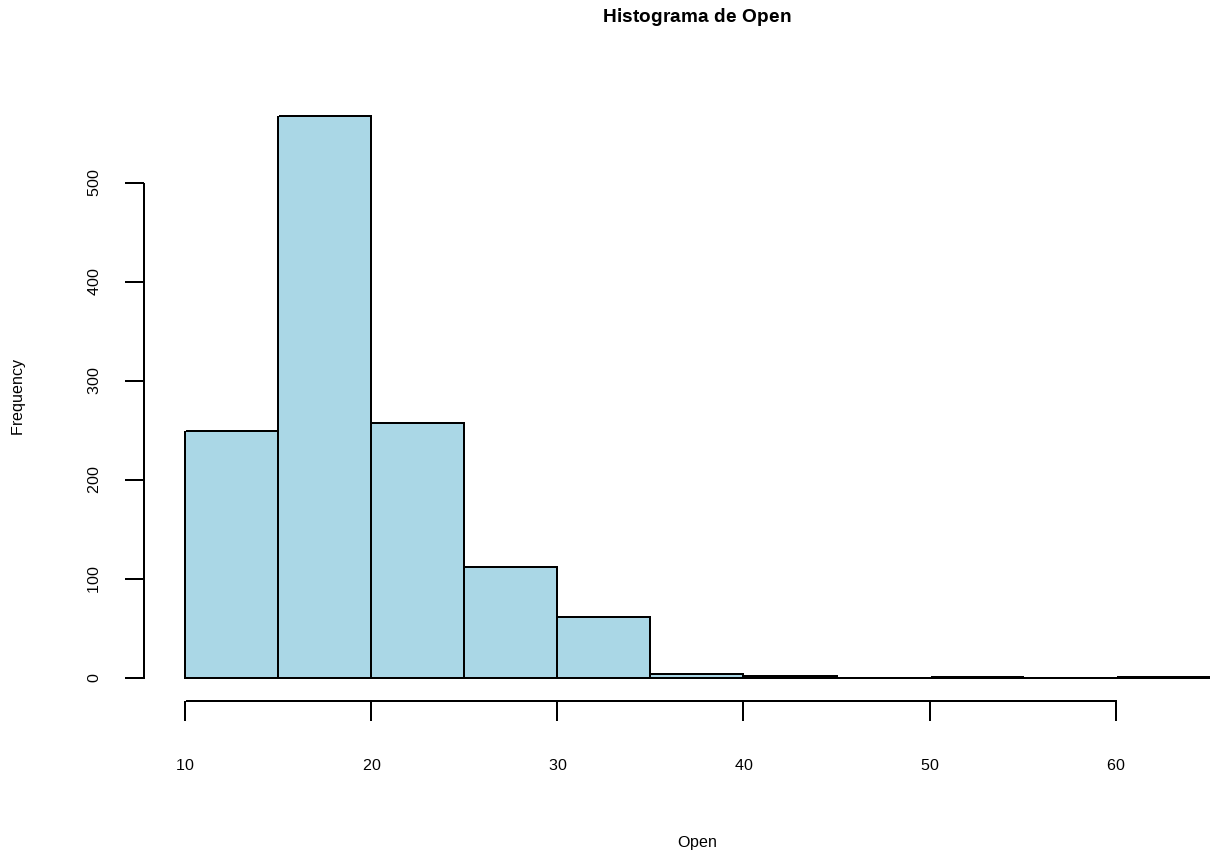
```
pander(diagnose_outlier(vix))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	43	3.424	34.73	19.41
High	40	3.185	38.69	20.46
Low	45	3.583	31.39	18.4
Close	36	2.866	34.7	19.18
Adj.Close	36	2.866	34.7	19.18
Volume	0	0	NA	0
rentabilidad	49	3.901	0.09006	-0.0001768
rent_porcent	49	3.901	9.006	-0.01768

without_mean
18.86
19.86
17.92
18.72
18.72
0
-0.003843
-0.3843

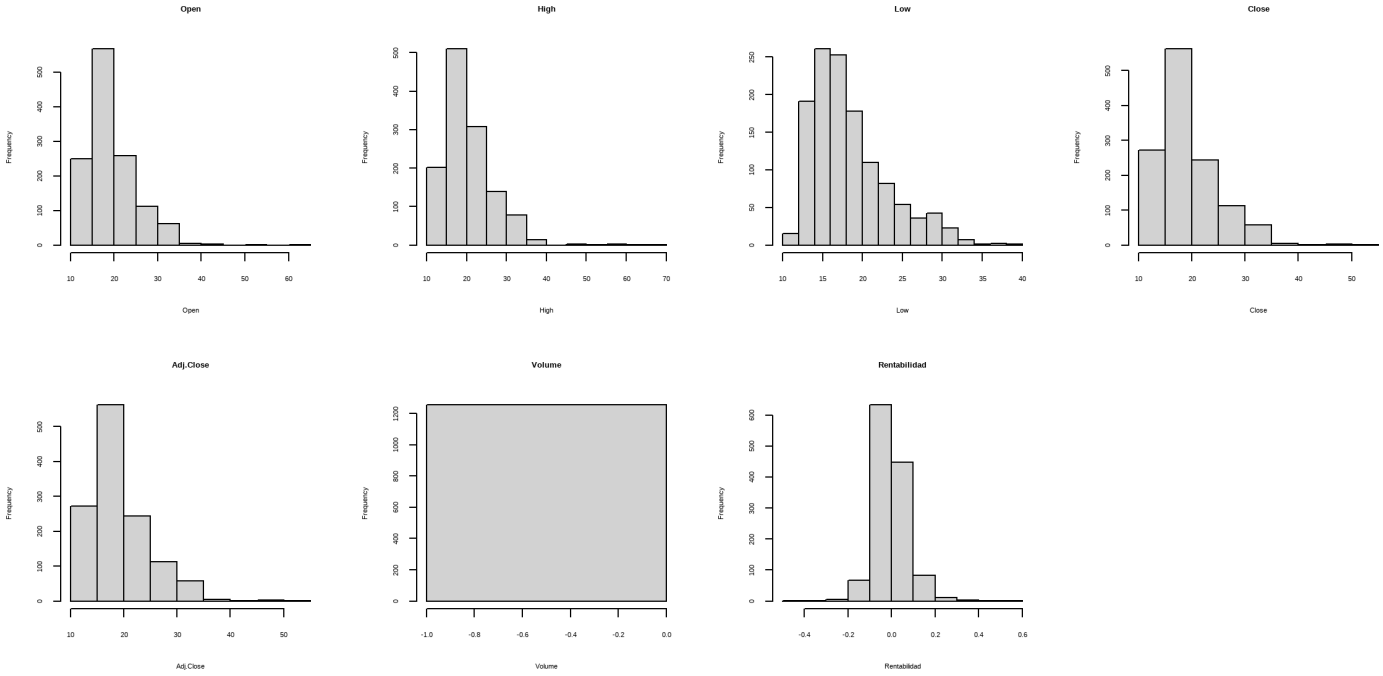
```
hist(vix$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(vix$Open, main = "Open", xlab = "Open")
hist(vix$High, main = "High", xlab = "High")
hist(vix$Low, main = "Low", xlab = "Low")
hist(vix$Close, main = "Close", xlab = "Close")
hist(vix$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(vix$Volume, main = "Volume", xlab = "Volume")
hist(vix$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Short S&P 500 (SH)

```
sh <- read.csv("datos_csv/SH.csv")
pander::pander(head(sh,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	58.04	58.32	58.04	58.2	48.83	775175
2021-09-08	58.28	58.56	58.16	58.28	48.9	1452975
2021-09-09	58.32	58.56	58.08	58.56	49.13	1475100
2021-09-10	58.24	59	58.2	59	49.5	1811575
2021-09-13	58.6	59.16	58.52	58.84	49.37	2307275
2021-09-14	58.6	59.28	58.6	59.12	49.6	1969150
2021-09-15	59.12	59.24	58.56	58.64	49.2	1910125
2021-09-16	58.76	59.16	58.6	58.76	49.3	1615550
2021-09-17	58.84	59.36	58.8	59.28	49.74	2401625
2021-09-20	60.2	61	59.96	60.32	50.61	6288225

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
sh <- sh |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
sh <- sh |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(sh))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1255
Open	numeric	0	0	770
High	numeric	0	0	791
Low	numeric	0	0	760
Close	numeric	0	0	775
Adj.Close	numeric	0	0	969
Volume	integer	0	0	1251
rentabilidad	numeric	1	0.07968	1192
rent_porcent	numeric	1	0.07968	1176

unique_rate
1
0.6135
0.6303
0.6056
0.6175
0.7721
0.9968
0.9498
0.9371

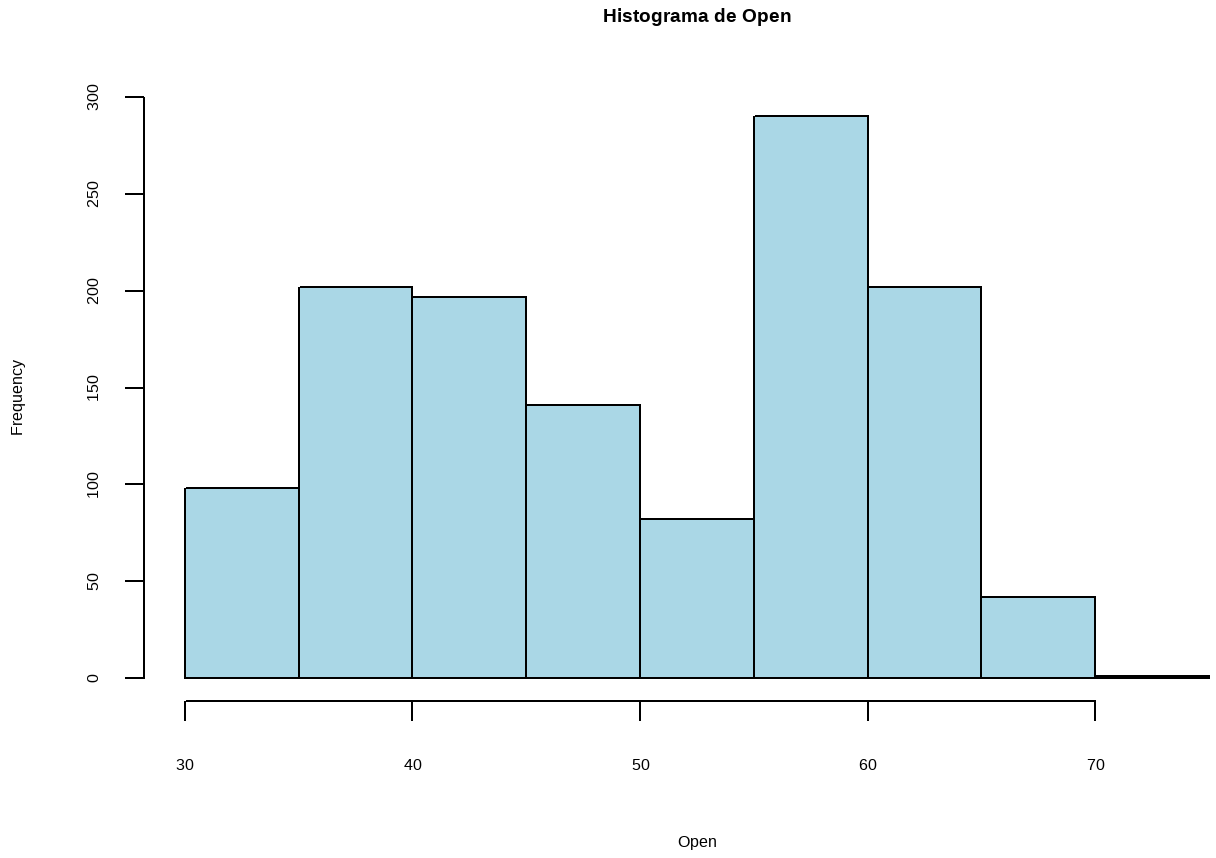
```
pander(diagnose_outlier(sh))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	0	0	NA	49.66
High	0	0	NA	49.98
Low	0	0	NA	49.36
Close	0	0	NA	49.65
Adj.Close	0	0	NA	44.29
Volume	48	3.825	19793278	6925364
rentabilidad	58	4.622	0.002836	-0.0004683
rent_porcent	58	4.622	0.2836	-0.04683

without_mean
49.66
49.98
49.36
49.65
44.29
6413632
-0.0006286
-0.06286

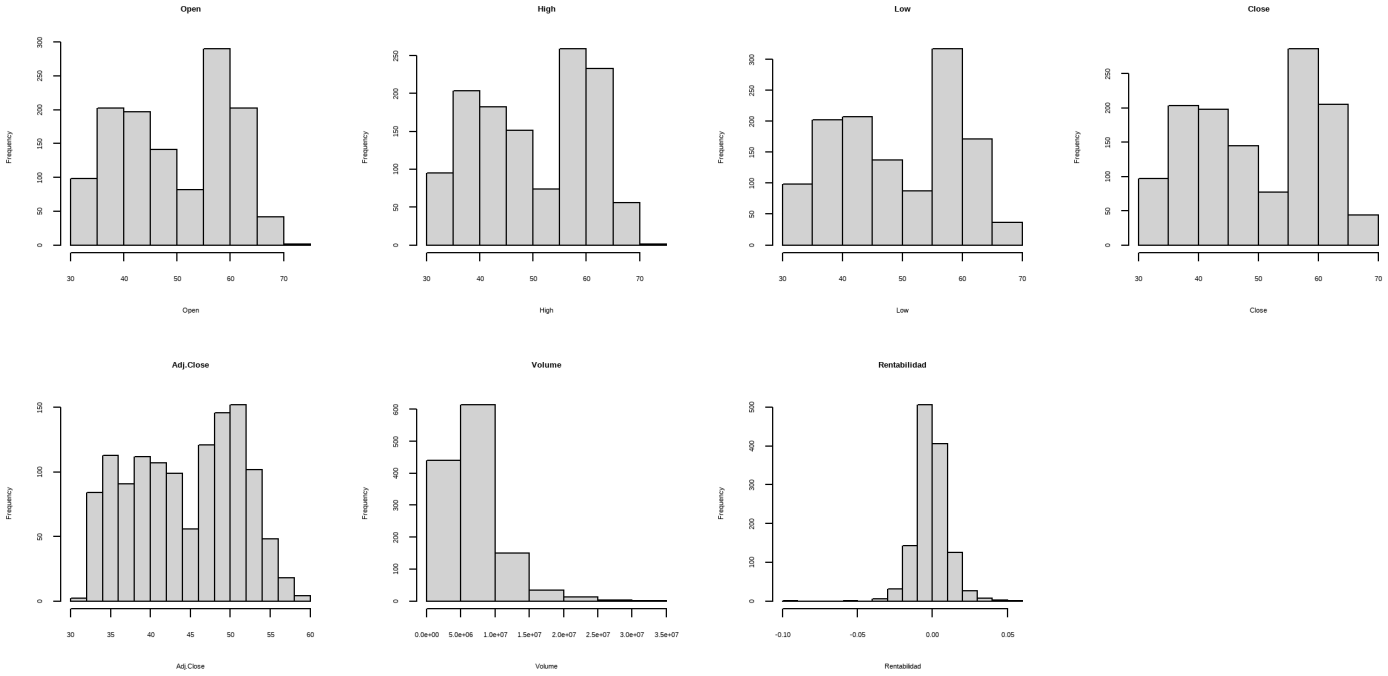
```
hist(sh$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(sh$Open, main = "Open", xlab = "Open")
hist(sh$High, main = "High", xlab = "High")
hist(sh$Low, main = "Low", xlab = "Low")
hist(sh$Close, main = "Close", xlab = "Close")
hist(sh$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(sh$Volume, main = "Volume", xlab = "Volume")
hist(sh$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



Short Nasdaq-100 (PSQ)

```
psq <- read.csv("datos_csv/PSQ.csv")
pander::pander(head(psq,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	57.35	57.55	57.2	57.25	47.67	758000
2021-09-08	57.35	57.85	57.35	57.5	47.88	1201240
2021-09-09	57.4	57.75	57.25	57.7	48.05	645340
2021-09-10	57.45	58.2	57.3	58.15	48.42	923940
2021-09-13	57.75	58.5	57.65	58.15	48.42	1014260
2021-09-14	57.95	58.5	57.8	58.35	48.59	1028600
2021-09-15	58.3	58.6	57.8	57.9	48.21	940660
2021-09-16	58.05	58.4	57.75	57.85	48.17	831940
2021-09-17	57.9	58.7	57.9	58.45	48.67	1435900
2021-09-20	59.5	60.5	59.15	59.7	49.71	2765040

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
psq <- psq |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
psq <- psq |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(psq))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1255
Open	numeric	0	0	906
High	numeric	0	0	900
Low	numeric	0	0	894
Close	numeric	0	0	888
Adj.Close	numeric	0	0	1029
Volume	integer	0	0	1251
rentabilidad	numeric	1	0.07968	1215
rent_porcent	numeric	1	0.07968	1203

unique_rate
1
0.7219
0.7171
0.7124
0.7076
0.8199
0.9968
0.9681
0.9586

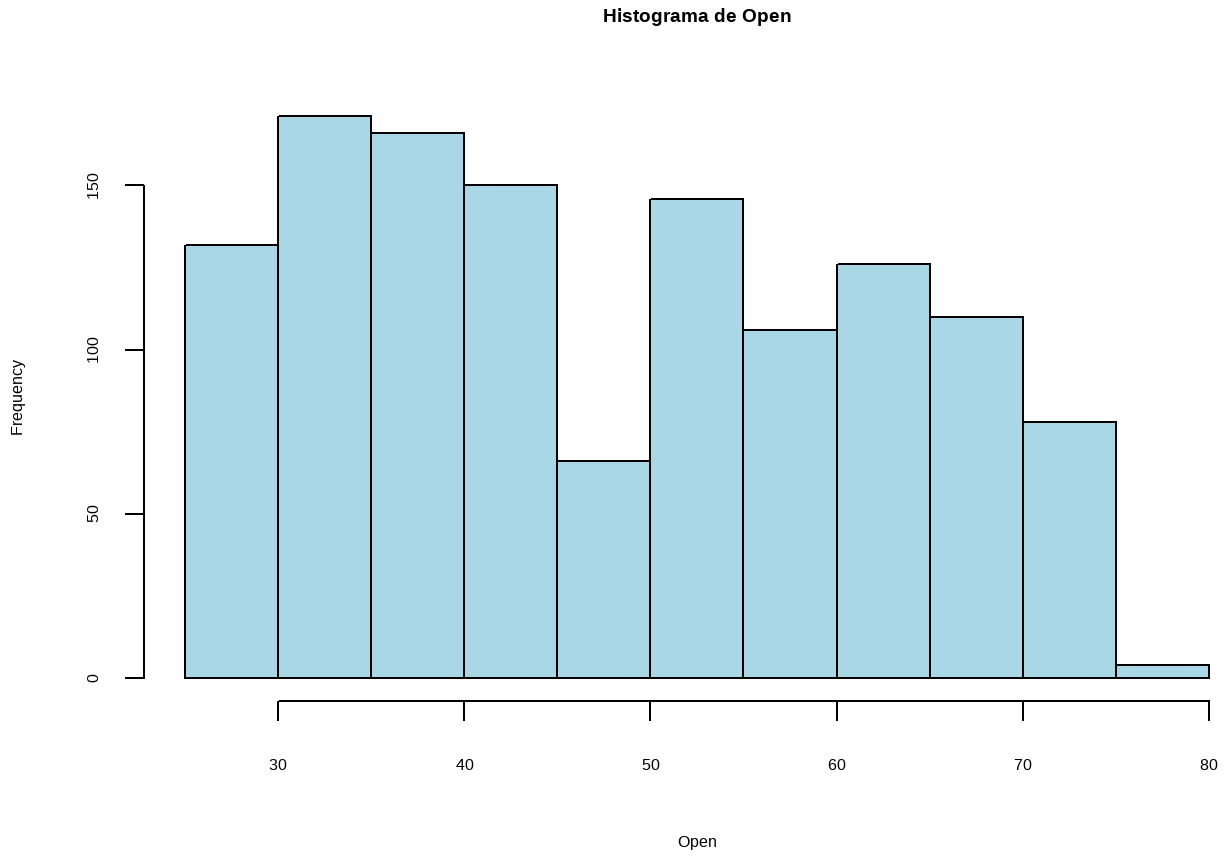
```
pander(diagnose_outlier(psq))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	0	0	NA	47.59
High	0	0	NA	48.01
Low	0	0	NA	47.19
Close	0	0	NA	47.57
Adj.Close	0	0	NA	41.86
Volume	52	4.143	15765908	5771174
rentabilidad	43	3.426	0.005253	-0.0006365
rent_porcent	43	3.426	0.5253	-0.06365

without_mean
47.59
48.01
47.19
47.57
41.86
5339149
-0.0008456
-0.08456

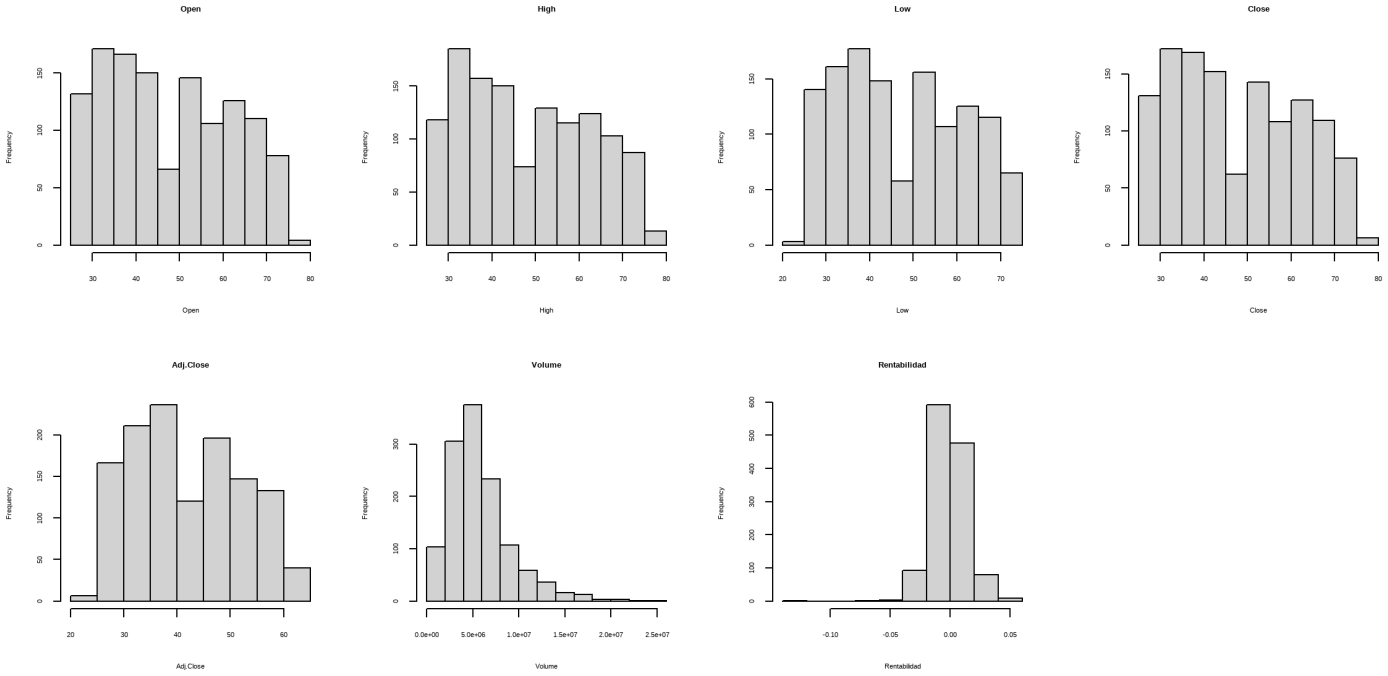
```
hist(psq$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(psq$Open, main = "Open", xlab = "Open")
hist(psq$High, main = "High", xlab = "High")
hist(psq$Low, main = "Low", xlab = "Low")
hist(psq$Close, main = "Close", xlab = "Close")
hist(psq$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(psq$Volume, main = "Volume", xlab = "Volume")
hist(psq$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



UltraShort oro (GLL)

```
gll <- read.csv("datos_csv/GLL.csv")
pander::pander(head(gll,10))
```

Date	Open	High	Low	Close	Adj.Close	Volume
2021-09-07	131.2	134	131	134	134	21525
2021-09-08	133.6	135.7	133.5	134.6	134.6	56075
2021-09-09	133.2	135.5	133.1	133.6	133.6	25725
2021-09-10	133.8	135	133.6	135	135	6725
2021-09-13	134.4	134.5	133.4	134.1	134.1	15400
2021-09-14	133.2	134.2	131.7	132.1	132.1	23025
2021-09-15	133.2	134.2	133.1	133.9	133.9	5225
2021-09-16	139.4	141.4	139.4	140	140	27325
2021-09-17	140.4	141.1	139.8	140.5	140.5	11775
2021-09-20	139.7	139.9	137.8	138.4	138.4	21750

creamos la rentabilidad del periodo calculada como:

$$rentabilidad = Ln\left(\frac{C_t}{C_{t-1}}\right)$$

```
gll <- gll |>
  mutate(
    rentabilidad = log(Close / lag(Close))
  )
gll <- gll |>
  mutate(
    rent_porcent = round(rentabilidad*100,4)
  )
```

posteriormente de este analisis vamos a realizar el analisis exploratorio de la base.

```
pander(diagnose(gll))
```

Table continues below

variables	types	missing_count	missing_percent	unique_count
Date	character	0	0	1255
Open	numeric	0	0	1011
High	numeric	0	0	1026
Low	numeric	0	0	1015
Close	numeric	0	0	1020
Adj.Close	numeric	0	0	1020
Volume	integer	0	0	1089
rentabilidad	numeric	1	0.07968	1238
rent_porcent	numeric	1	0.07968	1224

unique_rate
1
0.8056
0.8175
0.8088
0.8127
0.8127
0.8677
0.9865
0.9753

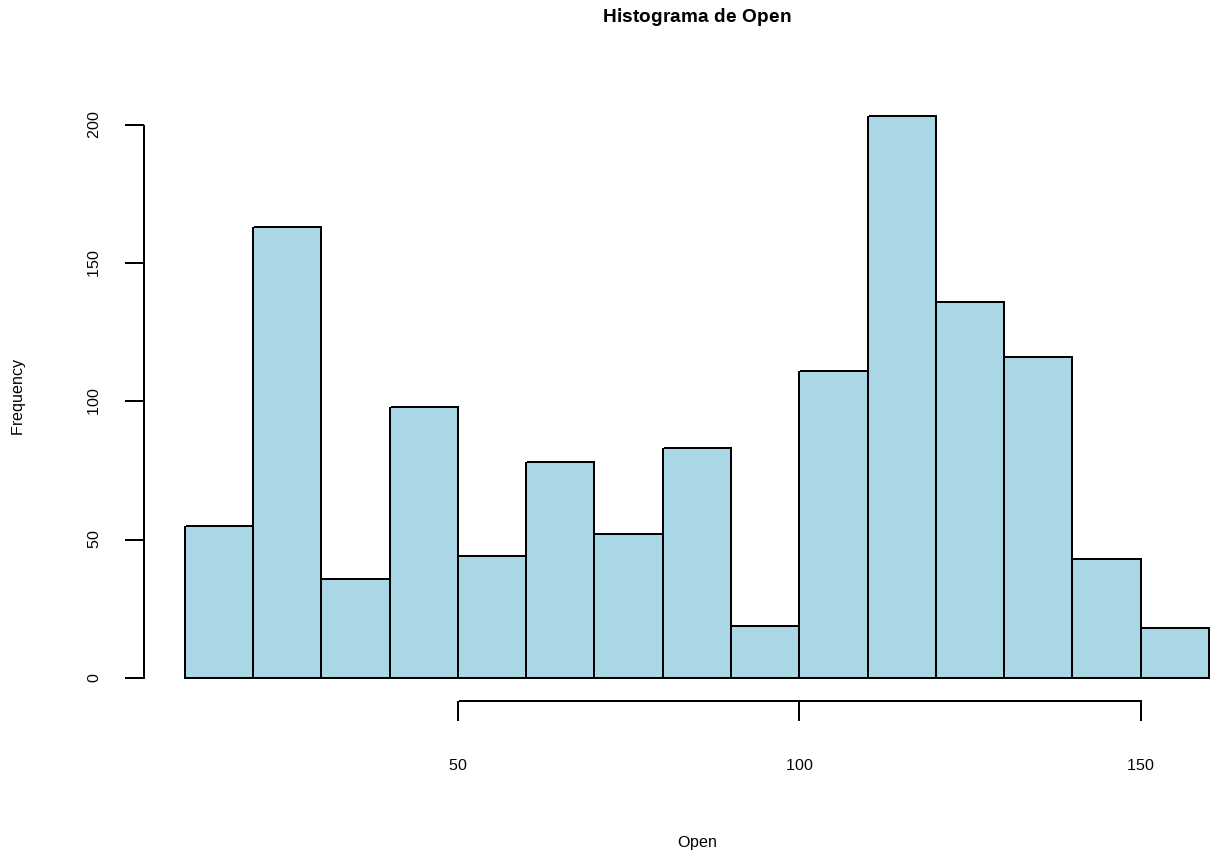
```
pander(diagnose_outlier(gll))
```

Table continues below

variables	outliers_cnt	outliers_ratio	outliers_mean	with_mean
Open	0	0	NA	85.61
High	0	0	NA	86.34
Low	0	0	NA	84.87
Close	0	0	NA	85.58
Adj.Close	0	0	NA	85.58
Volume	241	19.2	4463314	924524
rentabilidad	54	4.303	0.001363	-0.001446
rent_porcent	54	4.303	0.1363	-0.1446

without_mean
85.61
86.34
84.87
85.58
85.58
83451
-0.001572
-0.1572

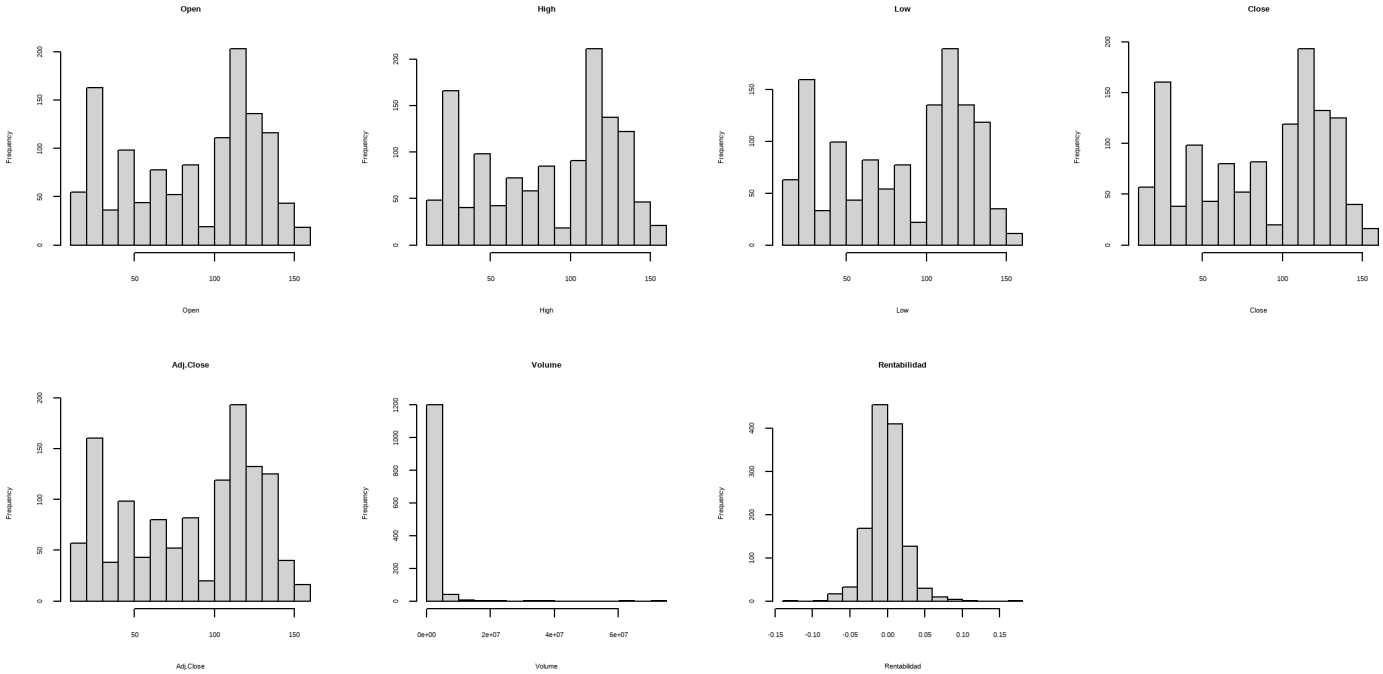
```
hist(gll$Open,
     main = "Histograma de Open",
     xlab = "Open",
     col = "lightblue",
     border = "black")
```




```
par(mfrow = c(2, 4))

hist(gll$Open, main = "Open", xlab = "Open")
hist(gll$High, main = "High", xlab = "High")
hist(gll$Low, main = "Low", xlab = "Low")
hist(gll$Close, main = "Close", xlab = "Close")
hist(gll$Adj.Close, main = "Adj.Close", xlab = "Adj.Close")
hist(gll$Volume, main = "Volume", xlab = "Volume")
hist(gll$rentabilidad, main = "Rentabilidad", xlab = "Rentabilidad")

par(mfrow = c(1, 1))
```



8. Correlación entre los activos

Terminado el diagnóstico individual, se consolidan las rentabilidades logarítmicas de los veintiún activos para estudiar cómo se mueven unos respecto de otros.

Conforme a lo declarado en el apartado 6, las series se cruzan por fecha, se conservan las jornadas en que los veintiún activos tienen precio y los rendimientos se calculan sobre esos precios alineados. El número de rendimientos que resulta es el tamaño efectivo de la muestra sobre la que se calculan todos los coeficientes de este apartado y del siguiente. El vector `clases` agrupa los activos en los ocho estratos del diseño y se utiliza en los gráficos.

```
activos <- list(
  "Tesla"                = tesla,
  "Google"               = google,
  "Microsoft"            = microsoft,
  "Petroleo WTI"         = petroleo,
  "Gas natural"          = gas,
  "Oro"                  = oro,
  "Diamante (proxy)"     = diamante,
  "S&P 500"              = sp500,
  "STOXX Europe 600"     = stoxx,
  "Nasdaq 100 (QQQ)"     = qqq,
  "Plata"                = plata,
  "Cobre"                = cobre,
  "Bonos Tesoro 20+"     = tlt,
  "Indice dolar"         = dolar,
  "Euro (FXE)"           = euro,
  "Bitcoin"              = btc,
  "Ethereum"             = eth,
  "VIX"                  = vix,
  "Short S&P 500 (SH)"   = sh,
  "Short Nasdaq (PSQ)"   = psq,
  "UltraShort Oro (GLL)" = gll
)

clases <- c(
  "Tesla"                = "Acciones",
  "Google"               = "Acciones",
  "Microsoft"            = "Acciones",
  "Diamante (proxy)"     = "Acciones",
  "S&P 500"              = "Indices",
  "STOXX Europe 600"     = "Indices",
  "Nasdaq 100 (QQQ)"     = "Indices",
  "Petroleo WTI"         = "Materias primas",
  "Gas natural"          = "Materias primas",
  "Oro"                  = "Materias primas",
  "Plata"                = "Materias primas",
  "Cobre"                = "Materias primas",
  "Bonos Tesoro 20+"     = "Renta fija",
  "Indice dolar"         = "Divisas",
  "Euro (FXE)"           = "Divisas",
  "Bitcoin"              = "Criptoactivos",
  "Ethereum"             = "Criptoactivos",
  "VIX"                  = "Volatilidad",
  "Short S&P 500 (SH)"   = "Inversos",
  "Short Nasdaq (PSQ)"   = "Inversos",
  "UltraShort Oro (GLL)" = "Inversos"
)

precios <- map_dfr(names(activos), function(nombre) {
  data.frame(
    Date   = as.Date(activos[[nombre]]$Date),
    Activo = nombre,
```

```
    Close  = activos[[nombre]]$Close
  )
}) |>
  pivot_wider(names_from = Activo, values_from = Close) |>
  arrange(Date)

comunes <- precios[complete.cases(precios[ , names(activos)]), ]

X      <- apply(as.matrix(comunes[ , names(activos)]), 2, function(p) diff(log(p)))
fechas <- comunes$Date[-1]

pander(data.frame(
  Fechas_totales  = nrow(precios),
  Precios_comunes = nrow(comunes),
  Rendimientos    = nrow(X),
  Desde           = format(min(fechas)),
  Hasta           = format(max(fechas))
))
```

Fechas_totales	Precios_comunes	Rendimientos	Desde	Hasta
1827	1223	1222	2021-09-08	2026-09-04

Cierres asíncronos

Antes de calcular las correlaciones conviene medir el efecto de las distintas horas de cierre. La tabla compara la correlación de tres activos con el rendimiento del S&P 500 del mismo día y con el del día anterior.

```
retardo <- map_dfr(c("STOXX Europe 600", "Bitcoin", "Ethereum"), function(nombre) {
  hoy <- X[-1, nombre]
  data.frame(
    Activo             = nombre,
    SP500_mismo_dia    = round(cor(hoy, X[-1, "S&P 500"], method = "spearman"), 3),
    SP500_dia_anterior = round(cor(hoy, X[-nrow(X), "S&P 500"], method = "spearman"), 3)
  )
})

pander(retardo)
```

Activo	SP500_mismo_dia	SP500_dia_anterior
STOXX Europe 600	0.487	0.189
Bitcoin	0.396	-0.092
Ethereum	0.411	-0.053

El STOXX Europe 600 conserva una correlación de 0,189 con el S&P 500 del día anterior: parte de lo que ocurre en la tarde estadounidense se incorpora al índice europeo en la sesión siguiente, por lo que sus coeficientes contemporáneos subestiman el vínculo real entre ambos mercados. En los criptoactivos la correlación con el día

anterior es prácticamente nula (−0,092 en bitcoin y −0,053 en ethereum), porque cierran después que la bolsa estadounidense y ya incorporan lo ocurrido en ella.

Correlación de Spearman

Se utiliza el coeficiente de Spearman porque trabaja sobre rangos y no sobre los valores originales, lo que lo hace robusto frente a los valores extremos que el `diagnose_outlier` detectó en todos los activos.

```
spearman <- cor(X, method = "spearman")
pander(round(spearman, 3))
```

Table continues below

	Tesla	Google	Microsoft	Petroleo WTI
Tesla	1	0.433	0.409	0.011
Google	0.433	1	0.602	0.002
Microsoft	0.409	0.602	1	0.01
Petroleo WTI	0.011	0.002	0.01	1
Gas natural	0.032	0.031	0.041	0.095
Oro	0.04	0.094	0.022	0.091
Diamante (proxy)	0.284	0.267	0.199	0.125
S&P 500	0.586	0.674	0.706	0.019
STOXX Europe 600	0.265	0.266	0.275	0.019
Nasdaq 100 (QQQ)	0.639	0.708	0.738	-0.002
Plata	0.124	0.164	0.112	0.119
Cobre	0.188	0.17	0.132	0.193
Bonos Tesoro 20+	0.031	0.05	0.037	-0.195
Indice dolar	-0.154	-0.182	-0.143	-0.002
Euro (FXE)	0.156	0.186	0.163	-0.006
Bitcoin	0.36	0.308	0.302	0.032
Ethereum	0.362	0.329	0.312	0.023
VIX	-0.473	-0.495	-0.514	-0.009
Short S&P 500 (SH)	-0.577	-0.667	-0.695	-0.022
Short Nasdaq (PSQ)	-0.636	-0.7	-0.731	0.004
UltraShort Oro (GLL)	-0.061	-0.119	-0.049	-0.116

Table continues below

	Gas natural	Oro	Diamante (proxy)	S&P 500
Tesla	0.032	0.04	0.284	0.586
Google	0.031	0.094	0.267	0.674
Microsoft	0.041	0.022	0.199	0.706
Petroleo WTI	0.095	0.091	0.125	0.019
Gas natural	1	0.025	0.023	0.057
Oro	0.025	1	0.351	0.098
Diamante (proxy)	0.023	0.351	1	0.426
S&P 500	0.057	0.098	0.426	1
STOXX Europe 600	0.012	0.172	0.423	0.488
Nasdaq 100 (QQQ)	0.039	0.085	0.378	0.938
Plata	0.007	0.753	0.439	0.188
Cobre	-0.006	0.411	0.571	0.272
Bonos Tesoro 20+	-0.024	0.184	0.051	0.093
Indice dolar	-0.005	-0.415	-0.385	-0.274
Euro (FXE)	0.004	0.337	0.347	0.285
Bitcoin	0.003	0.113	0.254	0.396
Ethereum	0.004	0.097	0.252	0.411
VIX	-0.038	-0.056	-0.374	-0.759
Short S&P 500 (SH)	-0.056	-0.091	-0.423	-0.986
Short Nasdaq (PSQ)	-0.039	-0.075	-0.376	-0.932
UltraShort Oro (GLL)	-0.026	-0.903	-0.36	-0.139

Table continues below

	STOXX Europe 600	Nasdaq 100 (QQQ)	Plata
Tesla	0.265	0.639	0.124
Google	0.266	0.708	0.164
Microsoft	0.275	0.738	0.112
Petroleo WTI	0.019	-0.002	0.119
Gas natural	0.012	0.039	0.007

	STOXX Europe 600	Nasdaq 100 (QQQ)	Plata
Oro	0.172	0.085	0.753
Diamante (proxy)	0.423	0.378	0.439
S&P 500	0.488	0.938	0.188
STOXX Europe 600	1	0.415	0.27
Nasdaq 100 (QQQ)	0.415	1	0.181
Plata	0.27	0.181	1
Cobre	0.345	0.253	0.511
Bonos Tesoro 20+	0.06	0.077	0.096
Indice dolar	-0.231	-0.233	-0.373
Euro (FXE)	0.188	0.248	0.318
Bitcoin	0.204	0.402	0.162
Ethereum	0.232	0.419	0.143
VIX	-0.419	-0.698	-0.139
Short S&P 500 (SH)	-0.482	-0.925	-0.189
Short Nasdaq (PSQ)	-0.411	-0.991	-0.174
UltraShort Oro (GLL)	-0.141	-0.119	-0.694

Table continues below

	Cobre	Bonos Tesoro 20+	Indice dolar
Tesla	0.188	0.031	-0.154
Google	0.17	0.05	-0.182
Microsoft	0.132	0.037	-0.143
Petroleo WTI	0.193	-0.195	-0.002
Gas natural	-0.006	-0.024	-0.005
Oro	0.411	0.184	-0.415
Diamante (proxy)	0.571	0.051	-0.385
S&P 500	0.272	0.093	-0.274
STOXX Europe 600	0.345	0.06	-0.231
Nasdaq 100 (QQQ)	0.253	0.077	-0.233
Plata	0.511	0.096	-0.373

	Cobre	Bonos Tesoro 20+	Indice dolar
Cobre	1	0.022	-0.361
Bonos Tesoro 20+	0.022	1	-0.256
Indice dolar	-0.361	-0.256	1
Euro (FXE)	0.315	0.204	-0.939
Bitcoin	0.186	-0.009	-0.195
Ethereum	0.197	-0.008	-0.193
VIX	-0.234	-0.055	0.215
Short S&P 500 (SH)	-0.274	-0.094	0.268
Short Nasdaq (PSQ)	-0.253	-0.075	0.226
UltraShort Oro (GLL)	-0.378	-0.227	0.441

Table continues below

	Euro (FXE)	Bitcoin	Ethereum	VIX
Tesla	0.156	0.36	0.362	-0.473
Google	0.186	0.308	0.329	-0.495
Microsoft	0.163	0.302	0.312	-0.514
Petroleo WTI	-0.006	0.032	0.023	-0.009
Gas natural	0.004	0.003	0.004	-0.038
Oro	0.337	0.113	0.097	-0.056
Diamante (proxy)	0.347	0.254	0.252	-0.374
S&P 500	0.285	0.396	0.411	-0.759
STOXX Europe 600	0.188	0.204	0.232	-0.419
Nasdaq 100 (QQQ)	0.248	0.402	0.419	-0.698
Plata	0.318	0.162	0.143	-0.139
Cobre	0.315	0.186	0.197	-0.234
Bonos Tesoro 20+	0.204	-0.009	-0.008	-0.055
Indice dolar	-0.939	-0.195	-0.193	0.215
Euro (FXE)	1	0.196	0.195	-0.228
Bitcoin	0.196	1	0.837	-0.336
Ethereum	0.195	0.837	1	-0.374

	Euro (FXE)	Bitcoin	Ethereum	VIX
VIX	-0.228	-0.336	-0.374	1
Short S&P 500 (SH)	-0.279	-0.395	-0.404	0.752
Short Nasdaq (PSQ)	-0.242	-0.404	-0.416	0.697
UltraShort Oro (GLL)	-0.388	-0.147	-0.119	0.086

Table continues below

	Short S&P 500 (SH)	Short Nasdaq (PSQ)
Tesla	-0.577	-0.636
Google	-0.667	-0.7
Microsoft	-0.695	-0.731
Petroleo WTI	-0.022	0.004
Gas natural	-0.056	-0.039
Oro	-0.091	-0.075
Diamante (proxy)	-0.423	-0.376
S&P 500	-0.986	-0.932
STOXX Europe 600	-0.482	-0.411
Nasdaq 100 (QQQ)	-0.925	-0.991
Plata	-0.189	-0.174
Cobre	-0.274	-0.253
Bonos Tesoro 20+	-0.094	-0.075
Indice dolar	0.268	0.226
Euro (FXE)	-0.279	-0.242
Bitcoin	-0.395	-0.404
Ethereum	-0.404	-0.416
VIX	0.752	0.697
Short S&P 500 (SH)	1	0.937
Short Nasdaq (PSQ)	0.937	1
UltraShort Oro (GLL)	0.13	0.109

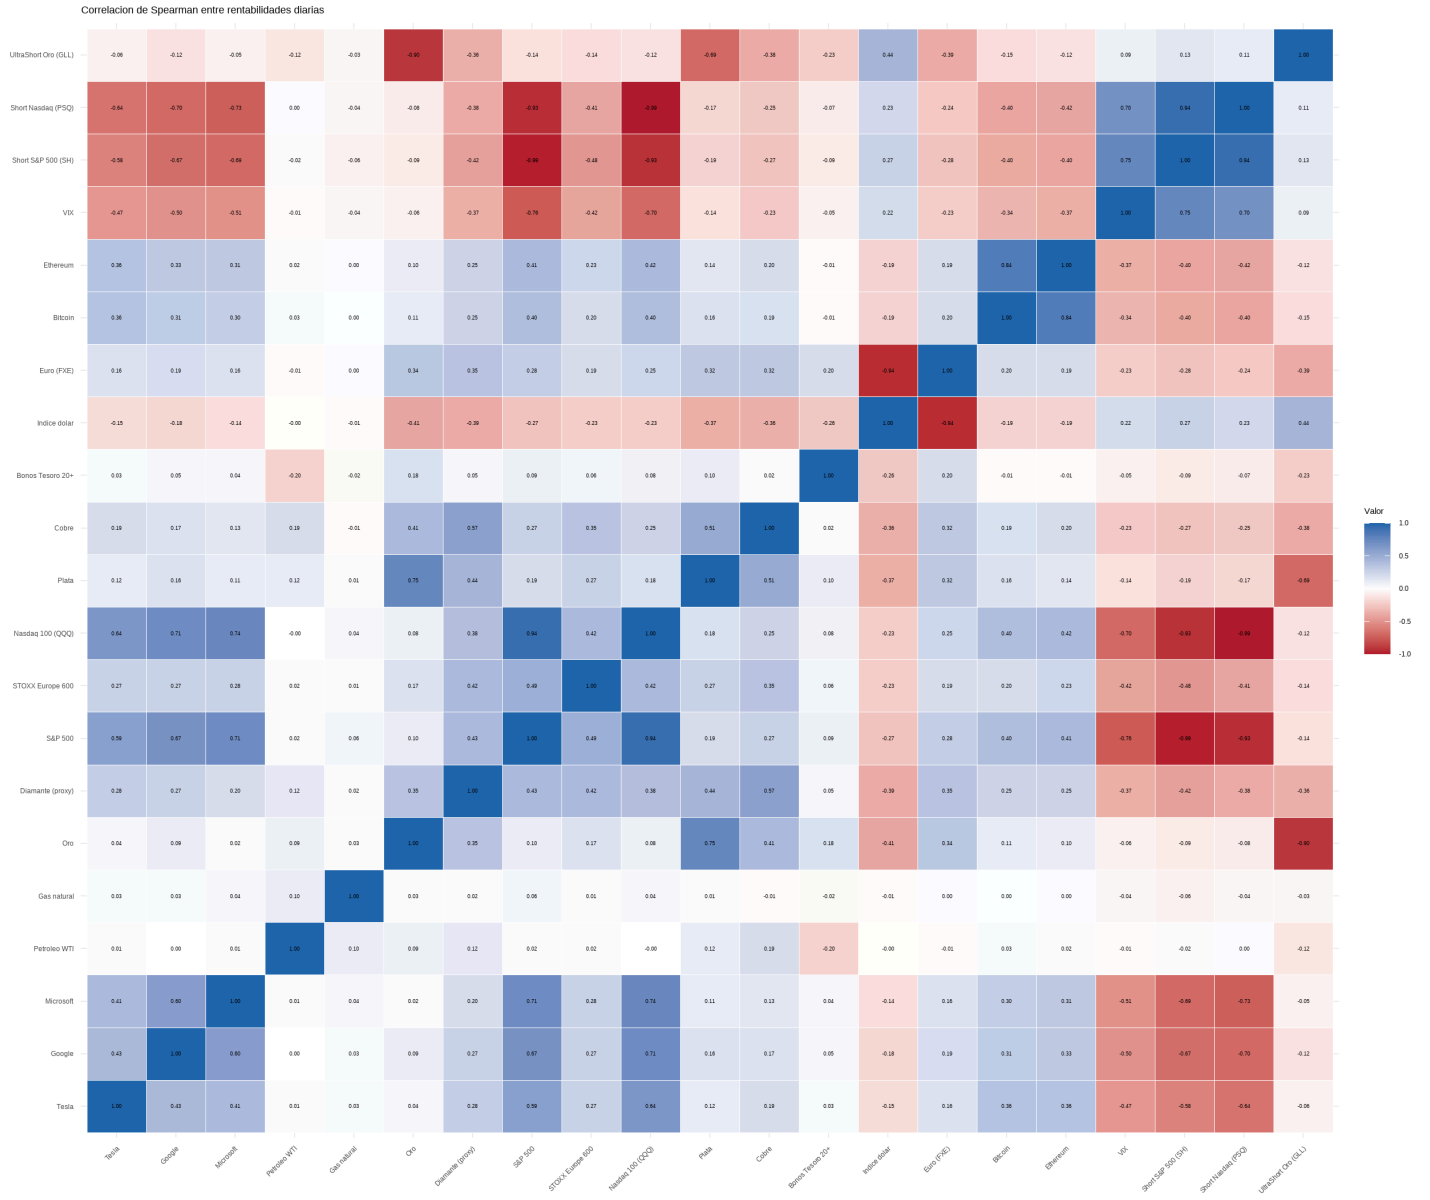
	UltraShort Oro (GLL)
Tesla	-0.061

	UltraShort Oro (GLL)
Google	-0.119
Microsoft	-0.049
Petroleo WTI	-0.116
Gas natural	-0.026
Oro	-0.903
Diamante (proxy)	-0.36
S&P 500	-0.139
STOXX Europe 600	-0.141
Nasdaq 100 (QQQ)	-0.119
Plata	-0.694
Cobre	-0.378
Bonos Tesoro 20+	-0.227
Indice dolar	0.441
Euro (FXE)	-0.388
Bitcoin	-0.147
Ethereum	-0.119
VIX	0.086
Short S&P 500 (SH)	0.13
Short Nasdaq (PSQ)	0.109
UltraShort Oro (GLL)	1

```
mapa_calor <- function(m, titulo) {
  largo <- as.data.frame(as.table(m))
  colnames(largo) <- c("Activo1", "Activo2", "Valor")

  ggplot(largo, aes(Activo1, Activo2, fill = Valor)) +
    geom_tile(color = "white") +
    geom_text(aes(label = sprintf("%.2f", Valor)), size = 2.3) +
    scale_fill_gradient2(low = "#b2182b", mid = "white", high = "#2166ac",
                         midpoint = 0, limits = c(-1, 1)) +
    labs(title = titulo, x = NULL, y = NULL) +
    theme_minimal() +
    theme(axis.text.x = element_text(angle = 45, hjust = 1))
}

mapa_calor(spearman, "Correlacion de Spearman entre rentabilidades diarias")
```



Pares con correlación negativa

Con veintiún activos la matriz contiene 210 pares distintos. La tabla ordena los doce con la correlación más negativa.

```
pares <- which(upper.tri(spearman), arr.ind = TRUE)

todos_los_pares <- data.frame(
  Activo_1 = colnames(spearman)[pares[ , 1]],
  Activo_2 = colnames(spearman)[pares[ , 2]],
  Spearman = round(spearman[pares], 3)
)

todos_los_pares |>
  arrange(Spearman) |>
  head(12) |>
  pander()
```

Activo_1	Activo_2	Spearman
Nasdaq 100 (QQQ)	Short Nasdaq (PSQ)	-0.991
S&P 500	Short S&P 500 (SH)	-0.986
Indice dolar	Euro (FXE)	-0.939
S&P 500	Short Nasdaq (PSQ)	-0.932
Nasdaq 100 (QQQ)	Short S&P 500 (SH)	-0.925
Oro	UltraShort Oro (GLL)	-0.903
S&P 500	VIX	-0.759
Microsoft	Short Nasdaq (PSQ)	-0.731
Google	Short Nasdaq (PSQ)	-0.7
Nasdaq 100 (QQQ)	VIX	-0.698
Microsoft	Short S&P 500 (SH)	-0.695
Plata	UltraShort Oro (GLL)	-0.694

Correlación de distancias

El coeficiente de Spearman solo detecta relaciones monótonas: si dos activos se mueven juntos en magnitud pero sin una dirección consistente, Spearman devuelve un valor cercano a cero. La correlación de distancias resuelve esa limitación, ya que vale cero **si y solo si** las dos variables son independientes, e identifica también dependencias no lineales. Su rango va de 0 a 1 y no toma valores negativos, de modo que una relación inversa perfecta aparece en ella con un valor cercano a 1.

```
k  <- ncol(X)
dc <- matrix(1, k, k, dimnames = list(colnames(X), colnames(X)))

for (i in 1:(k - 1)) {
  for (j in (i + 1):k) {
    valor    <- dcor(X[ , i], X[ , j])
    dc[i, j] <- valor
    dc[j, i] <- valor
  }
}

pander(round(dc, 3))
```

Table continues below

	Tesla	Google	Microsoft	Petroleo WTI
Tesla	1	0.41	0.387	0.05
Google	0.41	1	0.582	0.055

	Tesla	Google	Microsoft	Petroleo WTI
Microsoft	0.387	0.582	1	0.061
Petroleo WTI	0.05	0.055	0.061	1
Gas natural	0.064	0.059	0.071	0.105
Oro	0.066	0.104	0.065	0.11
Diamante (proxy)	0.267	0.258	0.2	0.141
S&P 500	0.559	0.651	0.687	0.089
STOXX Europe 600	0.255	0.259	0.267	0.09
Nasdaq 100 (QQQ)	0.609	0.683	0.716	0.077
Plata	0.128	0.162	0.124	0.128
Cobre	0.181	0.168	0.138	0.194
Bonos Tesoro 20+	0.07	0.071	0.065	0.205
Indice dolar	0.152	0.182	0.153	0.06
Euro (FXE)	0.156	0.185	0.169	0.063
Bitcoin	0.34	0.289	0.295	0.054
Ethereum	0.348	0.311	0.307	0.064
VIX	0.454	0.478	0.497	0.08
Short S&P 500 (SH)	0.55	0.643	0.675	0.09
Short Nasdaq (PSQ)	0.606	0.676	0.709	0.078
UltraShort Oro (GLL)	0.084	0.13	0.086	0.124

Table continues below

	Gas natural	Oro	Diamante (proxy)	S&P 500
Tesla	0.064	0.066	0.267	0.559
Google	0.059	0.104	0.258	0.651
Microsoft	0.071	0.065	0.2	0.687
Petroleo WTI	0.105	0.11	0.141	0.089
Gas natural	1	0.054	0.051	0.077
Oro	0.054	1	0.333	0.109
Diamante (proxy)	0.051	0.333	1	0.409
S&P 500	0.077	0.109	0.409	1

	Gas natural	Oro	Diamante (proxy)	S&P 500
STOXX Europe 600	0.06	0.176	0.404	0.469
Nasdaq 100 (QQQ)	0.064	0.097	0.365	0.925
Plata	0.051	0.725	0.421	0.188
Cobre	0.048	0.389	0.544	0.26
Bonos Tesoro 20+	0.06	0.175	0.075	0.12
Indice dolar	0.06	0.389	0.37	0.27
Euro (FXE)	0.053	0.317	0.333	0.28
Bitcoin	0.057	0.117	0.24	0.378
Ethereum	0.057	0.106	0.239	0.396
VIX	0.058	0.087	0.363	0.743
Short S&P 500 (SH)	0.076	0.105	0.405	0.986
Short Nasdaq (PSQ)	0.064	0.091	0.362	0.918
UltraShort Oro (GLL)	0.053	0.888	0.349	0.151

Table continues below

	STOXX Europe 600	Nasdaq 100 (QQQ)	Plata	Cobre
Tesla	0.255	0.609	0.128	0.181
Google	0.259	0.683	0.162	0.168
Microsoft	0.267	0.716	0.124	0.138
Petroleo WTI	0.09	0.077	0.128	0.194
Gas natural	0.06	0.064	0.051	0.048
Oro	0.176	0.097	0.725	0.389
Diamante (proxy)	0.404	0.365	0.421	0.544
S&P 500	0.469	0.925	0.188	0.26
STOXX Europe 600	1	0.399	0.261	0.331
Nasdaq 100 (QQQ)	0.399	1	0.184	0.241
Plata	0.261	0.184	1	0.49
Cobre	0.331	0.241	0.49	1
Bonos Tesoro 20+	0.089	0.103	0.098	0.055
Indice dolar	0.228	0.232	0.346	0.339

	STOXX Europe 600	Nasdaq 100 (QQQ)	Plata	Cobre
Euro (FXE)	0.191	0.244	0.297	0.3
Bitcoin	0.201	0.383	0.156	0.175
Ethereum	0.228	0.402	0.141	0.188
VIX	0.406	0.681	0.146	0.231
Short S&P 500 (SH)	0.464	0.911	0.187	0.261
Short Nasdaq (PSQ)	0.395	0.99	0.177	0.241
UltraShort Oro (GLL)	0.149	0.135	0.665	0.363

Table continues below

	Bonos Tesoro 20+	Indice dolar	Euro (FXE)
Tesla	0.07	0.152	0.156
Google	0.071	0.182	0.185
Microsoft	0.065	0.153	0.169
Petroleo WTI	0.205	0.06	0.063
Gas natural	0.06	0.06	0.053
Oro	0.175	0.389	0.317
Diamante (proxy)	0.075	0.37	0.333
S&P 500	0.12	0.27	0.28
STOXX Europe 600	0.089	0.228	0.191
Nasdaq 100 (QQQ)	0.103	0.232	0.244
Plata	0.098	0.346	0.297
Cobre	0.055	0.339	0.3
Bonos Tesoro 20+	1	0.249	0.205
Indice dolar	0.249	1	0.925
Euro (FXE)	0.205	0.925	1
Bitcoin	0.054	0.184	0.188
Ethereum	0.053	0.185	0.191
VIX	0.087	0.208	0.218
Short S&P 500 (SH)	0.12	0.265	0.275
Short Nasdaq (PSQ)	0.101	0.227	0.241

	Bonos Tesoro 20+	Indice dolar	Euro (FXE)
UltraShort Oro (GLL)	0.213	0.414	0.366

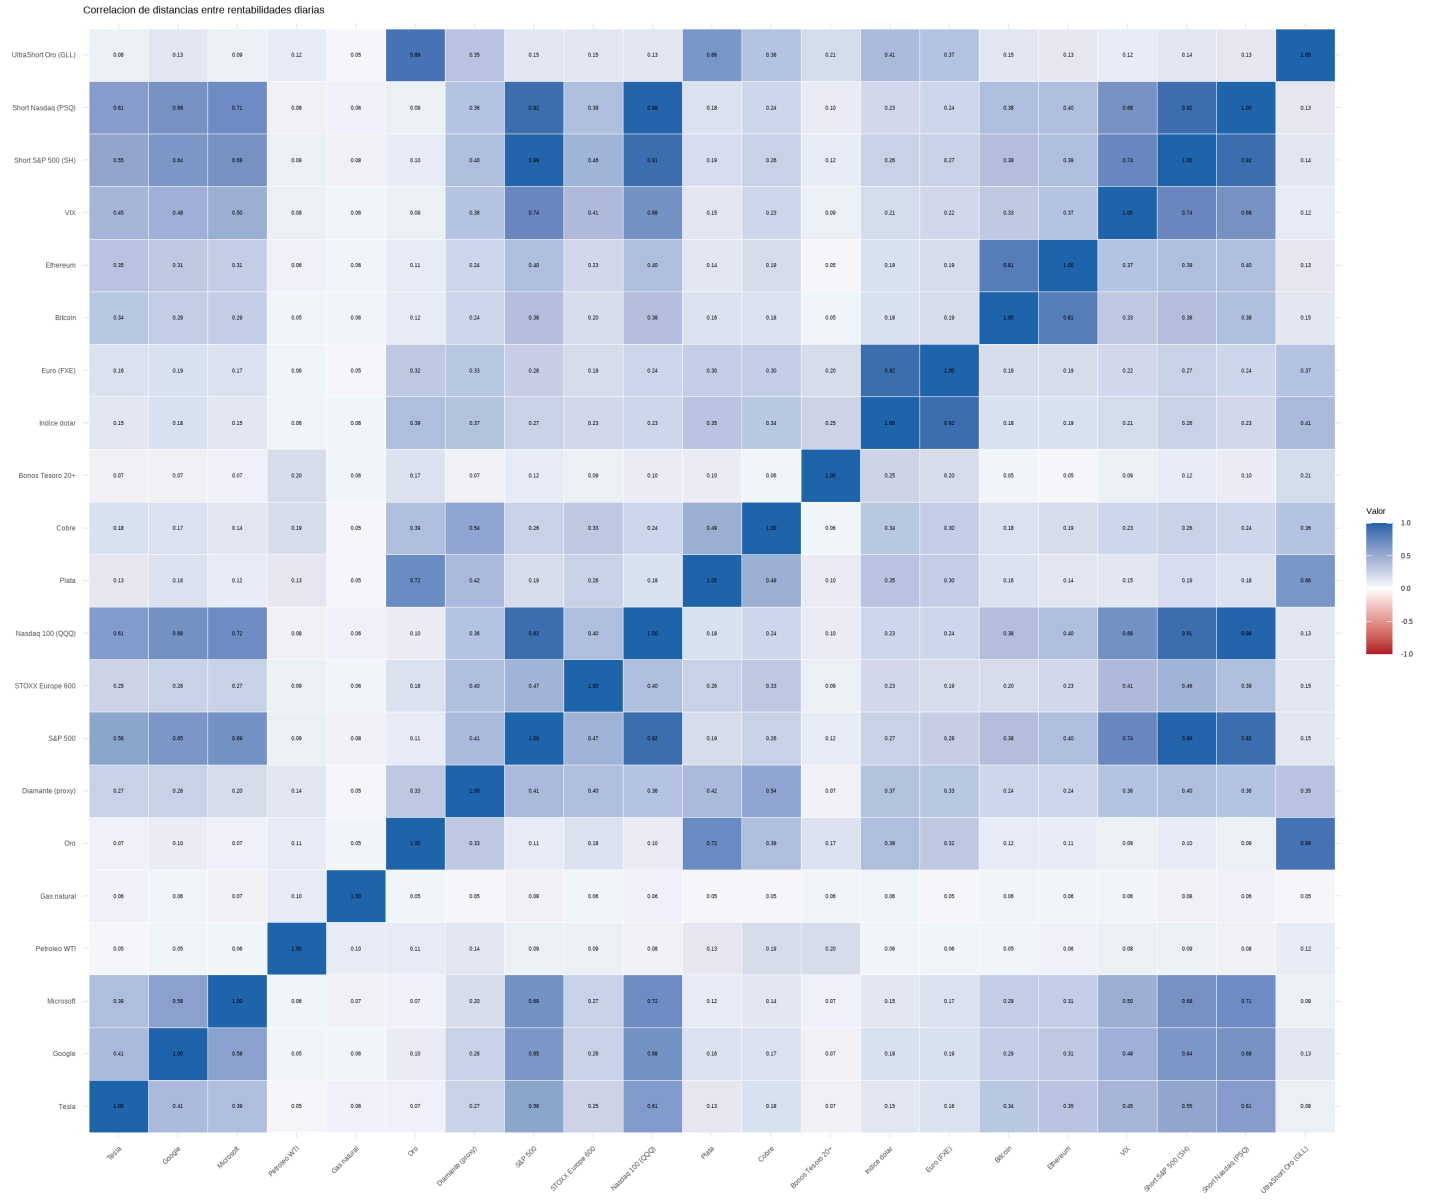
Table continues below

	Bitcoin	Ethereum	VIX	Short S&P 500 (SH)
Tesla	0.34	0.348	0.454	0.55
Google	0.289	0.311	0.478	0.643
Microsoft	0.295	0.307	0.497	0.675
Petroleo WTI	0.054	0.064	0.08	0.09
Gas natural	0.057	0.057	0.058	0.076
Oro	0.117	0.106	0.087	0.105
Diamante (proxy)	0.24	0.239	0.363	0.405
S&P 500	0.378	0.396	0.743	0.986
STOXX Europe 600	0.201	0.228	0.406	0.464
Nasdaq 100 (QQQ)	0.383	0.402	0.681	0.911
Plata	0.156	0.141	0.146	0.187
Cobre	0.175	0.188	0.231	0.261
Bonos Tesoro 20+	0.054	0.053	0.087	0.12
Indice dolar	0.184	0.185	0.208	0.265
Euro (FXE)	0.188	0.191	0.218	0.275
Bitcoin	1	0.814	0.327	0.378
Ethereum	0.814	1	0.368	0.391
VIX	0.327	0.368	1	0.736
Short S&P 500 (SH)	0.378	0.391	0.736	1
Short Nasdaq (PSQ)	0.384	0.399	0.678	0.923
UltraShort Oro (GLL)	0.145	0.127	0.119	0.145

	Short Nasdaq (PSQ)	UltraShort Oro (GLL)
Tesla	0.606	0.084
Google	0.676	0.13
Microsoft	0.709	0.086
Petroleo WTI	0.078	0.124

	Short Nasdaq (PSQ)	UltraShort Oro (GLL)
Gas natural	0.064	0.053
Oro	0.091	0.888
Diamante (proxy)	0.362	0.349
S&P 500	0.918	0.151
STOXX Europe 600	0.395	0.149
Nasdaq 100 (QQQ)	0.99	0.135
Plata	0.177	0.665
Cobre	0.241	0.363
Bonos Tesoro 20+	0.101	0.213
Indice dolar	0.227	0.414
Euro (FXE)	0.241	0.366
Bitcoin	0.384	0.145
Ethereum	0.399	0.127
VIX	0.678	0.119
Short S&P 500 (SH)	0.923	0.145
Short Nasdaq (PSQ)	1	0.129
UltraShort Oro (GLL)	0.129	1

```
mapa_calor(dc, "Correlacion de distancias entre rentabilidades diarias")
```



Spearman frente a correlación de distancias

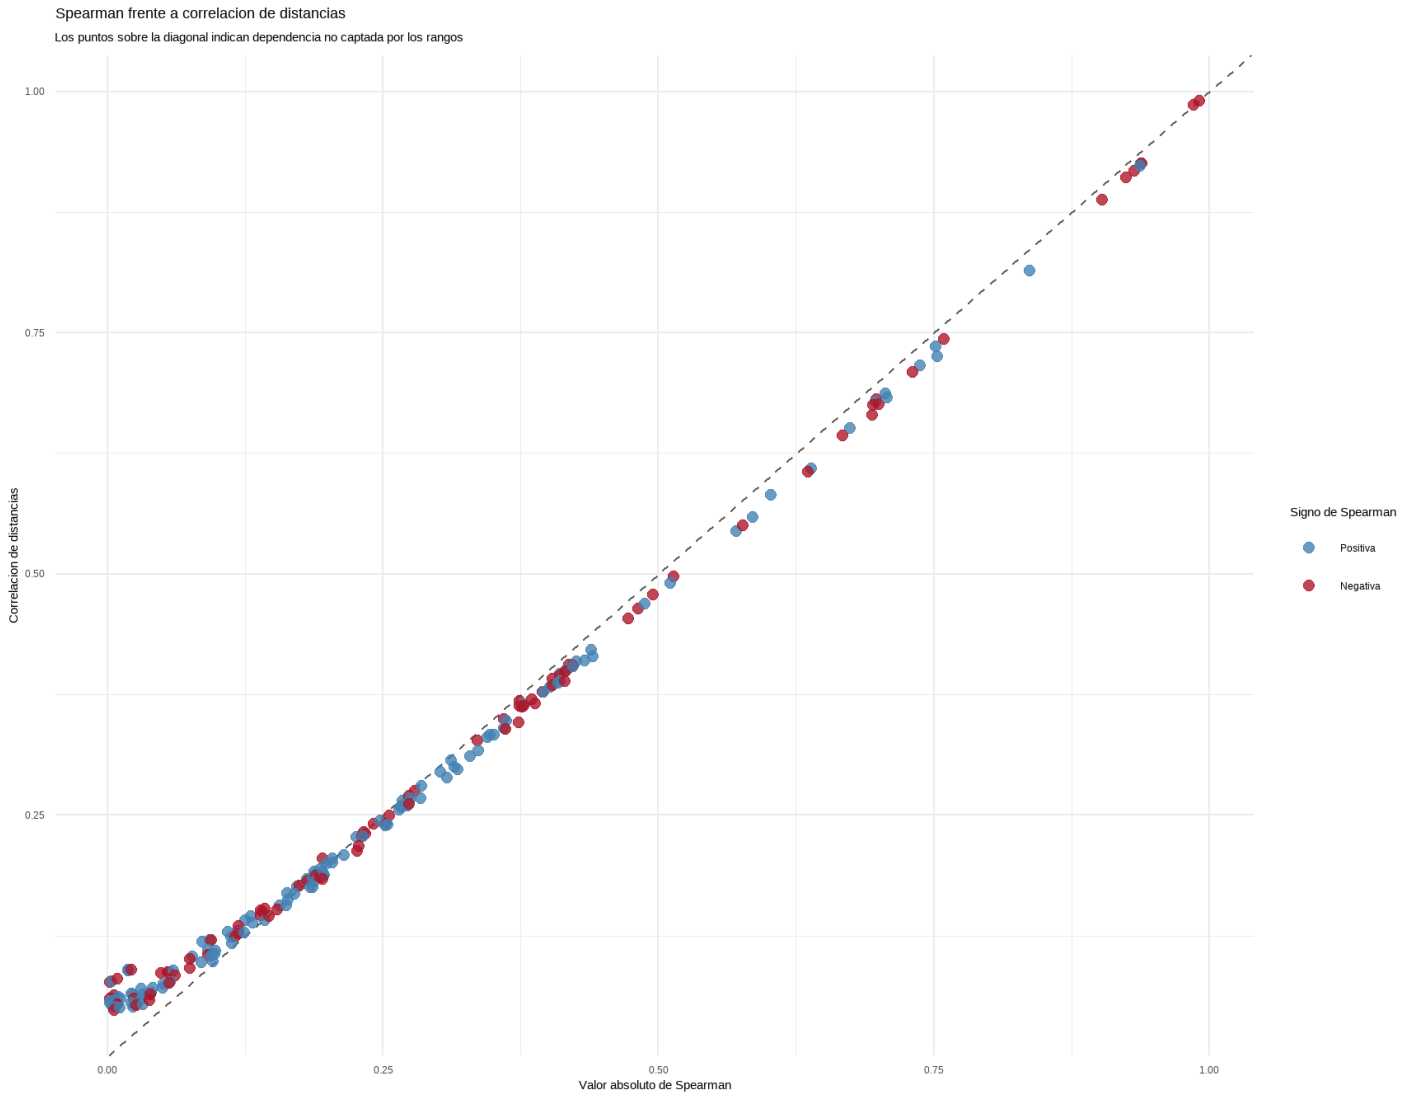
Comparar ambos coeficientes permite detectar pares de activos con dependencia no monótona: si la correlación de distancias es claramente mayor que el valor absoluto de Spearman, existe una relación que el coeficiente de rangos no captura.

```
comparacion <- data.frame(
  Activo_1  = colnames(spearman)[pares[ , 1]],
  Activo_2  = colnames(spearman)[pares[ , 2]],
  Spearman  = round(spearman[pares], 3),
  Distancia = round(dc[pares], 3)
) |>
  mutate(Diferencia = round(Distancia - abs(Spearman), 3)) |>
  arrange(desc(Diferencia))

pander(head(comparacion, 12))
```

Activo_1	Activo_2	Spearman	Distancia	Diferencia
Petroleo WTI	Nasdaq 100 (QQQ)	-0.002	0.077	0.075
Petroleo WTI	Short Nasdaq (PSQ)	0.004	0.078	0.074
Petroleo WTI	STOXX Europe 600	0.019	0.09	0.071
Petroleo WTI	VIX	-0.009	0.08	0.071
Petroleo WTI	S&P 500	0.019	0.089	0.07
Petroleo WTI	Short S&P 500 (SH)	-0.022	0.09	0.068
Petroleo WTI	Indice dolar	-0.002	0.06	0.058
Petroleo WTI	Euro (FXE)	-0.006	0.063	0.057
Gas natural	Indice dolar	-0.005	0.06	0.055
Gas natural	Bitcoin	0.003	0.057	0.054
Google	Petroleo WTI	0.002	0.055	0.053
Gas natural	Ethereum	0.004	0.057	0.053

```
ggplot(comparacion, aes(x = abs(Spearman), y = Distancia, color = Spearman < 0)) +
  geom_abline(slope = 1, intercept = 0, linetype = "dashed", color = "grey40") +
  geom_point(size = 2.2, alpha = 0.8) +
  scale_color_manual(values = c("FALSE" = "steelblue", "TRUE" = "#b2182b"),
                     labels = c("Positiva", "Negativa"),
                     name   = "Signo de Spearman") +
  labs(
    title    = "Spearman frente a correlacion de distancias",
    subtitle = "Los puntos sobre la diagonal indican dependencia no captada por los rangos",
    x        = "Valor absoluto de Spearman",
    y        = "Correlacion de distancias"
  ) +
  theme_minimal()
```



Sesgo de la correlación de distancias

El estimador muestral de la correlación de distancias no vale cero cuando dos variables son independientes: tiene un sesgo positivo que depende del tamaño de la muestra y de la forma de las distribuciones. Para saber a partir de qué valor el coeficiente refleja dependencia real se construye una línea base: se permuta al azar el orden de una de las series, lo que rompe cualquier relación con la otra, y se recalcula el coeficiente cien veces. La línea base se construye sobre el par petróleo y S&P 500, por lo que funciona como una aproximación para el resto de los pares.

```
set.seed(123)
linea_base <- replicate(100, dcor(X[ , "Petroleo WTI"], sample(X[ , "S&P 500"])))
umbral     <- unname(quantile(linea_base, 0.95))

pander(data.frame(
  Media_bajo_independencia = round(mean(linea_base), 3),
  Percentil_95             = round(umbral, 3)
))
```

Media_bajo_independencia	Percentil_95
0.054	0.074

```
comparacion |>
  head(12) |>
  mutate(Supera_linea_base = ifelse(Distancia > umbral, "Si", "No")) |>
  pander()
```

Table continues below

Activo_1	Activo_2	Spearman	Distancia	Diferencia	Supera_linea_base
Petroleo WTI	Nasdaq 100 (QQQ)	-0.002	0.077	0.075	Si
Petroleo WTI	Short Nasdaq (PSQ)	0.004	0.078	0.074	Si
Petroleo WTI	STOXX Europe 600	0.019	0.09	0.071	Si
Petroleo WTI	VIX	-0.009	0.08	0.071	Si
Petroleo WTI	S&P 500	0.019	0.089	0.07	Si
Petroleo WTI	Short S&P 500 (SH)	-0.022	0.09	0.068	No
Petroleo WTI	Indice dolar	-0.002	0.06	0.058	No
Petroleo WTI	Euro (FXE)	-0.006	0.063	0.057	No
Gas natural	Indice dolar	-0.005	0.06	0.055	No
Gas natural	Bitcoin	0.003	0.057	0.054	No
Google	Petroleo WTI	0.002	0.055	0.053	No
Gas natural	Ethereum	0.004	0.057	0.053	No

Análisis de las correlaciones

Con veintiún activos la matriz de Spearman se organiza en bloques nítidos. El más compacto es el de la renta variable estadounidense: el S&P 500 y el Nasdaq-100 forman el par positivo más alto de toda la matriz (0,938), y las tres tecnológicas correlacionan entre 0,639 y 0,738 con el Nasdaq-100. Los criptoactivos forman un bloque propio, con 0,837 entre bitcoin y ethereum, y lo mismo ocurre con los metales preciosos, con 0,753 entre el oro y la plata.

Las materias primas se dividen en dos grupos. Los energéticos siguen siendo prácticamente independientes de la renta variable: el petróleo y el gas natural no superan 0,057 en valor absoluto frente a ninguna acción ni índice. Los metales, en cambio, muestran una relación débil pero apreciable, que alcanza 0,272 entre el cobre y el S&P 500 y 0,345 entre el cobre y el STOXX Europe 600, coherente con su vínculo con la actividad industrial. Los bonos del Tesoro a largo plazo apenas se relacionan con el S&P 500 (0,093), lo que indica que en este periodo no cumplieron su función tradicional de refugio frente a las caídas de las acciones.

Seis pares tienen una correlación inferior a −0,9, y los productos inversos explican cinco de ellos. SH frente al S&P 500 (−0,986) y PSQ frente al Nasdaq-100 (−0,991) replican casi exactamente su diseño, y los cruces entre ellos también quedan por debajo de −0,9 porque ambos índices se mueven casi juntos. GLL frente al oro alcanza −0,903, una cifra algo menos extrema, que puede deberse a que el fondo y el futuro continuo no siguen exactamente el mismo contrato ni cierran a la misma hora. El único par natural por debajo de −0,9 es el del índice del dólar frente al euro (−0,939), y tiene una explicación estructural: el euro representa cerca del 58 % de la canasta con la que se calcula el índice, de modo que este se comporta en buena medida como el reflejo del tipo de cambio entre ambas monedas.

Fuera de los productos construidos para ello, la relación negativa más fuerte con el mercado es la del VIX: −0,759 frente al S&P 500 y entre −0,419 y −0,698 frente a las demás acciones e índices. Cuando las acciones caen, la volatilidad que el mercado espera para las semanas siguientes aumenta. El índice del dólar muestra una relación negativa más moderada con casi todos los activos de riesgo: −0,274 con el S&P 500, −0,415 con el oro y −0,361 con el cobre, lo que refleja que las materias primas cotizan en dólares y que el dólar tiende a fortalecerse en los episodios de aversión al riesgo.

La comparación con la correlación de distancias confirma que la dependencia fuerte es monótona. En los pares extremos, positivos o negativos, ambos coeficientes coinciden casi por completo: el S&P 500 frente a SH marca 0,986 en los dos, en valor absoluto. Donde Spearman es prácticamente nulo, la correlación de distancias solo es informativa si supera la línea base de independencia, cuya media es 0,054 y cuyo percentil 95 es 0,074. Entre los doce pares con mayor diferencia, los seis que superan la línea base tienen al petróleo en común: frente al S&P 500, el Nasdaq-100, el STOXX Europe 600, el VIX, SH y PSQ, con valores entre 0,077 y 0,090. Como esos seis instrumentos se mueven casi como uno solo, no son seis confirmaciones independientes sino la misma señal vista desde seis ángulos: una dependencia débil y no monótona entre el petróleo y la renta variable, compatible con que ambos registren movimientos grandes en las mismas jornadas sin que la dirección coincida. El margen sobre la línea base es estrecho y la línea base no incorpora la dependencia temporal de las series, por lo que el resultado debe tomarse como una señal a verificar y no como una conclusión.

9. Rendimientos frente al S&P 500

En este apartado se toma el S&P 500 como referencia de mercado y se evalúa el comportamiento de los otros veinte activos frente a él. Para cada activo se estima la regresión `r_activo = alfa + beta * r_sp500 + error` sobre las rentabilidades diarias, y se reportan también la rentabilidad acumulada y la volatilidad anualizada del periodo.

El coeficiente beta mide la sensibilidad del activo a los movimientos del índice: un beta de 2 implica que, en promedio, el activo amplifica al doble los movimientos del mercado, y un beta negativo indica que se mueve en sentido contrario. El coeficiente de determinación indica qué proporción de la variabilidad del activo queda explicada por el índice. El intercepto anualizado recoge el rendimiento medio no atribuible al mercado; conviene advertir que se calcula sin descontar una tasa libre de riesgo, por lo que es una medida descriptiva y no un alfa de Jensen.

```
benchmark <- X[ , "S&P 500"]
otros     <- setdiff(colnames(X), "S&P 500")

frente_sp <- map_dfr(otros, function(nombre) {
  r      <- X[ , nombre]
  modelo <- lm(r ~ benchmark)
  data.frame(
    Activo           = nombre,
    Spearman         = round(cor(r, benchmark, method = "spearman"), 3),
    Distancia        = round(dc[nombre, "S&P 500"], 3),
    Beta             = round(unname(coef(modelo)[2]), 3),
    R2               = round(summary(modelo)$r.squared, 3),
    Intercepto_anual = round(unname(coef(modelo)[1]) * 252 * 100, 2),
    Rend_acum        = round((exp(sum(r)) - 1) * 100, 1),
    Vol_anual        = round(sd(r) * sqrt(252) * 100, 1),
    row.names        = NULL
  )
}) |>
  arrange(desc(Rend_acum))

pander(frente_sp)
```

Table continues below

Activo	Spearman	Distancia	Beta	R2
Plata	0.188	0.188	0.465	0.039
Oro	0.098	0.109	0.112	0.01
Google	0.674	0.651	1.269	0.45
Nasdaq 100 (QQQ)	0.938	0.925	1.286	0.905
Bitcoin	0.396	0.378	1.279	0.171
Microsoft	0.706	0.687	1.155	0.484
Cobre	0.272	0.26	0.413	0.063
Tesla	0.586	0.559	2.057	0.343
STOXX Europe 600	0.488	0.469	0.387	0.217
Diamante (proxy)	0.426	0.409	1.157	0.202
Petroleo WTI	0.019	0.089	0.118	0.002

Activo	Spearman	Distancia	Beta	R2
Indice dolar	-0.274	0.27	-0.106	0.064
Euro (FXE)	0.285	0.28	0.119	0.071
VIX	-0.759	0.743	-5.418	0.588
Ethereum	0.411	0.396	1.793	0.19
Gas natural	0.057	0.077	0.321	0.004
Bonos Tesoro 20+	0.093	0.12	0.073	0.006
Short S&P 500 (SH)	-0.986	0.986	-0.993	0.982
Short Nasdaq (PSQ)	-0.932	0.918	-1.288	0.894
UltraShort Oro (GLL)	-0.139	0.151	-0.348	0.025

Intercepto_anual	Rend_acum	Vol_anual
15.46	171.4	40.3
17.57	148.9	19.2
3.58	134.6	32.6
-1.16	88.2	23.3
-3.14	70.2	53.2
-2.23	66.5	28.6
4.37	54.2	28.4
-15.61	41.1	60.5
2.28	37.4	14.3
-6.45	35.8	44.4
4.71	33.8	41.9
2.59	7.2	7.2
-1.94	-3	7.7
55.21	-19.9	121.7
-26.65	-28.3	70.9
-12.38	-34.9	86.1
-12.78	-44	15.8
-1.16	-44.4	17.3
-2.25	-55	23.5
-33.55	-83.7	37.6

La referencia contra la que se comparan estas cifras es el propio índice:

```
pander(data.frame(
  Activo    = "S&P 500",
  Rend_acum = round((exp(sum(benchmark)) - 1) * 100, 1),
  Vol_anual = round(sd(benchmark) * sqrt(252) * 100, 1),
  row.names = NULL
))
```

Activo	Rend_acum	Vol_anual
S&P 500	70.8	17.2

Evolución acumulada

Con veintiún series un único gráfico resulta ilegible, por lo que la evolución se presenta por clase de activo. En todos los paneles la línea gris punteada es el S&P 500, para facilitar la comparación. Cada panel tiene su propia escala vertical.

```
acumulado <- map_dfr(colnames(X), function(nombre) {
  data.frame(
    Date   = fechas,
    Activo = nombre,
    Clase  = unname(clases[nombre]),
    indice = 100 * exp(cumsum(X[ , nombre]))
  )
})

referencia <- acumulado |>
  filter(Activo == "S&P 500") |>
  select(Date, indice)

ggplot(acumulado, aes(x = Date, y = indice, color = Activo)) +
  geom_line(data = referencia, aes(x = Date, y = indice), inherit.aes = FALSE,
            color = "grey55", linetype = "dashed", linewidth = 0.5) +
  geom_line(linewidth = 0.6) +
  geom_hline(yintercept = 100, color = "grey80") +
  facet_wrap(~ Clase, ncol = 4, scales = "free_y") +
  labs(
    title    = "Evolucion de una inversion de 100 unidades por clase de activo",
    subtitle = "La linea gris punteada es el S&P 500 en todos los paneles",
    x        = NULL,
    y        = "Indice (base 100)",
    color    = NULL
  ) +
  theme_minimal() +
  theme(legend.position = "bottom")
```



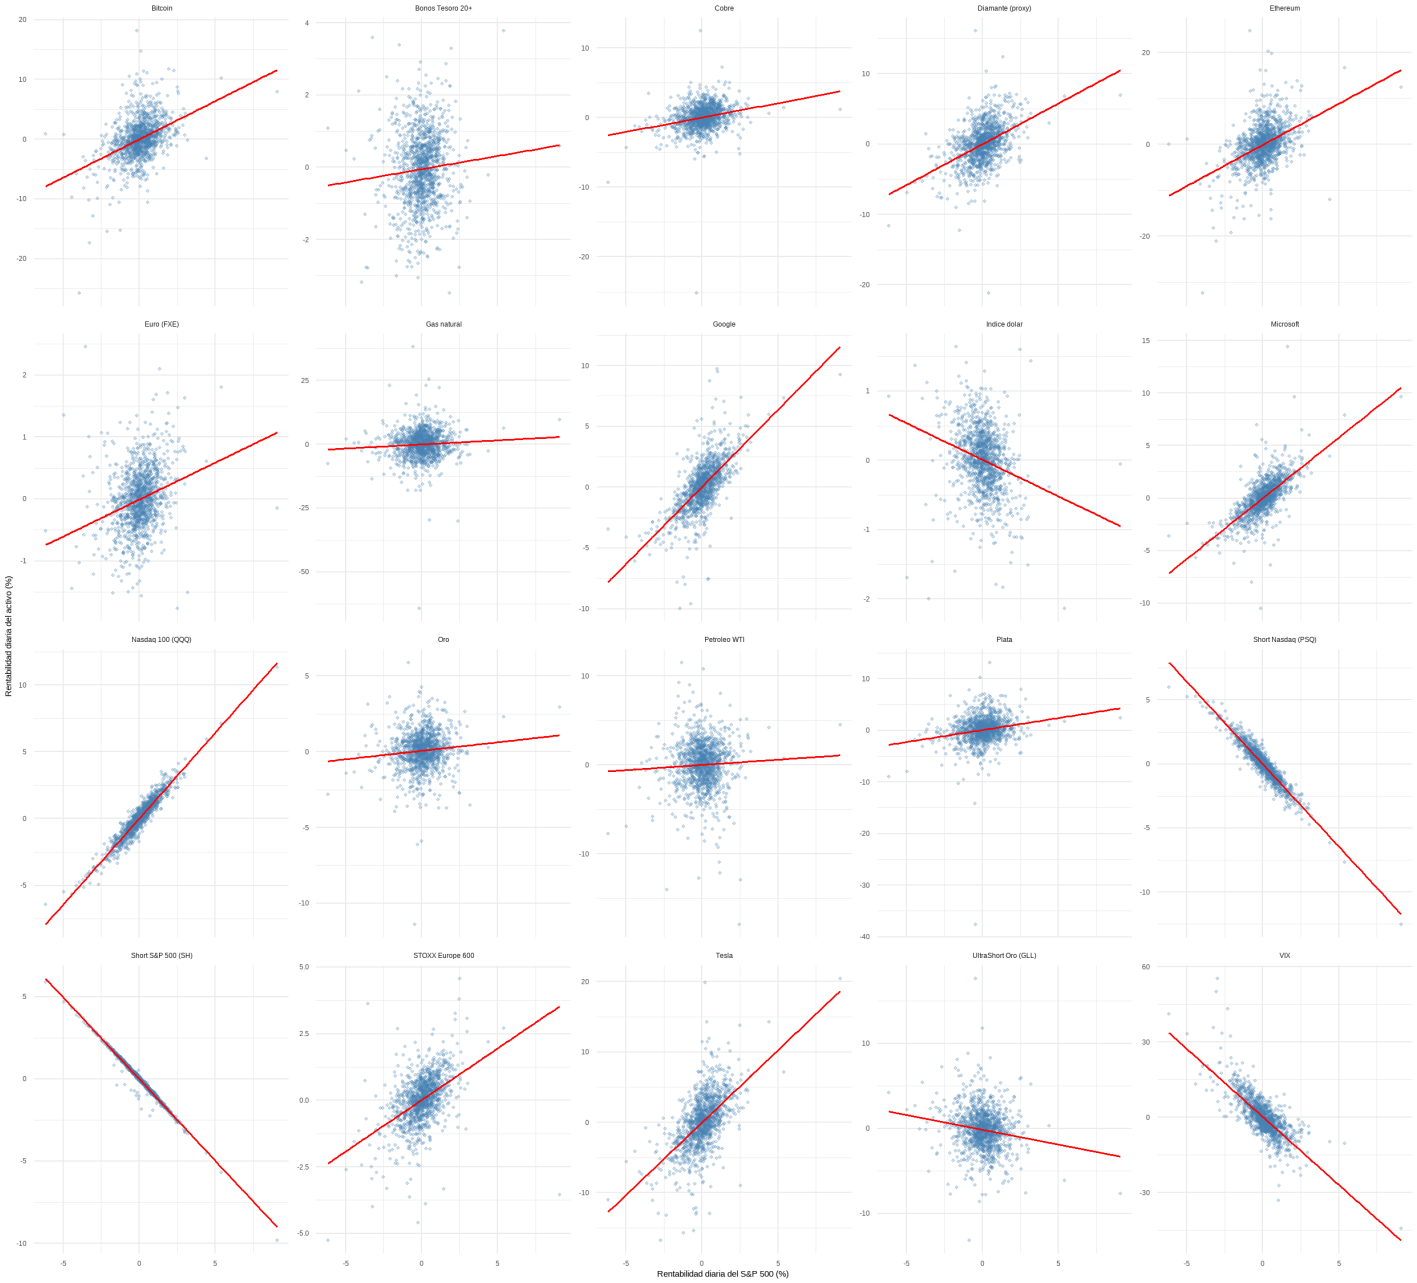
Relación diaria con el índice

```
dispersion <- map_dfr(otros, function(nombre) {
  data.frame(
    Activo  = nombre,
    activo  = X[ , nombre] * 100,
    mercado = benchmark * 100
  )
})

ggplot(dispersion, aes(x = mercado, y = activo)) +
  geom_point(alpha = 0.25, size = 0.7, color = "steelblue") +
  geom_smooth(method = "lm", se = FALSE, color = "red", linewidth = 0.7) +
  facet_wrap(~ Activo, scales = "free_y", ncol = 5) +
  labs(
    title = "Rentabilidad diaria de cada activo frente al S&P 500",
    x     = "Rentabilidad diaria del S&P 500 (%)",
    y     = "Rentabilidad diaria del activo (%)"
  ) +
  theme_minimal()
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

Rentabilidad diaria de cada activo frente al S&P 500



Riesgo frente a rentabilidad

```
riesgo <- frente_sp |>
  select(Activo, Rend_acum, Vol_anual) |>
  bind_rows(data.frame(
    Activo    = "S&P 500",
    Rend_acum = round((exp(sum(benchmark)) - 1) * 100, 1),
    Vol_anual = round(sd(benchmark) * sqrt(252) * 100, 1)
  )) |>
  mutate(Clase = unname(clases[Activo]))

ggplot(riesgo, aes(x = Vol_anual, y = Rend_acum, color = Clase, label = Activo)) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "grey60") +
  geom_point(size = 3) +
  geom_text_repel(size = 3.2, show.legend = FALSE, max.overlaps = Inf) +
  labs(
    title    = "Riesgo frente a rentabilidad",
    subtitle = "Ventana comun 2021-2026",
    x        = "Volatilidad anualizada (%)",
    y        = "Rentabilidad acumulada del periodo (%)",
    color    = "Clase"
  ) +
  theme_minimal()
```



Estabilidad de la relación en el tiempo

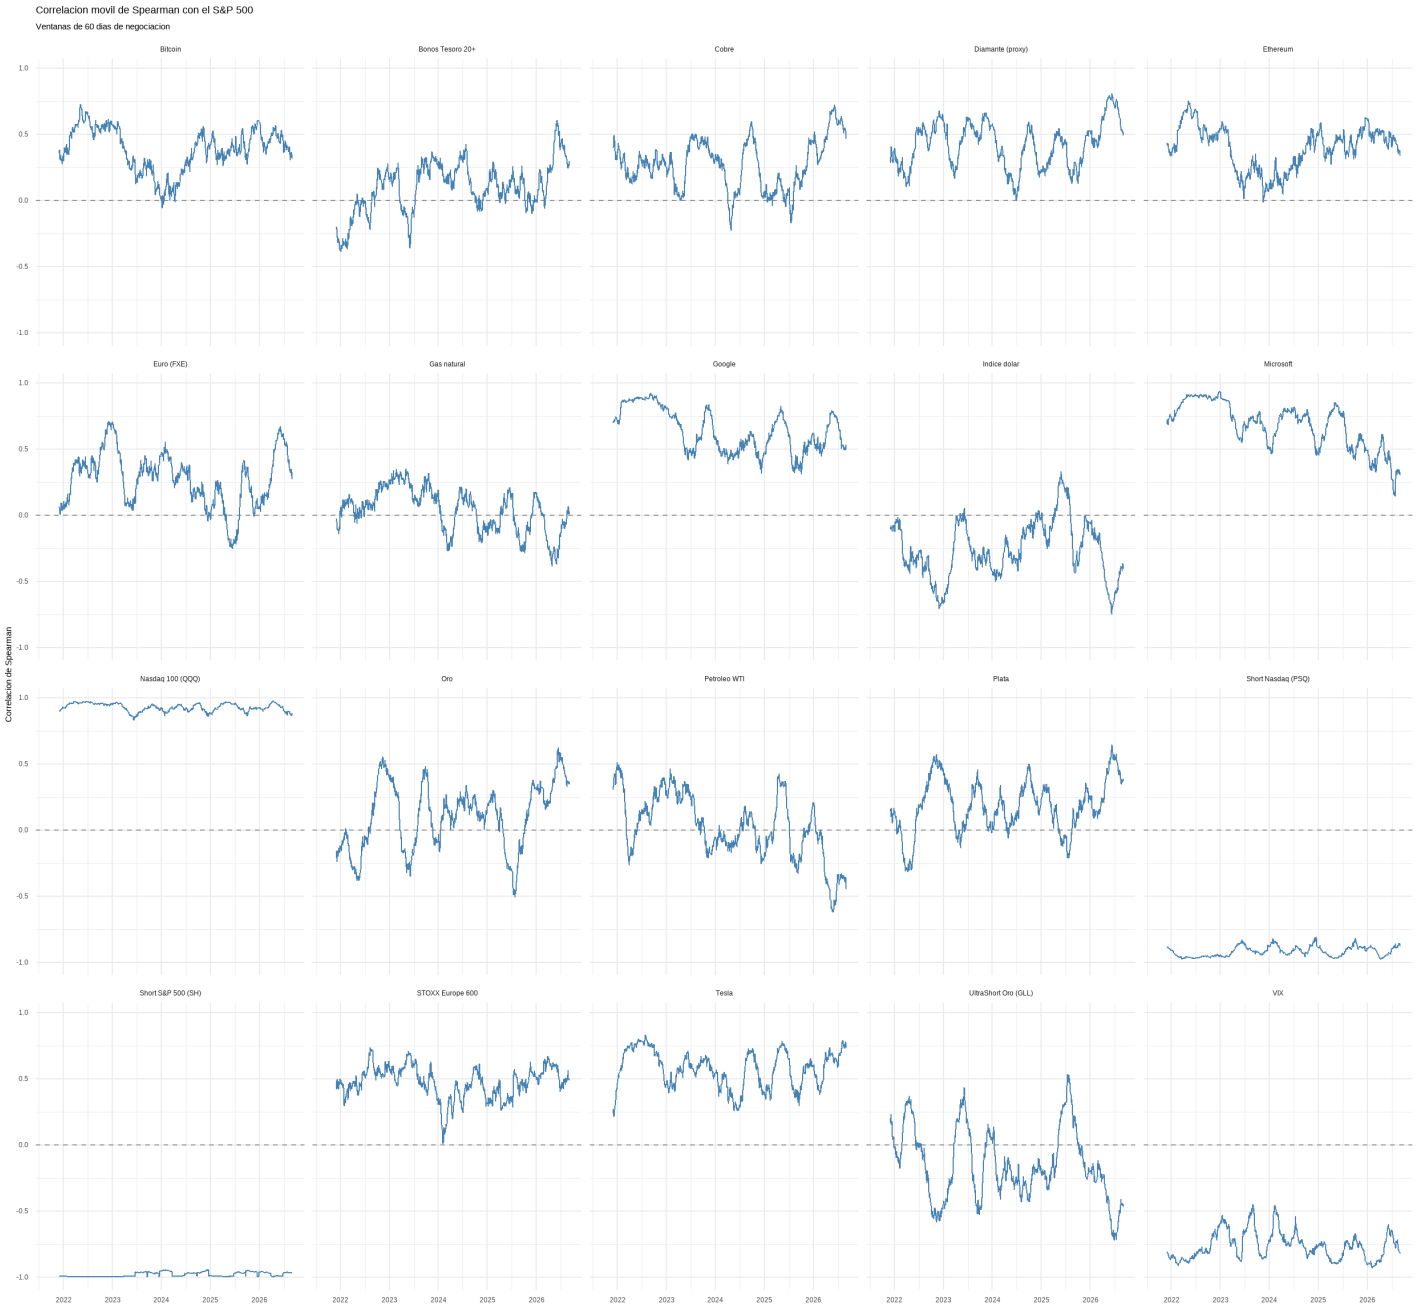
Los coeficientes anteriores resumen los cinco años en un único número. Para comprobar si esa relación se mantiene estable se calcula la correlación de Spearman móvil con el S&P 500 sobre ventanas de sesenta días de negociación.

```
ventana <- 60

movil <- map_dfr(otros, function(nombre) {
  valores <- rep(NA_real_, nrow(X))
  for (i in ventana:nrow(X)) {
    tramo      <- (i - ventana + 1):i
    valores[i] <- cor(X[tramo, nombre], X[tramo, "S&P 500"], method = "spearman")
  }
  data.frame(Date = fechas, Activo = nombre, correlacion = valores)
})

ggplot(movil, aes(x = Date, y = correlacion)) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "grey60") +
  geom_line(color = "steelblue", linewidth = 0.5) +
  facet_wrap(~ Activo, ncol = 5) +
  labs(
    title    = "Correlacion movil de Spearman con el S&P 500",
    subtitle = "Ventanas de 60 dias de negociacion",
    x        = NULL,
    y        = "Correlacion de Spearman"
  ) +
  theme_minimal()
```

```
## Warning: Removed 1180 rows containing missing values or values outside the scale range
## (`geom_line()`).
```



Cobertura frente a diversificación

Los pares con correlación fuertemente negativa invitan a pensar que combinarlos produce una cartera sin riesgo. La tabla evalúa esa idea con carteras de dos activos que se reequilibran cada día a pesos fijos. Las cinco primeras combinan un activo con su espejo; la última combina dos activos con correlación cercana a cero, como referencia. `Peso_1` es la proporción invertida en el primer activo.

```
combinaciones <- list(
  list("S&P 500",          "Short S&P 500 (SH)",   1/2),
  list("Nasdaq 100 (QQQ)", "Short Nasdaq (PSQ)",   1/2),
  list("Oro",              "UltraShort Oro (GLL)", 1/2),
  list("Oro",              "UltraShort Oro (GLL)", 2/3),
  list("Indice dolar",     "Euro (FXE)",           1/2),
  list("S&P 500",          "Oro",                  1/2)
)

carteras <- map_dfr(combinaciones, function(p) {
  r1      <- exp(X[ , p[[1]]]) - 1
  r2      <- exp(X[ , p[[2]]]) - 1
  w       <- p[[3]]
  cartera <- w * r1 + (1 - w) * r2
  data.frame(
    Activo_1     = p[[1]],
    Activo_2     = p[[2]],
    Peso_1       = round(w, 2),
    Spearman     = round(cor(X[ , p[[1]]], X[ , p[[2]]], method = "spearman"), 3),
    Rend_1       = round((prod(1 + r1) - 1) * 100, 1),
    Rend_2       = round((prod(1 + r2) - 1) * 100, 1),
    Rend_cartera = round((prod(1 + cartera) - 1) * 100, 1),
    Vol_1        = round(sd(r1) * sqrt(252) * 100, 1),
    Vol_2        = round(sd(r2) * sqrt(252) * 100, 1),
    Vol_cartera  = round(sd(cartera) * sqrt(252) * 100, 1)
  )
})

pander(carteras)
```

Table continues below

Activo_1	Activo_2	Peso_1	Spearman	Rend_1	Rend_2
S&P 500	Short S&P 500 (SH)	0.5	-0.986	70.8	-44.4
Nasdaq 100 (QQQ)	Short Nasdaq (PSQ)	0.5	-0.991	88.2	-55
Oro	UltraShort Oro (GLL)	0.5	-0.903	148.9	-83.7
Oro	UltraShort Oro (GLL)	0.67	-0.903	148.9	-83.7
Indice dolar	Euro (FXE)	0.5	-0.939	7.2	-3
S&P 500	Oro	0.5	0.098	70.8	148.9

Rend_cartera	Vol_1	Vol_2	Vol_cartera
4.7	17.2	17.2	1.1
5	23.3	23.4	1.3
-23	19.2	37.7	10.9

Rend_cartera	Vol_1	Vol_2	Vol_cartera
18.7	19.2	37.7	5.3
3.3	7.2	7.7	1.4
113.8	17.2	19.2	13.5

Análisis del desempeño frente al índice

Durante la ventana analizada el S&P 500 acumuló un 70,8 % con una volatilidad anualizada del 17,2 %. Solo cuatro de los veinte activos restantes lo superaron.

Activos que superaron al índice. La plata acumuló un 171,4 % y el oro un 148,9 %. El oro lo hizo con una volatilidad del 19,2 %, muy cercana a la del índice, con un beta de 0,112 y un coeficiente de determinación de 0,010: su rendimiento no proviene del mercado de acciones. La plata duplicó esa volatilidad (40,3 %) y es el activo de mejor rendimiento de la muestra. Google acumuló un 134,6 % y el Nasdaq-100 un 88,2 %, en ambos casos amplificando al mercado, con betas de 1,269 y 1,286. El Nasdaq-100 es además el activo mejor explicado por el índice, con un coeficiente de determinación de 0,905.

Rendimiento parecido con más riesgo. Bitcoin acumuló un 70,2 %, prácticamente lo mismo que el índice, pero con una volatilidad del 53,2 %, tres veces mayor. Microsoft acumuló un 66,5 % con un beta de 1,155 y un coeficiente de determinación de 0,484.

Por debajo del índice. El cobre (54,2 %), Tesla (41,1 %), el STOXX Europe 600 (37,4 %), Anglo American (35,8 %) y el petróleo (33,8 %) quedaron por debajo del S&P 500. Tesla es el caso más marcado: tiene el beta positivo más alto de la muestra (2,057), una volatilidad del 60,5 % y un intercepto anualizado de −15,61 %, es decir, obtuvo menos de lo que correspondería a su exposición al mercado.

Divisas. El índice del dólar (7,2 %) y el euro (−3,0 %) apenas se movieron en términos acumulados, con volatilidades inferiores al 8 %. Fuera del VIX y de los productos inversos, el dólar es el único activo cuya correlación con el S&P 500 es negativa de forma estable: su beta es de −0,106 y su correlación móvil es negativa en el 91 % de las ventanas.

Pérdidas. Además del euro, siete activos terminaron con pérdida. Ethereum perdió un 28,3 % con una volatilidad del 70,9 % y un beta de 1,793, muy superior al de bitcoin (1,279). El gas natural perdió un 34,9 % con una volatilidad del 86,1 %. Los bonos del Tesoro a largo plazo perdieron un 44,0 % de su precio, afectados por la subida de tasas de interés iniciada en 2022, con un beta de apenas 0,073: no compensaron las caídas de las acciones. El VIX perdió un 19,9 % en su nivel, con la volatilidad más alta de la muestra (121,7 %), aunque conviene recordar que no es un activo invertible. Los tres productos inversos también perdieron valor: SH un 44,4 %, PSQ un 55,0 % y GLL un 83,7 %. Las dos primeras pérdidas son la contracara de un mercado alcista; la de GLL es la más severa porque combina el apalancamiento doble con un activo de referencia que más que duplicó su precio.

Cobertura frente a diversificación. La tabla de carteras resume la lección central del apartado. Combinar el S&P 500 con SH a partes iguales reduce la volatilidad del 17,2 % al 1,1 %, pero también el rendimiento, del 70,8 % al 4,7 % en cinco años: la cartera se comporta prácticamente como efectivo. Lo mismo ocurre con el Nasdaq-100 y PSQ (5,0 % con 1,3 % de volatilidad) y con el dólar y el euro (3,3 % con 1,4 %). Un activo con correlación cercana a −1 no diversifica, cubre: elimina el riesgo junto con el rendimiento. El caso del oro con GLL añade una advertencia práctica. Como GLL es un producto −2x, repartir a partes iguales deja una exposición neta corta al oro y produce una pérdida del 23,0 %; la proporción que neutraliza la exposición es de dos tercios en oro y un tercio

en GLL, que da un 18,7 % con 5,3 % de volatilidad. En contraste, combinar el S&P 500 con el oro, cuya correlación es de apenas 0,098, reduce la volatilidad a un 13,5 %, por debajo de la de cualquiera de los dos por separado, y conserva un rendimiento del 113,8 %. Esa es la diferencia entre cubrir y diversificar.

Estabilidad. La correlación móvil confirma que solo las relaciones construidas son estables. SH se mantiene entre −1,00 y −0,94 durante todo el periodo, PSQ entre −0,97 y −0,81 y el Nasdaq-100 entre 0,83 y 0,97. El VIX es negativo en todas las ventanas, entre −0,93 y −0,45. El resto de las relaciones cambia de forma apreciable: Microsoft oscila entre 0,94 y 0,15, los bonos del Tesoro entre −0,38 y 0,61, y el petróleo es negativo en el 49 % de las ventanas. Para una estrategia de corto plazo esto implica que una cobertura basada en correlaciones naturales, a diferencia de una basada en productos inversos, puede dejar de funcionar justo cuando más se necesita.

10. Simulación de Monte Carlo de carteras

Los apartados anteriores describen lo que ocurrió. Una simulación de Monte Carlo sirve para algo distinto: explorar qué conjunto de resultados es compatible con ese comportamiento. La idea es generar miles de escenarios artificiales a partir de los datos observados y estudiar la distribución de los resultados en lugar de un único camino.

En este apartado se aplica en dos niveles. Primero se simulan carteras, sorteando al azar miles de combinaciones de pesos entre los activos disponibles, para ver qué relaciones entre riesgo y rendimiento eran alcanzables. Después se simulan trayectorias futuras de unas carteras concretas, con tres motores de generación distintos, para comparar qué ocurre cuando se supone normalidad y cuando no se supone nada sobre la distribución.

Antes de simular conviene fijar tres decisiones. El universo se limita a los veinte activos invertibles, excluyendo el VIX, que es un indicador y no un instrumento que se pueda comprar. Los cálculos se hacen sobre rendimientos simples diarios, porque los pesos de una cartera se aplican a ellos y no a los logarítmicos. Y todas las carteras se reequilibran cada día a sus pesos objetivo, que es el supuesto más simple y el que no requiere decidir una regla de reequilibrio.

10.1 Universo y carteras de referencia

Se definen siete carteras de referencia. Las cuatro primeras son decisiones de inversión plausibles; la quinta es la cobertura estudiada en el apartado anterior; las dos últimas salen de la propia simulación y se explican más adelante.

```
invertibles <- setdiff(colnames(X), "VIX")
R           <- exp(X[ , invertibles]) - 1
ndias       <- nrow(R)

metricas <- function(rp) {
  c(Rend = (prod(1 + rp)^(252 / length(rp)) - 1) * 100,
    Vol  = sd(rp) * sqrt(252) * 100)
}

peso <- function(...) {
  v <- c(...)
  w <- setNames(rep(0, ncol(R)), colnames(R))
  w[names(v)] <- v
  w / sum(w)
}
```

```
set.seed(2026)

S <- 5000
W <- matrix(rexp(S * ncol(R)), nrow = ncol(R))
W <- t(t(W) / colSums(W))
rownames(W) <- colnames(R)

RP <- R %*% W

nube <- data.frame(
  Rend = (apply(1 + RP, 2, prod)^(252 / ndias) - 1) * 100,
  Vol  = apply(RP, 2, sd) * sqrt(252) * 100
) |>
  mutate(Ratio = Rend / Vol)

imin <- which.min(nube$Vol)
imax <- which.max(nube$Ratio)

carteras <- list(
  "Solo S&P 500"    = peso("S&P 500" = 1),
  "Pesos iguales"   = setNames(rep(1 / ncol(R), ncol(R)), colnames(R)),
  "60/40"           = peso("S&P 500" = 0.6, "Bonos Tesoro 20+" = 0.4),
  "Diversificada"   = peso("S&P 500" = 0.35, "Nasdaq 100 (QQQ)" = 0.10, "STOXX Europe 600" = 0.1
0,
                           "Oro" = 0.20, "Cobre" = 0.05, "Bonos Tesoro 20+" = 0.10,
                           "Bitcoin" = 0.05, "Petroleo WTI" = 0.05),
  "Cubierta 50/50"  = peso("S&P 500" = 0.5, "Short S&P 500 (SH)" = 0.5),
  "Minima varianza" = W[ , imin],
  "Mejor relacion"  = W[ , imax]
)

historico <- map_dfr(names(carteras), function(nombre) {
  rp <- as.vector(R %*% carteras[[nombre]])
  m  <- metricas(rp)
  data.frame(
    Cartera     = nombre,
    Rend_anual  = round(m[1], 2),
    Vol_anual   = round(m[2], 2),
    Acumulado   = round((prod(1 + rp) - 1) * 100, 1),
    Ratio       = round(m[1] / m[2], 3),
    row.names   = NULL
  )
})

pander(historico)
```

Cartera	Rend_anual	Vol_anual	Acumulado	Ratio
Solo S&P 500	11.67	17.24	70.8	0.677
Pesos iguales	9.55	12.74	55.6	0.75

Cartera	Rend_anual	Vol_anual	Acumulado	Ratio
60/40	2.47	12.54	12.5	0.197
Diversificada	12.31	12.67	75.6	0.972
Cubierta 50/50	0.95	1.14	4.7	0.828
Minima varianza	4.49	4.34	23.7	1.033
Mejor relacion	15.17	12.46	98.3	1.218

La columna `Ratio` es el rendimiento anual dividido por la volatilidad anual. No es un coeficiente de Sharpe, porque no descuenta la tasa libre de riesgo, pero ordena las carteras por rendimiento obtenido por unidad de riesgo asumido.

10.2 Cinco mil carteras aleatorias

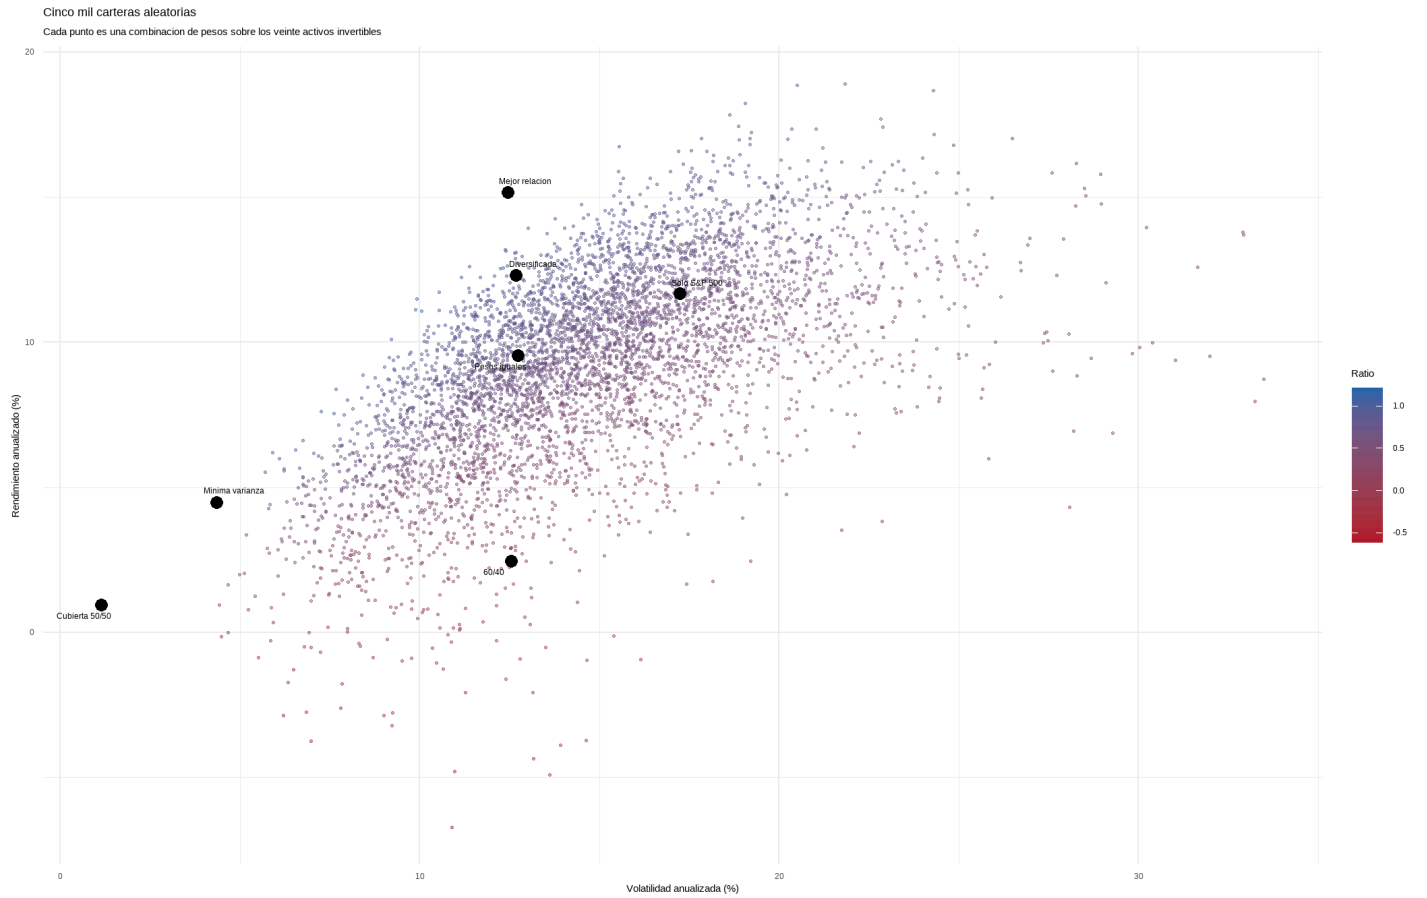
La primera simulación sortea 5.000 vectores de pesos. Cada vector se obtiene generando veinte valores de una distribución exponencial y dividiéndolos por su suma, lo que produce puntos repartidos de manera uniforme sobre el conjunto de carteras posibles sin posiciones cortas. Para cada una se calculan el rendimiento anualizado y la volatilidad que habría tenido en el periodo analizado.

```
pander(data.frame(
  Carteras        = S,
  Rend_minimo     = round(min(nube$Rend), 1),
  Rend_maximo     = round(max(nube$Rend), 1),
  Vol_minima      = round(min(nube$Vol), 1),
  Vol_maxima      = round(max(nube$Vol), 1),
  Mejor_ratio     = round(max(nube$Ratio), 3)
))
```

Carteras	Rend_minimo	Rend_maximo	Vol_minima	Vol_maxima	Mejor_ratio
5000	-6.7	18.9	4.3	33.5	1.218

```
referencias <- historico |>
  mutate(Cartera = factor(Cartera, levels = names(carteras)))

ggplot(nube, aes(x = Vol, y = Rend)) +
  geom_point(aes(color = Ratio), size = 0.6, alpha = 0.45) +
  scale_color_gradient(low = "#b2182b", high = "#2166ac") +
  geom_point(data = referencias, aes(x = Vol_anual, y = Rend_anual),
             inherit.aes = FALSE, size = 3, color = "black") +
  geom_text_repel(data = referencias, aes(x = Vol_anual, y = Rend_anual, label = Cartera),
                  inherit.aes = FALSE, size = 3.2, max.overlaps = Inf) +
  labs(
    title    = "Cinco mil carteras aleatorias",
    subtitle = "Cada punto es una combinacion de pesos sobre los veinte activos invertibles",
    x        = "Volatilidad anualizada (%)",
    y        = "Rendimiento anualizado (%)",
    color    = "Ratio"
  ) +
  theme_minimal()
```



Las dos carteras que la simulación selecciona merecen mirarse por dentro. La tabla muestra los cinco activos con mayor peso en cada una.

```
mayores <- function(w, etiqueta) {
  orden <- sort(w, decreasing = TRUE)[1:5]
  data.frame(
    Cartera = etiqueta,
    Activo  = names(orden),
    Peso    = round(as.numeric(orden) * 100, 1)
  )
}

pander(bind_rows(
  mayores(carteras[["Minima varianza"]], "Minima varianza"),
  mayores(carteras[["Mejor relacion"]],  "Mejor relacion")
))
```

Cartera	Activo	Peso
Minima varianza	Indice dolar	16
Minima varianza	Short S&P 500 (SH)	15
Minima varianza	Euro (FXE)	11.1
Minima varianza	S&P 500	9.3
Minima varianza	Google	7.6
Mejor relacion	Oro	27.9
Mejor relacion	Indice dolar	11.7
Mejor relacion	Google	10.4
Mejor relacion	Gas natural	6.8
Mejor relacion	Microsoft	6.5

10.3 Trayectorias simuladas a un año

La segunda simulación genera el futuro de cada cartera. Se producen 1.000 trayectorias de 252 jornadas con tres motores distintos:

- **Normal.** Cada rendimiento diario se sortea de una distribución normal con la media y la desviación estándar históricas de la cartera. Es el supuesto paramétrico clásico.
- **Bootstrap.** Cada rendimiento diario se extrae al azar, con reemplazo, del conjunto de rendimientos diarios realmente observados. No impone ninguna forma a la distribución, de modo que conserva las colas y la asimetría de los datos, pero rompe el orden temporal.
- **Bloques.** Se extraen tramos consecutivos de veinte jornadas en lugar de días sueltos. Al conservar tramos completos, mantiene parcialmente el agrupamiento de volatilidad que se detectó en el análisis exploratorio.

```
NSIM <- 1000
B    <- 20

simular <- function(lp, metodo, h) {
  if (metodo == "Normal") {
    matrix(rnorm(NSIM * h, mean(lp), sd(lp)), nrow = h)
  } else if (metodo == "Bootstrap") {
    matrix(sample(lp, NSIM * h, replace = TRUE), nrow = h)
  } else {
    nb  <- ceiling(h / B)
    ini <- matrix(sample(1:(length(lp) - B + 1), NSIM * nb, replace = TRUE), nrow = nb)
    apply(ini, 2, function(col) as.vector(sapply(col, function(i) lp[i:(i + B - 1)]))[1:h])
  }
}

caida_maxima <- function(camino) {
  v <- exp(cumsum(camino))
  max(1 - v / cummax(v)) * 100
}
```

```
set.seed(2026)

simulacion <- map_dfr(names(carteras), function(nombre) {
  rp <- as.vector(R %*% carteras[[nombre]])
  lp <- log(1 + rp)

  map_dfr(c("Normal", "Bootstrap", "Bloques"), function(metodo) {
    M   <- simular(lp, metodo, 252)
    fin <- 100 * exp(colSums(M))
    dd  <- apply(M, 2, caida_maxima)

    data.frame(
      Cartera       = nombre,
      Metodo        = metodo,
      P5            = round(quantile(fin, 0.05), 1),
      Mediana       = round(median(fin), 1),
      P95           = round(quantile(fin, 0.95), 1),
      Prob_perdida  = round(mean(fin < 100) * 100, 1),
      Caida_mediana = round(median(dd), 1),
      Caida_p95     = round(quantile(dd, 0.95), 1),
      row.names     = NULL
    )
  })
})

pander(simulacion)
```

Table continues below

Cartera	Metodo	P5	Mediana	P95	Prob_perdida

Cartera	Metodo	P5	Mediana	P95	Prob_perdida	Caida_mediana	Caida_p95
Solo S&P 500	Normal	83.7	112.8	149.8	24.3	13.6	25.7
Solo S&P 500	Bootstrap	84.2	111.8	147.8	26.3	13.6	26.1
Solo S&P 500	Bloques	86.9	113.5	144.9	20.2	13.3	23.7
Pesos iguales	Normal	89.5	110.9	134.9	21	9.8	19.1
Pesos iguales	Bootstrap	88.7	108.8	133.6	24.2	10.2	19.4
Pesos iguales	Bloques	88.2	109.9	134.4	23.4	10.3	20.4
60/40	Normal	82.7	102.9	126.7	41.5	11.9	22.7
60/40	Bootstrap	83.4	102	125.3	44.6	11.7	22.4
60/40	Bloques	82.3	103	124.3	40.2		
Diversificada	Normal	92.6	113.2	137.9	18		
Diversificada	Bootstrap	91.1	111.9	137.7	18.7		
Diversificada	Bloques	91.4	113.4	137	15.4		
Cubierta 50/50	Normal	99.1	101	103	19.3		
Cubierta 50/50	Bootstrap	98.9	101	102.7	19		
Cubierta 50/50	Bloques	99.5	101	102.4	14.3		
Minima varianza	Normal	97.2	104.3	112.2	16.2		
Minima varianza	Bootstrap	97.8	104.5	111.9	14.7		
Minima varianza	Bloques	97.3	104.7	112	14.9		
Mejor relacion	Normal	93.7	115.9	141.3	13.8		
Mejor relacion	Bootstrap	92.5	114.7	140.6	14.6		
Mejor relacion	Bloques	95.6	116	139.3	9.9		

Caida_mediana	Caida_p95
11.9	23.2
9.5	18.3
9.5	18
10.3	18.8
0.9	1.9
0.9	2.2
0.9	1.7
3.3	6.7
3.3	6.6
3.5	6.5
8.9	17.2
9	17.1
9.3	16.3

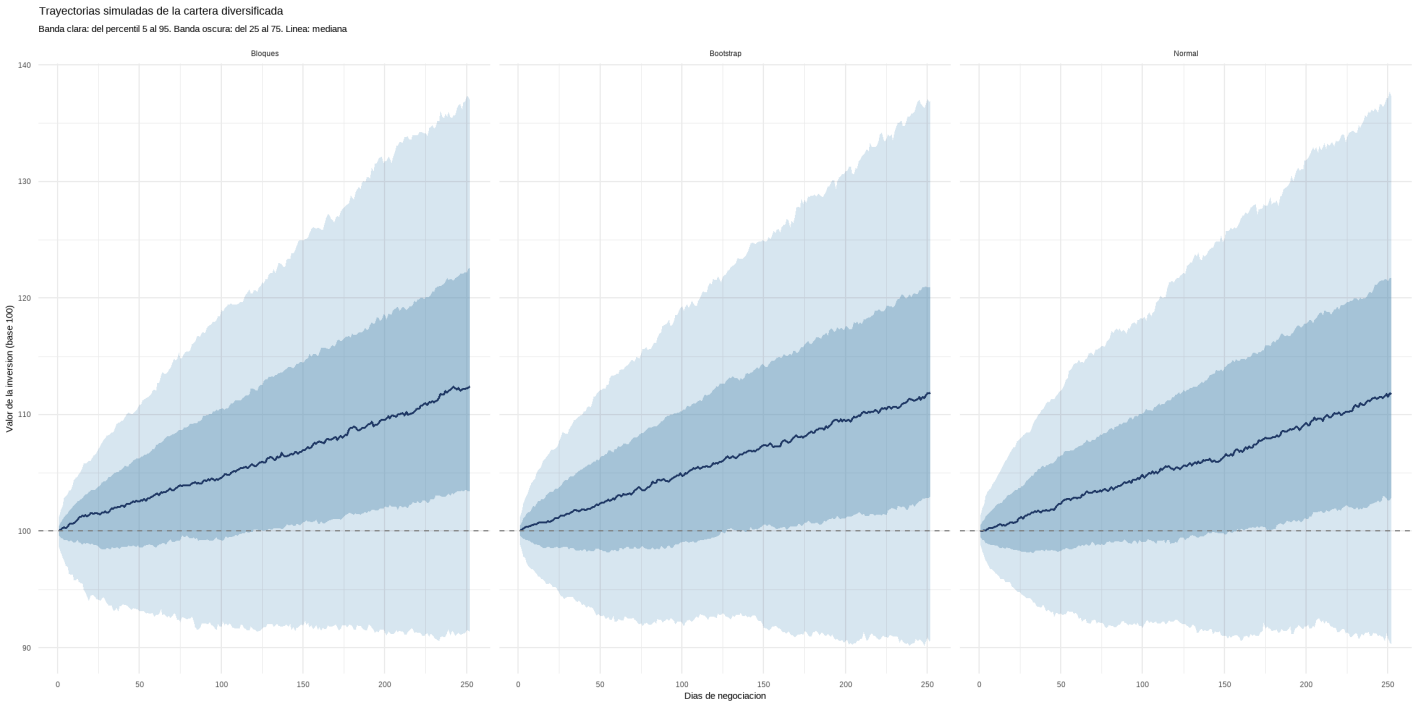
Todos los valores están expresados sobre una inversión inicial de 100 unidades. `P5` y `P95` delimitan el intervalo que contiene el 90 % de los escenarios, `Prob_perdida` es el porcentaje de trayectorias que terminan por debajo de 100 y las dos últimas columnas describen la caída máxima sufrida dentro del año.

```r
set.seed(7)

lp_div <- log(1 + as.vector(R %*% carteras[["Diversificada"]]))

bandas <- map_dfr(c("Normal", "Bootstrap", "Bloques"), function(metodo) {
  valores <- 100 * exp(apply(simular(lp_div, metodo, 252), 2, cumsum))
  data.frame(
    Dia    = 1:252,
    Metodo = metodo,
    p05    = apply(valores, 1, quantile, 0.05),
    p25    = apply(valores, 1, quantile, 0.25),
    p50    = apply(valores, 1, median),
    p75    = apply(valores, 1, quantile, 0.75),
    p95    = apply(valores, 1, quantile, 0.95)
  )
})

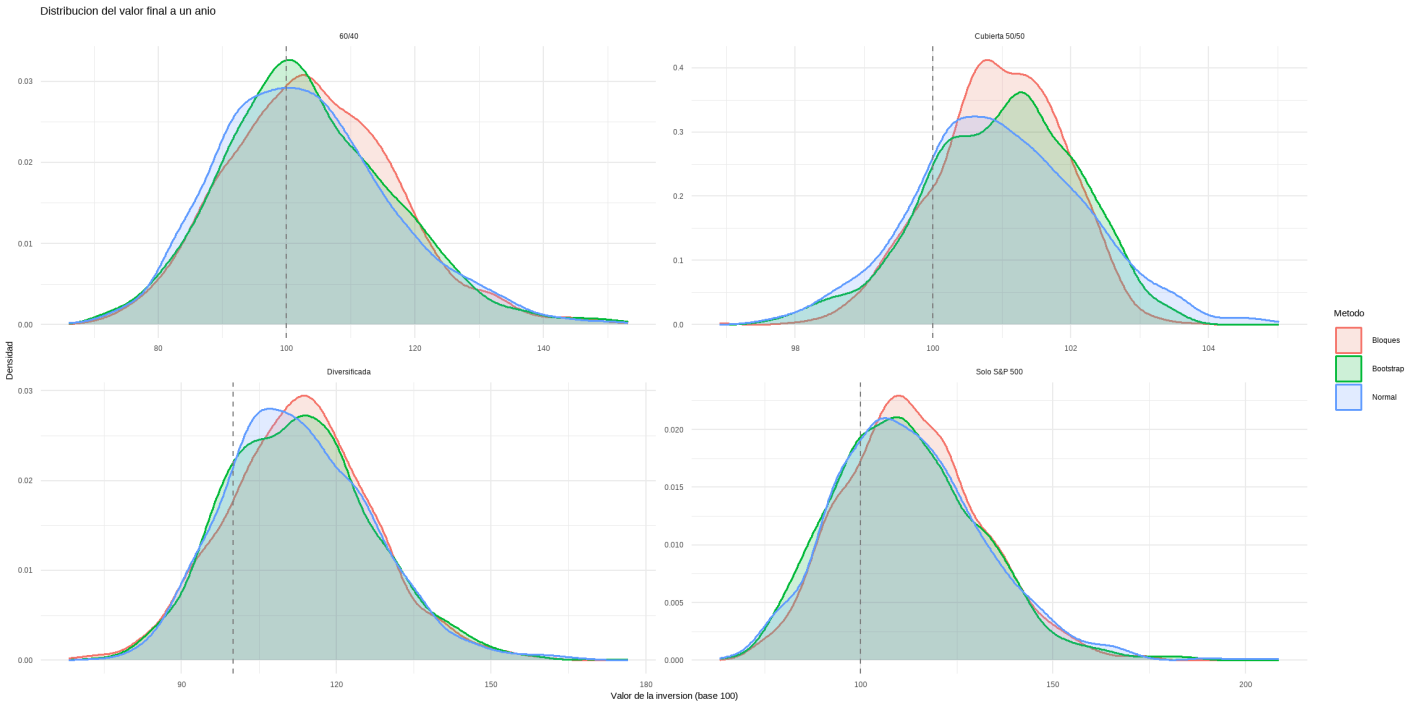
ggplot(bandas, aes(x = Dia)) +
  geom_ribbon(aes(ymin = p05, ymax = p95), fill = "steelblue", alpha = 0.20) +
  geom_ribbon(aes(ymin = p25, ymax = p75), fill = "steelblue", alpha = 0.35) +
  geom_line(aes(y = p50), color = "#1F3864", linewidth = 0.7) +
  geom_hline(yintercept = 100, linetype = "dashed", color = "grey50") +
  facet_wrap(~ Metodo) +
  labs(
    title    = "Trayectorias simuladas de la cartera diversificada",
    subtitle = "Banda clara: del percentil 5 al 95. Banda oscura: del 25 al 75. Linea: mediana",
    x        = "Dias de negociacion",
    y        = "Valor de la inversion (base 100)"
  ) +
  theme_minimal()
```



```
set.seed(7)

finales <- map_dfr(c("Solo S&P 500", "Diversificada", "60/40", "Cubierta 50/50"), function(nombr
e) {
  lp <- log(1 + as.vector(R %*% carteras[[nombre]]))
  map_dfr(c("Normal", "Bootstrap", "Bloques"), function(metodo) {
    data.frame(
      Cartera = nombre,
      Metodo  = metodo,
      Final   = 100 * exp(colSums(simular(lp, metodo, 252)))
    )
  })
})

ggplot(finales, aes(x = Final, fill = Metodo, color = Metodo)) +
  geom_density(alpha = 0.18, linewidth = 0.6) +
  geom_vline(xintercept = 100, linetype = "dashed", color = "grey50") +
  facet_wrap(~ Cartera, scales = "free", ncol = 2) +
  labs(
    title = "Distribucion del valor final a un anio",
    x     = "Valor de la inversion (base 100)",
    y     = "Densidad"
  ) +
  theme_minimal()
```



10.4 ¿Cuánto importa el supuesto de normalidad?

El informe ha insistido en que los rendimientos no son normales. Conviene comprobar qué consecuencias tiene eso dentro de la simulación. La primera comprobación es directa: comparar los cuantiles bajos observados en los rendimientos diarios de cada cartera con los que predice una normal de igual media y desviación.

```
colas <- map_dfr(c("Solo S&P 500", "Diversificada", "Pesos iguales"), function(nombre) {
  rp <- as.vector(R %*% carteras[[nombre]])
  data.frame(
    Cartera     = nombre,
    P1_empirico = round(quantile(rp, 0.01) * 100, 2),
    P1_normal   = round(qnorm(0.01, mean(rp), sd(rp)) * 100, 2),
    P5_empirico = round(quantile(rp, 0.05) * 100, 2),
    P5_normal   = round(qnorm(0.05, mean(rp), sd(rp)) * 100, 2),
    Peor_dia    = round(min(rp) * 100, 2),
    Curtosis    = round(mean((rp - mean(rp))^4) / sd(rp)^4, 1),
    row.names   = NULL
  )
})

pander(colas)
```

Table continues below

Cartera	P1_empirico	P1_normal	P5_empirico	P5_normal	Peor_dia
Solo S&P 500	-2.99	-2.48	-1.65	-1.74	-5.97
Diversificada	-2.12	-1.81	-1.23	-1.26	-4.44
Pesos iguales	-2.12	-1.83	-1.25	-1.28	-4.06

Curtosis
9.9
7.3
5.3

La segunda comprobación repite la simulación con un horizonte de diez jornadas en lugar de un año.

```
set.seed(2026)

corto <- map_dfr(c("Solo S&P 500", "Diversificada", "Mejor relacion"), function(nombre) {
  lp <- log(1 + as.vector(R %*% carteras[[nombre]]))
  map_dfr(c("Normal", "Bootstrap", "Bloques"), function(metodo) {
    fin <- 100 * exp(colSums(simular(lp, metodo, 10)))
    data.frame(
      Cartera      = nombre,
      Metodo       = metodo,
      P1           = round(quantile(fin, 0.01), 1),
      P5           = round(quantile(fin, 0.05), 1),
      Mediana      = round(median(fin), 1),
      P99          = round(quantile(fin, 0.99), 1),
      Prob_perdida = round(mean(fin < 100) * 100, 1),
      row.names    = NULL
    )
  })
})

pander(corto)
```

Cartera	Metodo	P1	P5	Mediana	P99	Prob_perdida
Solo S&P 500	Normal	92.9	94.7	100.6	109	43.8
Solo S&P 500	Bootstrap	91.8	94.9	100.5	108.9	44.7
Solo S&P 500	Bloques	91.6	94.3	100.6	108.1	41.8
Diversificada	Normal	94.5	96.2	100.5	106.5	41.3
Diversificada	Bootstrap	94.4	96.5	100.5	106.8	42.3
Diversificada	Bloques	93.3	96.5	100.8	106.1	36.5
Mejor relacion	Normal	94.8	96.4	100.6	106.5	40
Mejor relacion	Bootstrap	95	96.4	100.7	106.3	41
Mejor relacion	Bloques	94.3	96.4	100.7	106.3	38.3

10.5 Análisis de la simulación

Las carteras aleatorias delimitan lo que era alcanzable. Las 5.000 combinaciones cubren rendimientos anualizados entre −6,7 % y 18,9 % y volatilidades entre 4,3 % y 33,5 %. La nube tiene la forma habitual: el rendimiento aumenta con el riesgo, pero con una dispersión enorme, de manera que para casi cualquier nivel de volatilidad existían carteras buenas y carteras malas. La relación entre rendimiento y volatilidad llega como máximo a 1,218.

La diversificación hecha a mano funcionó mejor que el índice. La cartera diversificada obtuvo un 12,31 % anual con un 12,67 % de volatilidad, frente al 11,67 % y el 17,24 % del S&P 500. Su relación entre rendimiento y riesgo es de 0,972 contra 0,677 del índice, es decir, más rendimiento con casi un tercio menos de volatilidad. La cartera de pesos iguales, que no requiere ninguna decisión, alcanza 0,750 y también supera al índice en esa medida.

La cartera clásica 60/40 fue la peor del grupo. Obtuvo un 2,47 % anual con un 12,54 % de volatilidad y una relación de 0,197. La causa está documentada en el apartado 9: los bonos del Tesoro a largo plazo perdieron un 44 % de su precio en el periodo y su correlación con las acciones fue de 0,093, de modo que aportaron riesgo sin aportar ni rendimiento ni protección. Es un recordatorio de que una regla de cartera reputada puede fallar durante cinco años seguidos si cambia el régimen de tasas de interés.

Las dos carteras elegidas por la simulación deben leerse con cuidado. La de mínima varianza logra un 4,49 % con apenas un 4,34 % de volatilidad, pero lo hace apoyándose en el índice del dólar (16 %), en el fondo inverso SH (15 %) y en el euro (11,1 %), es decir, en instrumentos de cobertura que cuestan rendimiento. La de mejor relación alcanza un 15,17 % con un 12,46 %, y concentra un 27,9 % en oro, el activo que más subió. Ninguna de las dos es una recomendación: ambas se eligieron mirando los mismos datos con los que después se miden, lo que garantiza que su desempeño esté sobreestimado. Un ejercicio honesto exigiría seleccionar los pesos en un periodo y evaluarlos en otro posterior.

A un año, los tres motores de simulación dicen casi lo mismo. Para la cartera diversificada, el percentil 5 queda entre 91,1 y 92,6 según el método, la mediana entre 111,9 y 113,4 y la probabilidad de terminar con pérdida entre el 15,4 % y el 18,7 %. Para el S&P 500 las diferencias son algo mayores, con probabilidades de pérdida entre el 20,2 % y el 26,3 %, pero siguen siendo pequeñas frente a la incertidumbre total.

La diferencia sí aparece en el horizonte corto. En los rendimientos diarios, la normal subestima claramente la cola izquierda: el percentil 1 observado del S&P 500 es de −2,99 %, mientras que la normal predice −2,48 %, y el peor día del periodo fue de −5,97 %, un valor que una normal considera prácticamente imposible. La curtosis de 9,9 confirma el exceso de valores extremos. A diez jornadas esa diferencia todavía se nota: el percentil 1 del valor final es 92,9 con el motor normal y 91,8 y 91,6 con el bootstrap y con los bloques. A 252 jornadas la diferencia se desvanece, porque sumar muchos rendimientos independientes acerca el resultado a una normal por el teorema central del límite. La conclusión práctica es precisa: para medir el riesgo de un año el supuesto de normalidad no cambia mucho las cifras, pero para gestionar el riesgo diario o semanal de una estrategia de corto plazo sí lo hace, y ahí conviene el enfoque no paramétrico.

La cobertura vuelve a mostrar su costo. La cartera cubierta al 50 % termina entre 99 y 103 en el 90 % de los escenarios, con una caída máxima mediana del 0,9 %. Casi no puede perder, pero tampoco puede ganar. Es la versión simulada de lo que el apartado 9 mostró con datos reales.

Los límites del ejercicio deben quedar claros. Los tres motores suponen que el futuro se parece al pasado reciente: el normal toma su media y su desviación, y los dos no paramétricos reutilizan literalmente los rendimientos observados. Ninguno incorpora cambios de régimen, ni la inestabilidad de las correlaciones documentada en el apartado 9, ni costos de transacción, ni el efecto de reequilibrar a diario una cartera real. El motor de bloques recupera parte de la dependencia temporal, pero solo dentro de tramos de veinte días. Por eso los resultados deben leerse como un rango de escenarios compatible con el pasado, y no como una previsión.

11. Posibles pasos siguientes

El informe cierra la etapa descriptiva del proyecto. Los pasos que siguen se agrupan en seis frentes.

Datos. Sustituir el precio de cierre por el cierre ajustado para incorporar dividendos e intereses, lo que corregiría la subestimación del rendimiento de Microsoft, de Anglo American y sobre todo del fondo de bonos. Revisar los saltos por cambio de contrato en las series continuas de futuros, especialmente los días extremos del gas natural y de la plata. Ampliar la ventana más allá de cinco años para cubrir más de un régimen de mercado, aceptando que no todos los activos tienen histórico suficiente.

Dependencia. La correlación de distancias detectó una posible dependencia no monótona entre el petróleo y la renta variable que la correlación de rangos no ve. El paso natural es modelar la estructura de dependencia con cópulas, que separan las distribuciones individuales de la forma en que se relacionan, y contrastar la dependencia en las colas, es decir, si los activos caen juntos con más frecuencia de la que sugiere su correlación media. Una alternativa complementaria son los modelos de correlación condicional variable en el tiempo, coherentes con la inestabilidad que mostró el análisis de ventanas móviles.

Series de tiempo. Ajustar modelos de la familia ARIMA sobre los rendimientos y modelos de volatilidad condicional para la varianza, justificados por el agrupamiento de volatilidad observado. Contrastar formalmente la estacionariedad de las series transformadas y evaluar modelos de cambio de régimen, que permitirían representar los tramos en que las correlaciones cambian de signo.

Optimización de carteras. Sustituir el sorteo aleatorio de pesos por una optimización explícita: mínima varianza, máxima relación entre rendimiento y riesgo, y paridad de riesgo. Estimar la matriz de covarianzas con métodos robustos o de contracción, porque con veinte activos y mil observaciones la estimación directa es inestable. Y, sobre todo, validar fuera de muestra: elegir los pesos en un periodo, aplicarlos en el siguiente, reequilibrar con una regla fija e incluir costos de transacción. La cartera de pesos iguales debe usarse como referencia exigente, ya que en este periodo superó al índice sin necesidad de estimar nada.

Simulación. Reemplazar el bootstrap de bloques de longitud fija por un bootstrap estacionario, con longitud aleatoria, que evita artefactos en los extremos de cada tramo. Simular la cartera completa a partir de las marginales empíricas y una cópula ajustada, en lugar de simular directamente el rendimiento agregado, lo que permitiría que la dependencia entre activos cambie con el escenario. Añadir escenarios de estrés basados en episodios históricos concretos y medir el resultado con déficit esperado además de valor en riesgo.

Evaluación y decisión. Construir reglas de decisión a partir de los pronósticos, evaluarlas con validación progresiva en el tiempo y comparar su desempeño con pruebas no paramétricas, que es el terreno natural para contrastar estrategias cuyos rendimientos no son normales. Antes de cualquier aplicación con dinero real, el proyecto debería pasar por una fase de simulación en papel, con datos en tiempo real y costos incluidos.

Riesgos que conviene tener presentes. El principal es el sobreajuste: cuantas más combinaciones se prueben sobre el mismo periodo, más probable es encontrar una que funcione por azar, como ilustran las dos carteras seleccionadas por la simulación. El segundo es la dependencia de una única ventana temporal. El tercero, de orden práctico, es que todo el análisis se apoya en una sola fuente de datos gratuita que, como se documentó en el apartado 6, revisa sus series sin previo aviso. Este trabajo es académico y no constituye una recomendación de inversión.